

# 语言模型是无监督多任务学习者

Alec Radford\*   Jeffrey Wu\*   Rewon Child   David Luan  
Dario Amodei\*\*   Ilya Sutskever\*\*

\*,\* 同等贡献   <sup>1</sup>OpenAI, San Francisco, California, United States.

通讯作者: Alec Radford <alec@openai.com>

## Abstract

自然语言处理任务，如问答、机器翻译、阅读理解和摘要，通常通过在任务特定数据集上进行监督学习来解决。我们证明，当在一个包含数百万网页的新数据集 WebText 上训练时，语言模型在没有任何显式监督的情况下就开始学习这些任务。当以文档加问题为条件时，语言模型生成的答案在 CoQA 数据集上达到 55 F1——与 4 个基线系统中的 3 个相匹配或超过，而无需使用 127,000+ 训练样本。语言模型的容量对零样本任务迁移的成功至关重要，增加容量以对数线性方式提升各任务上的性能。我们的最大模型 GPT-2 是一个 15 亿参数的 Transformer，在零样本设置下，在 8 个测试的语言建模数据集上的 7 个上取得了最先进的结果，但仍然欠拟合 WebText。模型的样本反映了这些改进，并包含连贯的文本段落。这些发现为构建能够从其自然出现的示范中学习执行任务的语言处理系统指明了一条有前景的道路。

## 1 引言

机器学习系统如今（在期望上）通过使用大数据集、高容量模型和监督学习的组合，在其训练的任务上表现出色 (39; 63; 4)。然而，这些系统对数据分布 (58) 和任务规范的细微变化 (37) 是脆弱且敏感的。当前系统更适合被描述为狭隘专家而非胜任的通才。我们希望迈向更通用的系统，能够执行许多任务——最终无需为每个任务手动创建和标注训练数据集。

创建 ML 系统的主流方法是收集展示期望任务正确行为的训练样本数据集，训练系统模仿这些行为，然后在独立同分布 (IID) 的留出样本上测试其性能。这在推动狭隘专家方面取得了良好进展。但字幕模型 (41)、阅读理解系统 (33) 和图像分类器 (2) 在多样化输入上的常常不稳定的行为，凸显了这种方法的一些缺点。

我们怀疑单任务在单领域数据集上训练的普遍性是当前系统缺乏泛化性的主要原因。在使用当前架构向鲁棒系统迈进可能需要在广泛领域和任务上进行训练和性能测量。最近，一些基准如 GLUE (70) 和 decaNLP (47) 已被提出以开始研究这一点。

多任务学习 (12) 是提升通用性能的有前景的框架。然而，NLP 中的多任务训练仍处于早期阶段。最近的工作报告了适度的性能提升 (74)，迄今为止最雄心勃勃的两项工作分别在总共 10 和 17 个（数据集，目标）对上进行了训练 (47; 11)。从元学习的角度来看，每个（数据集，目标）对是从数据集和目标的分布中采样的单个训练样本。当前的 ML 系统需要数百到数千个样本才能归纳出泛化良好的函数。这表明多任务训练可能需要同样多的有效训练对才能用当前方法实现其承诺。用当前技术暴力推进的方式继续扩展数据集的创建和目标的设计将非常困难。这促使我们探索执行多任务学习的其他设置。

当前在语言任务上表现最好的系统利用预训练和监督微调的组合。这种方法有着悠久的历史，朝着更灵活的迁移形式发展。首先，词向量被学习并用作任务特定架构的输入 (49; 14)，然后循环网络的上下文表征被迁移 (17; 53)，最近的工作表明任务特定架构不再必要，迁移许多自注意力块就足够了 (56; 20)。

这些方法仍然需要监督训练来执行任务。当只有少量或没有监督数据可用时，另一条工作线展示了语言模型执行特定任务的潜力，如常识推理 (60) 和情感分析 (55)。

在本文中，我们连接这两条工作线，继续更通用迁移方法的趋势。我们证明语言模型可以在零样本设置下执行下游任务——无需任何参数或架构修改。我们通过突出语言模型在零样本设置下执行广泛任务的能力来展示这种方法的潜力。我们取得了有前景、有竞争力，甚至根据任务而异的最先进结果。

## 2 方法

我们方法的核心是语言建模。语言建模通常被框架化为从一组样本  $(x_1, x_2, \dots, x_n)$  进行无监督分布估计，每个样本由可变长度的符号序列  $(s_1, s_2, \dots, s_n)$  组成。由于语言具有自然的顺序性，通常将符号上的联合概率分解为条件概率的乘积 (32; 10)：

$$p(x) = \prod_{i=1}^n p(s_i | s_1, \dots, s_{i-1}) \quad (1)$$

这种方法允许对  $p(x)$  以及任何形式为  $p(s_{n-k}, \dots, s_n | s_1, \dots, s_{n-k-1})$  的条件分布进行可处理的采样和估计。近年来，能够计算这些条件概率的模型的表达能力有了显著提升，例如 Transformer 这样的自注意力架构 (67)。

学习执行单一任务可以在概率框架中表达为估计条件分布  $p(\text{output} | \text{input})$ 。由于通用系统应该能够执行许多不同任务，即使对相同输入，它也应该不仅以输入为条件，还要以要执行的任务为条件。也就是说，它应该建模  $p(\text{output} | \text{input}, \text{task})$ 。这在多任务和元学习设置中以各种方式被形式化。任务条件化通常在架构层面实现，如 (35) 中的任务特定编码器和解码器，或在算法层面实现，如 MAML 的内部和外部循环优化框架 (23)。但正如 McCann 等人 (47) 所例示的，语言提供了一种灵活的方式来将任务、输入和输出全部指定为符号序列。例如，一个翻译训练样本可以写为序列 (translate to french, english text, french text)。同样，阅读理解训练样本可以写为 (answer the question, document, question, answer)。McCann 等人 (47) 证明了可以训练单个模型 MQAN 来推断和执行此格式的许多不同任务。

语言建模原则上也能够学习 McCann 等人 (47) 的任务，而无需显式监督哪些符号是要预测的输出。由于监督目标与无监督目标相同，仅对序列的子集进行评估，因此无监督目标的全局最小值也是监督目标的全局最小值。在这种略微玩具化的设置下，Sutskever 等人 (64) 讨论的密度估计作为原则性训练目标的担忧被规避了。问题变成了我们在实践中是否能够将无监督目标优化到收敛。初步实验证实，足够大的语言模型能够在这种玩具设置下执行多任务学习，但学习速度远慢于显式监督方法。

虽然从上述良好设置的设置到“野生语言”的混乱还有很大距离，Weston (71) 在对话的背景下论证了开发能够直接从自然语言学习的系统的必要性，并演示了一个概念验证——使用前向预测教师输出，在没有奖励信号的情况下学习 QA 任务。虽然对话是一种有吸引力的方法，但我们担心它过于限制性。互联网包含大量被动可用的信息，无需交互式通信。我们的猜测是，具有足够容量的语言模型将开始学习推断和执行自然语言序列中展示的任务，以便更好地预测它们，无论其获取方式如何。如果语言模型能够做到这一点，它实际上就是在执行无监督多任务学习。我们通过分析语言模型在零样本设置下在广泛任务上的性能来测试这一点。

### 2.1 训练数据集

大多数先前工作在单一文本领域上训练语言模型，如新闻文章 (34)、Wikipedia (48) 或小说 (38)。我们的方法推动构建尽可能大且多样化的数据集，以在尽可能多样化的领域和上下文中收集任务的自然语言演示。

一个有前景的多样且几乎无限的文本来源是像 Common Crawl 这样的网络抓取。虽然这些档案比当前语言建模数据集大许多数量级，但它们存在显著的数据质量问题。Trinh 和 Le (66) 在他们关于常识推理的工作中使用了 Common Crawl，但注意到大量文档“内容大多难以理解”。我们在对 Common Crawl 的初步实验中观察到了类似的数据问题。

相反，我们创建了一个强调文档质量的新网络抓取。为此，我们只抓取经过人类策划/过滤的网页。手动过滤完整的网络抓取将异常昂贵，因此作为起点，我们抓取了来自 Reddit（一个社交媒体平台）的所有获得至少 3 个赞的外部链接。这可以被视为其他用户是否认为该链接有趣、有教育意义或仅仅是好玩的启发式指标。

结果数据集 WebText 包含这 4500 万个链接的文本子集。为了从 HTML 响应中提取文本，我们结合使用了 Dragnet (54) 和 Newspaper 内容提取器。本文中呈现的所有结果使用 WebText 的初步版本，不包含 2017 年 12 月之后创建的链接，在去重和基于启发式的清理后包含略超过 800 万文档，总计 40GB 文本。我们从 WebText 中移除了所有 Wikipedia 文档，因为它对其他数据集是常见数据源，可能因训练数据与测试评估任务的重叠而使分析复杂化。

### 2.2 输入表示

通用语言模型 (LM) 应该能够计算（并生成）任何字符串的概率。当前的大规模 LM 包括预处理步骤，如小写化、分词和词汇外标记，这些限制了可建模字符串的空间。虽然将 Unicode 字符串作为 UTF-8 字节序列处理优雅地满足了这一要求，如 Gillick 等人 (24) 的工作所示，当前字节级 LM 在十亿词基准等大规模数据集上 (3) 与词级 LM 相比没有竞争力。我们在自己尝试在 WebText 上训练标准字节级 LM 时也观察到了类似的性能差距。

字节对编码 (BPE) (61) 是字符级和词级语言建模之间的实用中间地带，有效地在频繁符号序列的词级输入和罕见符号序列的字符级输入之间插值。尽管 BPE 名为字节对编码，但参考实现通常在 Unicode 码点上操作而非字节序列。这些实现需要包含完整的 Unicode 符号空间才能建模所有 Unicode 字符串。这将导致在任何多符号标记添加之前基础词汇量就超过 130,000。与 BPE 常用的 32,000 到 64,000 标记词汇相比，这过大。相比之下，字节级版本的 BPE 只需要大小为 256 的基础词汇。然而，直接将 BPE 应用于字节序列会导致次优合并，因为 BPE 使用基于贪婪频率的启发式方法构建标记词汇。我们观察到 BPE 包含许多常见词的版本如 dog，因为它们以许多变体出现如 dog, dog! dog?。这导致有限词汇槽和模型容量的次优分配。为避免这种情况，我们阻止 BPE 跨越任何字节序列的字符类别进行合并。我们为空格添加了例外，这显著提高了压缩效率，同时仅添加了最小的跨多个词汇标记的词汇碎片化。

这种输入表示允许我们将词级 LM 的经验优势与字节级方法的通用性结合起来。由于我们的方法可以为任何 Unicode 字符串分配概率，这使我们能够在任何数据集上评估我们的 LM，无论预处理、分词或词汇大小如何。

## 2.3 模型

我们对我们的 LM 使用基于 Transformer (67) 的架构。该模型大体遵循 OpenAI GPT 模型 (56) 的细节，仅做少量修改。层归一化 (7) 被移动到每个子块的输入，类似于预激活残差网络 (26)，并在最后的自注意力块之后添加了额外的层归一化。使用了一种修改的初始化方法，考虑了随着模型深度在残差路径上的累积。我们按因子  $1/\sqrt{N}$  缩放初始化时残差层的权重，其中  $N$  是残差层的数量。词汇扩展到 50,257。我们还将上下文大小从 512 增加到 1024 个标记，并使用更大的批次大小 512。

Table 1: 4 个模型大小的架构超参数。

| 参数    | 层数 | $d_{\text{model}}$ |
|-------|----|--------------------|
| 117M  | 12 | 768                |
| 345M  | 24 | 1024               |
| 762M  | 36 | 1280               |
| 1542M | 48 | 1600               |

## 3 实验

我们训练并基准测试了四个大约对数均匀分布大小的 LM。架构总结于表 2。最小模型等价于原始 GPT，第二小模型等价于 BERT 的最大模型 (20)。我们的最大模型，称为 GPT-2，参数量比 GPT 多一个数量级以上。每个模型的学习率在 WebText 的 5% 留出样本上手动调整以获得最佳困惑度。所有模型仍然欠拟合 WebText，留出困惑度至今随着更多训练时间仍有改善。

### 3.1 语言建模

作为零样本任务迁移的初步步骤，我们有兴趣了解 WebText LM 在其训练的主要任务——语言建模上的零样本领域迁移表现。由于我们的模型在字节级别操作且不需要有损预处理或分词，我们可以在任何语言模型基准上评估它。语言建模数据集上的结果通常以缩放或指数化版本的平均负对数概率每规范预测单元（通常是字符、字节或词）来报告。我们通过计算数据集根据 WebText LM 的对数概率并除以规范单元的数量来评估相同的量。对于这些数据集的许多，WebText LM 将在显著分布外被测试，必须预测激进标准化后的文本、分词伪影如断开连接的标点和缩略词、打乱的句子，甚至字符串 <UNK>，这在 WebText 中极其罕见——在 400 亿字节中仅出现 26 次。我们在表 3 中报告了主要结果，使用可逆反分词器尽可能多地移除这些分词/预处理伪影。由于这些反分词器是可逆的，我们仍然可以计算数据集的对数概率，并且它们可以被视为一种简单的领域自适应形式。使用这些反分词器，GPT-2 观察到 2.5 到 5 的困惑度提升。

WebText LM 在领域和数据集之间良好迁移，在零样本设置下在 8 个数据集上的 7 个上改进了最先进水平。在小型数据集上（如 Penn Treebank 和 WikiText-2，仅有 1 到 2 百万训练标记）观察到大幅改进。在用于测量长期依赖的数据集上（如 LAMBADA (51) 和儿童图书测试 (28)）也观察到大幅改进。我们的模型在十亿词基准 (13) 上仍显著劣于先前工作。这可能是因为它既是最大的数据集，又具有最具破坏性的预处理——1BW 的句子级打乱移除了所有长程结构。



## 3.2 儿童图书测试

儿童图书测试 (CBT) (28) 旨在考察 LM 在不同类别词语上的性能：命名实体、名词、动词和介词。CBT 不是报告困惑度作为评估指标，而是报告在自动构建的完形填空测试上的准确率，其中任务是预测省略词的 10 个可能选择中哪一个正确。遵循原始论文引入的 LM 方法，我们根据 LM 计算每个选择及其余下句子的条件概率，并预测概率最高的那个。随着模型大小的增加，性能稳步提升，缩小了与人类表现的大部分差距。数据重叠分析显示，CBT 测试集书籍之一《丛林之书》(Rudyard Kipling 著) 在 WebText 中，因此我们在没有显著重叠的验证集上报告结果。GPT-2 在普通名词上达到 93.3% 和在命名实体上达到 89.1% 的新最先进结果。应用了反分词器以移除 CBT 中的 PTB 风格分词伪影。

## 3.3 LAMBADA

LAMBADA 数据集 (51) 测试系统建模文本中长期依赖的能力。任务是预测句子的最后一个词，这些句子需要至少 50 个标记的上下文才能让人类成功预测。GPT-2 将困惑度最先进水平从 99.8 (25) 提高到 8.6，并将 LM 在此测试上的准确率从 19% (19) 提高到 52.66%。调查 GPT-2 的错误显示大多数预测是句子的有效延续，但不是有效的最后词。这表明 LM 没有利用词必须是句子最后一个这一额外的有用约束。添加停用词过滤器作为对此的近似，进一步将准确率提高到 63.24%，在此任务上整体改进了 4% 的最先进水平。先前的最先进 (30) 使用不同的受限预测设置，其中模型输出被限制为仅出现在上下文中的词。对于 GPT-2，这种限制是有害而非有益的，因为 19% 的答案不在上下文中。我们使用无预处理版本的数据集。

## 3.4 Winograd 模式挑战

Winograd 模式挑战 (43) 旨在通过测量系统解决文本中歧义的能力来衡量其执行常识推理的能力。最近 Trinh 和 Le (66) 展示了使用 LM 在此挑战上取得显著进展，通过预测具有更高概率的歧义解决方案。我们遵循他们的问题形式化，在图 3 中可视化了我们的模型在完整和部分评分技术下的性能。GPT-2 将最先进准确率提高了 7%，达到 70.70%。该数据集相当小，仅有 273 个样本，因此我们推荐阅读 Trichelair 等人 (65) 以帮助对此结果进行语境化理解。

## 3.5 阅读理解

对话问答数据集 (CoQA) (59) 由来自 7 个不同领域的文档及关于文档的问答者之间的自然语言对话组成。CoQA 测试阅读理解能力以及模型回答依赖对话历史的问题（如“为什么？”）的能力。

GPT-2 在以文档、相关对话历史和最终标记 A: 为条件时的贪心解码在开发集上达到 55 F1。这与 4 个基线系统中的 3 个相匹配或超过，而无需使用这些基线训练的 127,000+ 人工收集的问答对。监督 SOTA，一个基于 BERT 的系统 (20)，正接近人类 89 F1 的性能。虽然 GPT-2 的性能对于无监督训练的系统来说令人兴奋，但对其答案和错误的一些检查表明 GPT-2 经常使用简单的基于检索的启发式方法，如在回答 who 问题时用文档中的名字作答。

## 3.6 摘要

我们测试 GPT-2 在 CNN 和 Daily Mail 数据集 (50) 上执行摘要的能力。为了诱导摘要行为，我们在文章后添加 TL;DR: 文本，并使用 Top-k 随机采样生成 100 个标记 (22) ( $k=2$ )，这减少了重复并鼓励比贪心解码更抽象的摘要。我们使用这 100 个标记中前 3 个生成的句子作为摘要。虽然生成的摘要质量上类似摘要，如表 14 所示，它们通常关注文章的近端内容，或混淆具体细节，如事故涉及多少辆汽车或 logo 是在帽子上还是衬衫上。在常用的 ROUGE 1,2,L 指标上，生成的摘要仅开始接近经典神经基线的性能，且仅勉强超过从文章中选择 3 个随机句子。当任务提示被移除时，GPT-2 的性能在聚合指标上下降 6.4 点，这证明了用自然语言调用语言模型中任务特定行为的能力。

## 3.7 翻译

我们测试 GPT-2 是否已开始学习从一种语言翻译到另一种。为了帮助它推断这是期望的任务，我们以格式为 english sentence = french sentence 的样本对上下文为语言模型设定条件，然后在最终提示 english sentence = 之后从模型采样，使用贪心解码并使用第一个生成的句子作为翻译。在 WMT-14 英法测试集上，GPT-2 获得 5 BLEU，略差于先前无监督词翻译工作中推断的双语词典逐词替换 (16)。在 WMT-14 法英测试集上，GPT-2 能够利用其非常强大的英语语言模型表现显著更好，达到 11.5 BLEU。这超过了 (5) 和 (42) 的几个无监督机器翻

译基线，但仍远差于当前最佳无监督机器翻译方法的 33.5 BLEU (6)。此任务的性能令我们惊讶，因为我们有意从 WebText 中移除了非英语网页作为过滤步骤。为确认这一点，我们对 WebText 运行了字节级语言检测器，仅检测到 10MB 的法语数据，这大约是先前无监督机器翻译研究中常见的单语法语语料库的 500 倍小。

### 3.8 问答

一种测试语言模型中包含什么信息的潜在方法是评估它生成事实风格问题正确答案的频率。此前在神经系统中展示此类行为的例子（所有信息存储在参数中），如神经对话模型 (69)，由于缺乏高质量评估数据集，报告的是定性结果。最近引入的 Natural Questions 数据集 (40) 是更定量测试这一点有前景的资源。与翻译类似，语言模型的上下文以样例问答对作为种子，这有助于模型推断数据集的短答案风格。GPT-2 在被阅读理解数据集如 SQUAD 常用的精确匹配指标评估时正确回答 4.1% 的问题。作为比较点，最小模型没有超过一个极其简单基线的 1.0% 准确率（该基线为每种问题类型返回最常见答案）。GPT-2 正确回答的问题多 5.3 倍，表明模型容量一直是此类任务上神经系统表现不佳的主要因素。GPT-2 分配给其生成答案的概率校准良好，GPT-2 在最自信的 1% 问题上的准确率为 63.1%。GPT-2 在开发集问题上生成的最自信的 30 个答案显示在表 5 中。GPT-2 的性能仍远、远差于将信息检索与抽取式文档问答混合的开放域问答系统 30% 到 50% 的范围 (1)。

## 4 泛化与记忆

计算机视觉的近期工作表明，常见图像数据集包含非平凡数量的近似重复图像。例如 CIFAR-10 的训练和测试图像之间有 3.3% 的重叠 (9)。这导致机器学习系统泛化性能的过度报告。随着数据集大小的增加，这一问题变得越来越可能，这提示 WebText 可能发生类似现象。因此分析有多少测试数据也出现在训练数据中很重要。

为研究这一点，我们创建了包含 WebText 训练集标记的 8-gram 的 Bloom 过滤器。为提高召回率，字符串被标准化为仅包含小写字母数字词，以单个空格作为分隔符。Bloom 过滤器构造为假阳性率上界为  $1/10^8$ 。我们进一步通过生成 100 万字符串验证了低假阳性率，其中零个被过滤器发现。

这些 Bloom 过滤器让我们能够计算给定数据集中也在 WebText 训练集中发现的 8-gram 的百分比。表 6 显示了对常见 LM 基准测试集的这一重叠分析。常见 LM 数据集的测试集与 WebText 训练集有 1-6% 的重叠，平均重叠为 3.2%。有些令人惊讶的是，许多数据集自身的训练拆分有更大的重叠，平均为 5.9%。

我们的方法优化召回率，虽然手动检视重叠显示许多常见短语，但有很多更长的匹配是由于重复数据。这不是 WebText 独有的。例如，我们发现 WikiText-103 的测试集有一篇文章也在训练数据集中。由于测试集只有 60 篇文章，至少存在 1.6% 的重叠。可能更令人担忧的是，1BW 与其自身训练集有近 13.2% 的重叠。

对于 Winograd 模式挑战，我们发现仅 10 个模式与 WebText 训练集有任何 8-gram 重叠。其中 2 个是虚假匹配。在剩余 8 个中，仅 1 个模式出现在任何泄露答案的上下文中。

对于 CoQA，新闻领域中约 15% 的文档已在 WebText 中，模型在这些文档上表现约好 3 F1。CoQA 的开发集指标报告 5 个不同领域的平均性能，我们测量到由于重叠在各领域之间大约 0.5-1.0 F1 的增益。然而，WebText 中没有实际的训练问题或答案，因为 CoQA 是在 WebText 链接截止日期之后发布的。

在 LAMBADA 上，平均重叠为 1.2%。GPT-2 在重叠大于 15% 的样本上表现约好 2 困惑度。排除所有有任何重叠的样本重新计算指标，结果从 8.6 变为 8.7 困惑度，准确率从 63.2% 降至 62.9%。整体结果这个非常小的变化可能是由于仅每 200 个样本中有 1 个具有显著重叠。

总体而言，我们的分析表明，WebText 训练数据与特定评估数据集之间的数据重叠对报告结果提供了小但一致的益处。然而，对于大多数数据集，我们没有注意到比标准训练和测试集之间已有的重叠显著更大的重叠，如表 6 所突出的。

理解和量化高度相似文本如何影响性能是一个重要研究问题。更好的去重技术如可扩展模糊匹配也可能有助于更好地回答这些问题。目前，我们建议在创建新 NLP 数据集的训练和测试拆分时，使用基于 n-gram 重叠的去重作为重要的验证步骤和健全性检查。

另一种确定 WebText LM 性能是否可归因于记忆的潜在方法是检查它们在自己留出集上的性能。如图 4 所示，训练和测试集上的性能相似，并随着模型大小增加而一起改善。这表明即使是 GPT-2 在许多方面仍欠拟合 WebText。

## 5 相关工作

本工作的一个重要部分衡量了在更大数据集上训练的更大语言模型的性能。这类似于 Jozefowicz 等人 (34) 在十亿词基准上扩展基于 RNN 的语言模型的工作。Bajgar 等人 (8) 也通过创建来自 Project Gutenberg 的更大的训练数据集来补充标准训练数据集，改进了儿童图书测试的结果。Hestness 等人 (27) 对各种深度学习模型的性能

如何作为模型容量和数据集大小的函数变化进行了彻底分析。我们的实验虽然在任务间噪音更大，但表明类似趋势对目标的子任务也成立，并持续到 1B+ 参数范围。

生成模型中有趣的学习功能此前已被记录，如 RNN 语言模型中的细胞执行行宽跟踪和引用/注释检测 (36)。更启发我们工作的是 Liu 等人 (45) 的观察，即训练生成 Wikipedia 文章的模型也学会了在语言之间翻译名称。

先前工作已探索了过滤和构建网页大文本语料库的替代方法，如 iWeb 语料库 (18)。

关于语言任务预训练方法有大量工作。除引言中提到的外，GloVe (52) 将词向量表示学习扩展到所有 Common Crawl。早期关于文本深度表示学习的有影响力的工作是 Skip-thought 向量 (38)。McCann 等人 (46) 探索了使用从机器翻译模型派生的表示，Howard 和 Ruder (31) 改进了 (17) 的基于 RNN 的微调方法。Conneau 等人 (15) 研究了自然语言推理模型学到的表示的迁移性能，Subramanian 等人 (62) 探索了大规模多任务训练。

Ramachandran 等人 (57) 证明了 seq2seq 模型受益于用预训练的语言模型初始化为编码器和解码器。更近期的工作表明 LM 预训练在为困难生成任务（如闲聊对话和基于对话的问答系统）进行微调时也有帮助 (73; 21)。

## 6 讨论

许多研究致力于学习 (29)、理解 (44) 和批判性评估 (72) 监督和非监督预训练方法的表示。我们的结果表明，无监督任务学习是一个值得探索的有前景的额外研究领域。这些发现可能有助于解释预训练技术在下游 NLP 任务中广泛成功的原因，因为我们显示，在极限情况下，其中一种预训练技术开始学习直接执行任务，而无需监督自适应或修改。

在阅读理解上，GPT-2 的性能在零样本设置下与监督基线具有竞争力。然而，在摘要等其他任务上，虽然质量上在执行任务，其性能根据定量指标仍仅处于初级阶段。虽然作为研究结果具有启发性，但在实际应用方面，GPT-2 的零样本性能仍远未达到可用水平。

我们研究了 WebText LM 在许多规范 NLP 任务上的零样本性能，但还有许多额外任务可以评估。毫无疑问有许多实际任务 GPT-2 的性能仍不比随机好。即使在我们评估的常见任务上，如问答和翻译，语言模型仅在具有足够容量时才开始超越琐碎基线。

虽然零样本性能建立了 GPT-2 在许多任务上潜在性能的基线，但不清楚微调的上限在哪里。在某些任务上，GPT-2 完全抽象的输出与当前许多问答和阅读理解数据集上最先进的基于抽取式指针网络 (68) 的输出有显著差异。鉴于先前 GPT 微调的成功，我们计划研究在 decaNLP 和 GLUE 等基准上的微调，特别是因为不清楚 GPT-2 的额外训练数据和容量是否足以克服 BERT (20) 所展示的单向表示的低效性。

## 7 结论

当大型语言模型在足够大且多样化的数据集上训练时，它能够在许多领域和数据集上表现出色。GPT-2 在 8 个测试的语言建模数据集中的 7 个上零样本达到最先进性能。模型在零样本设置下能够执行的任务的多样性表明，训练以最大化足够多样化文本语料库似然的高容量模型开始学习如何在不需要显式监督的情况下执行令人惊讶数量的任务。

## 致谢

感谢所有在 WebText 中撰写文本、分享链接和点赞内容的人。GPT-2 的训练数据涉及数百万人的参与创

。还要感谢所有帮助我们提供训练基础设施的 Googler，包括 Zak Stone、JS Riehl、Jonathan Hseu、Russell Power、Yulong Cheng、Noam Shazeer、Solomon Boulos、Michael Banfield、Aman Gupta、Daniel Sohn 等等。最后感谢为论文草稿提供反馈的人：Jacob Steinhardt、Sam Bowman、Geoffrey Irving 和 Madison May。

## References

- [1] Alberti, C., Lee, K., and Collins, M. A BERT baseline for the Natural Questions. arXiv preprint arXiv:1901.08634, 2019.
- [2] Alcorn, M. A., Li, Q., Gong, Z., Wang, C., Mai, L., Ku, W.-S., and Nguyen, A. Strike (with) a pose: Neural networks are easily fooled by strange poses of familiar objects. arXiv preprint arXiv:1811.11553, 2018.

- [3] Al-Rfou, R., Choe, D., Constant, N., Guo, M., and Jones, L. Character-level language modeling with deeper self-attention. arXiv preprint arXiv:1808.04444, 2018.
- [4] Amodei, D., et al. Deep speech 2: End-to-end speech recognition in English and Mandarin. In ICML, pp. 173–182, 2016.
- [5] Artetxe, M., Labaka, G., Agirre, E., and Cho, K. Unsupervised neural machine translation. arXiv preprint arXiv:1710.11041, 2017.
- [6] Artetxe, M., Labaka, G., and Agirre, E. An effective approach to unsupervised machine translation. arXiv preprint arXiv:1902.01313, 2019.
- [7] Ba, J. L., Kiros, J. R., and Hinton, G. E. Layer normalization. arXiv preprint arXiv:1607.06450, 2016.
- [8] Bajgar, O., Kadlec, R., and Kleindienst, J. Embracing data abundance: Booktest dataset for reading comprehension. arXiv preprint arXiv:1610.00956, 2016.
- [9] Barz, B. and Denzler, J. Do we train on test data? Purging CIFAR of near-duplicates. arXiv preprint arXiv:1902.00423, 2019.
- [10] Bengio, Y., Ducharme, R., Vincent, P., and Jauvin, C. A neural probabilistic language model. JMLR, 3(Feb):1137–1155, 2003.
- [11] Bowman, S. R., et al. Looking for ELMo’s friends: Sentence-level pretraining beyond language modeling. arXiv preprint arXiv:1812.10860, 2018.
- [12] Caruana, R. Multitask learning. Machine Learning, 28(1):41–75, 1997.
- [13] Chelba, C., et al. One billion word benchmark for measuring progress in statistical language modeling. arXiv preprint arXiv:1312.3005, 2013.
- [14] Collobert, R., Weston, J., Bottou, L., Karlen, M., Kavukcuoglu, K., and Kuksa, P. Natural language processing (almost) from scratch. JMLR, 12(Aug):2493–2537, 2011.
- [15] Conneau, A., Kiela, D., Schwenk, H., Barrault, L., and Bordes, A. Supervised learning of universal sentence representations from natural language inference data. arXiv preprint arXiv:1705.02364, 2017.
- [16] Conneau, A., Lample, G., Ranzato, M., Denoyer, L., and Jégou, H. Word translation without parallel data. arXiv preprint arXiv:1710.04087, 2017.
- [17] Dai, A. M. and Le, Q. V. Semi-supervised sequence learning. In NeurIPS, pp. 3079–3087, 2015.
- [18] Davies, M. The 14 billion word iWeb corpus. <https://corpus.byu.edu/iWeb/>, 2018.
- [19] Dehghani, M., Gouws, S., Vinyals, O., Uszkoreit, J., and Kaiser, L. Universal transformers. arXiv preprint arXiv:1807.03819, 2018.
- [20] Devlin, J., Chang, M.-W., Lee, K., and Toutanova, K. BERT: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805, 2018.
- [21] Dinan, E., Roller, S., Shuster, K., Fan, A., Auli, M., and Weston, J. Wizard of Wikipedia: Knowledge-powered conversational agents. arXiv preprint arXiv:1811.01241, 2018.
- [22] Fan, A., Lewis, M., and Dauphin, Y. Hierarchical neural story generation. arXiv preprint arXiv:1805.04833, 2018.
- [23] Finn, C., Abbeel, P., and Levine, S. Model-agnostic meta-learning for fast adaptation of deep networks. arXiv preprint arXiv:1703.03400, 2017.
- [24] Gillick, D., Brunk, C., Vinyals, O., and Subramanya, A. Multilingual language processing from bytes. arXiv preprint arXiv:1512.00103, 2015.

- [25] Grave, E., Joulin, A., and Usunier, N. Improving neural language models with a continuous cache. arXiv preprint arXiv:1612.04426, 2016.
- [26] He, K., Zhang, X., Ren, S., and Sun, J. Identity mappings in deep residual networks. In ECCV, pp. 630–645. Springer, 2016.
- [27] Hestness, J., et al. Deep learning scaling is predictable, empirically. arXiv preprint arXiv:1712.00409, 2017.
- [28] Hill, F., Bordes, A., Chopra, S., and Weston, J. The Goldilocks principle: Reading children’s books with explicit memory representations. arXiv preprint arXiv:1511.02301, 2015.
- [29] Hill, F., Cho, K., and Korhonen, A. Learning distributed representations of sentences from unlabelled data. arXiv preprint arXiv:1602.03483, 2016.
- [30] Hoang, L., Wiseman, S., and Rush, A. M. Entity tracking improves cloze-style reading comprehension. arXiv preprint arXiv:1810.02891, 2018.
- [31] Howard, J. and Ruder, S. Universal language model fine-tuning for text classification. In ACL (Volume 1), pp. 328–339, 2018.
- [32] Jelinek, F. and Mercer, R. L. Interpolated estimation of Markov source parameters from sparse data. In Proc. Workshop on Pattern Recognition in Practice, 1980.
- [33] Jia, R. and Liang, P. Adversarial examples for evaluating reading comprehension systems. arXiv preprint arXiv:1707.07328, 2017.
- [34] Jozefowicz, R., Vinyals, O., Schuster, M., Shazeer, N., and Wu, Y. Exploring the limits of language modeling. arXiv preprint arXiv:1602.02410, 2016.
- [35] Kaiser, L., et al. One model to learn them all. arXiv preprint arXiv:1706.05137, 2017.
- [36] Karpathy, A., Johnson, J., and Fei-Fei, L. Visualizing and understanding recurrent networks. arXiv preprint arXiv:1506.02078, 2015.
- [37] Kirkpatrick, J., et al. Overcoming catastrophic forgetting in neural networks. PNAS, pp. 201611835, 2017.
- [38] Kiros, R., et al. Skip-thought vectors. In NeurIPS, pp. 3294–3302, 2015.
- [39] Krizhevsky, A., Sutskever, I., and Hinton, G. E. ImageNet classification with deep convolutional neural networks. In NeurIPS, pp. 1097–1105, 2012.
- [40] Kwiatkowski, T., et al. Natural Questions: a benchmark for question answering research. 2019.
- [41] Lake, B. M., Ullman, T. D., Tenenbaum, J. B., and Gershman, S. J. Building machines that learn and think like people. Behavioral and Brain Sciences, 40, 2017.
- [42] Lample, G., Conneau, A., Denoyer, L., and Ranzato, M. Unsupervised machine translation using monolingual corpora only. arXiv preprint arXiv:1711.00043, 2017.
- [43] Levesque, H., Davis, E., and Morgenstern, L. The Winograd schema challenge. In KR, 2012.
- [44] Levy, O. and Goldberg, Y. Neural word embedding as implicit matrix factorization. In NeurIPS, pp. 2177–2185, 2014.
- [45] Liu, P. J., et al. Generating Wikipedia by summarizing long sequences. arXiv preprint arXiv:1801.10198, 2018.
- [46] McCann, B., Bradbury, J., Xiong, C., and Socher, R. Learned in translation: Contextualized word vectors. In NeurIPS, pp. 6294–6305, 2017.



- [47] McCann, B., Keskar, N. S., Xiong, C., and Socher, R. The natural language decathlon: Multitask learning as question answering. arXiv preprint arXiv:1806.08730, 2018.
- [48] Merity, S., Xiong, C., Bradbury, J., and Socher, R. Pointer sentinel mixture models. arXiv preprint arXiv:1609.07843, 2016.
- [49] Mikolov, T., Sutskever, I., Chen, K., Corrado, G. S., and Dean, J. Distributed representations of words and phrases and their compositionality. In NeurIPS, pp. 3111–3119, 2013.
- [50] Nallapati, R., Zhou, B., Gulcehre, C., Xiang, B., et al. Abstractive text summarization using sequence-to-sequence RNNs and beyond. arXiv preprint arXiv:1602.06023, 2016.
- [51] Paperno, D., et al. The LAMBADA dataset: Word prediction requiring a broad discourse context. arXiv preprint arXiv:1606.06031, 2016.
- [52] Pennington, J., Socher, R., and Manning, C. GloVe: Global vectors for word representation. In EMNLP, pp. 1532–1543, 2014.
- [53] Peters, M. E., et al. Deep contextualized word representations. arXiv preprint arXiv:1802.05365, 2018.
- [54] Peters, M. E. and Lécocq, D. Content extraction using diverse feature sets. In WWW, pp. 89–90. ACM, 2013.
- [55] Radford, A., Jozefowicz, R., and Sutskever, I. Learning to generate reviews and discovering sentiment. arXiv preprint arXiv:1704.01444, 2017.
- [56] Radford, A., Narasimhan, K., Salimans, T., and Sutskever, I. Improving language understanding by generative pre-training. 2018.
- [57] Ramachandran, P., Liu, P. J., and Le, Q. V. Unsupervised pretraining for sequence to sequence learning. arXiv preprint arXiv:1611.02683, 2016.
- [58] Recht, B., Roelofs, R., Schmidt, L., and Shankar, V. Do CIFAR-10 classifiers generalize to CIFAR-10? arXiv preprint arXiv:1806.00451, 2018.
- [59] Reddy, S., Chen, D., and Manning, C. D. CoQA: A conversational question answering challenge. arXiv preprint arXiv:1808.07042, 2018.
- [60] Schwartz, R., et al. Story cloze task: UW NLP system. In Proc. 2nd Workshop on Linking Models of Lexical, Sentential and Discourse-level Semantics, pp. 52–55, 2017.
- [61] Sennrich, R., Haddow, B., and Birch, A. Neural machine translation of rare words with subword units. arXiv preprint arXiv:1508.07909, 2015.
- [62] Subramanian, S., Trischler, A., Bengio, Y., and Pal, C. J. Learning general purpose distributed sentence representations via large scale multi-task learning. arXiv preprint arXiv:1804.00079, 2018.
- [63] Sutskever, I., Vinyals, O., and Le, Q. V. Sequence to sequence learning with neural networks. In NeurIPS, pp. 3104–3112, 2014.
- [64] Sutskever, I., et al. Towards principled unsupervised learning. arXiv preprint arXiv:1511.06440, 2015.
- [65] Trichelair, P., et al. On the evaluation of common-sense reasoning in natural language understanding. arXiv preprint arXiv:1811.01778, 2018.
- [66] Trinh, T. H. and Le, Q. V. A simple method for commonsense reasoning. arXiv preprint arXiv:1806.02847, 2018.
- [67] Vaswani, A., et al. Attention is all you need. In NeurIPS, pp. 5998–6008, 2017.
- [68] Vinyals, O., Fortunato, M., and Jaitly, N. Pointer networks. In NeurIPS, pp. 2692–2700, 2015.

- [69] Vinyals, O. and Le, Q. A neural conversational model. arXiv preprint arXiv:1506.05869, 2015.
- [70] Wang, A., et al. GLUE: A multi-task benchmark and analysis platform for natural language understanding. arXiv preprint arXiv:1804.07461, 2018.
- [71] Weston, J. E. Dialog-based language learning. In NeurIPS, pp. 829–837, 2016.
- [72] Wieting, J. and Kiela, D. No training required: Exploring random encoders for sentence classification. arXiv preprint arXiv:1901.10444, 2019.
- [73] Wolf, T., Sanh, V., Chaumond, J., and Delangue, C. TransferTransfo: A transfer learning approach for neural network based conversational agents. arXiv preprint arXiv:1901.08149, 2019.
- [74] Yogatama, D., et al. Learning and evaluating general linguistic intelligence. arXiv preprint arXiv:1901.11373, 2019.