

世界模型

David Ha¹ Jürgen Schmidhuber^{2,3}

Abstract

我们探索为流行的强化学习环境构建成式神经网络模型。我们的世界模型能够以无监督的方式快速训练，学习环境的压缩时空表征。通过将从世界模型中提取的特征作为智能体的输入，我们可以训练一个非常紧凑且简单的策略来解决所需任务。我们甚至可以在世界模型生成的、智能体自身幻觉梦境中完全训练智能体，并将该策略迁移回真实环境中。

本文的交互式版本可在 <https://worldmodels.github.io> 获取。

1. 引言

人类基于有限感官所能感知到的信息，建立起对世界的心理模型。我们所做的决策和行动都基于这一内部模型。系统动力学之父 Jay Wright Forrester 将心理模型描述为：

我们脑海中携带的关于周围世界的图像，仅仅是一个模型。没有人在脑海中想象整个世界、政府或国家。他只有一些选定的概念以及它们之间的关系，并以此来表征真实的系统。(Forrester, 1971)




Figure 1. 世界模型，摘自 Scott McCloud 的《理解漫画》。(McCloud, 1993; E, 2012)

为了处理日常生活中涌入的大量信息，我们的大脑学习了这些信息的空间和时间方面的抽象表征。我们能够观察一个场景并记住其抽象描述 (Cheang & Tsao, 2017;

Quiroga et al., 2005)。证据还表明，我们在任何给定时刻感知到的东西，都受大脑基于内部模型对未来的预测所支配 (Nortmann et al., 2015; Gerrit et al., 2013)。

理解大脑中预测模型的一种方式，它可能不仅仅关乎一般意义上的未来预测，而是预测给定当前运动动作下的未来感觉数据 (Keller et al., 2012; Leinweber et al., 2017)。我们能够本能地基于这一预测模型行动，在面对危险时执行快速的反射行为 (Mobbs et al., 2015)，而无需有意识地规划行动方案。

以棒球为例。击球手只有毫秒级的时间来决定如何挥棒——这比视觉信号到达大脑所需的时间还短。我们之所以能够击中 100 英里/小时的快球，是因为我们有能力本能地预测球将到达何时何地。对于职业选手来说，这一切都是下意识发生的。他们的肌肉根据内部模型的预测，在正确的时间和位置反射性地挥棒 (Gerrit et al., 2013)。他们可以快速地对未来预测做出反应，而无需有意识地推演可能的未来场景来形成计划 (Hirshon, 2013)。




Figure 2. 我们所看到的，是基于大脑对未来的预测 (Kitaoka, 2002; Watanabe et al., 2018)。

在许多强化学习 (RL) 问题中 (Kaelbling et al., 1996; Sutton & Barto, 1998; Wiering & van Otterlo, 2012)，人工智能体同样受益于对过去和当前状态的良好表征以及对未来的良好预测模型 (Werbos, 1987; Silver, 2017)，最好是实现在通用计算机上的强大预测模型，如循环神经网络 (RNN) (Schmidhuber, 1990a;b; 1991a)。

大型 RNN 是高度表达性的模型，可以学习丰富的时空数据表征。然而，文献中的许多无模型 RL 方法通常只使用参数较少的小型神经网络。RL 算法常常受限于信用分配问题，这使得传统 RL 算法难以学习大型模型的上百万个权重，因此在实践中，通常使用较小的网络，因为它们能够在训练中更快地迭代到一个好的策略。

理想情况下，我们希望能够高效训练基于大型 RNN 的智

¹Google Brain ²NNAISENSE ³Swiss AI Lab, IDSIA (USI & SUPSI)



Figure 3. 在本工作中，我们构建了 OpenAI Gym 环境的概率生成模型。基于 RNN 的世界模型使用从真实游戏环境中收集的观测数据进行训练。在世界模型训练完成后，我们可以用它来模拟完整的环境并训练智能体。

能体。反向传播算法 (Linnainmaa, 1970; Kelley, 1960; Werbos, 1982) 可用于高效训练大型神经网络。在本工作中，我们着眼于训练大型神经网络¹来解决 RL 任务，方法是将智能体分解为大型世界模型和小型控制器模型。我们首先以无监督方式训练一个大型神经网络来学习智能体所处世界的模型，然后训练较小的控制器模型来学习使用这个世界模型来执行任务。小型控制器使训练算法能够将信用分配问题聚焦在较小的搜索空间上，同时通过较大的世界模型，不牺牲容量和表达能力。通过让智能体经由世界模型的透镜来训练，我们证明它可以学习高度紧凑的策略来执行任务。

尽管有大量与基于模型的强化学习相关的研究，但本文并非意在成为该领域当前状态的综述 (Arulkumaran et al., 2017; Schmidhuber, 2015b)。相反，本文的目标是从 1990 年至 2015 年间关于基于 RNN 的世界模型与控制器组合的一系列论文中提炼几个关键概念 (Schmidhuber, 1990a;b; 1991a; 1990c; 2015a)。我们还将讨论文献中其他具有相似思路的相关工作，即学习世界模型并使用该模型训练智能体。

在本文中，我们提出了一个简化的框架，用于实验性地展示这些论文中的一些关键概念，并就如何将思想有效应用于各种 RL 环境提出进一步的见解。在描述我们的方法论和实验时，我们使用与 *On Learning to Think: Algorithmic Information Theory for Novel Combinations of RL Controllers and RNN World Models* (Schmidhuber, 2015a) 中类似的术语和符号。

2. 智能体模型

我们提出了一个受人类认知系统启发的简单模型。在该模型中，我们的智能体具有一个视觉感知组件，将其所见压缩为一个小型表征编码。它还具有一个记忆组件，基于历史信息对未来编码进行预测。最后，我们的智能体具有一

¹典型的无模型 RL 模型具有 10^3 到 10^6 量级的模型参数。我们着眼于训练 10^7 量级参数的模型，这与拥有 10^8 甚至 10^9 个参数的最先进深度学习模型相比仍然相当小。原则上，本文所描述的方法可以利用这些更大的网络，如果我们需要的话。

个决策组件，仅基于视觉和记忆组件创建的表征来决定采取何种行动。




Figure 4. 我们的智能体由三个紧密协作的组件构成：视觉 (V)、记忆 (M) 和控制器 (C)。

2.1. VAE (V) 模型

环境在每个时间步为我们的智能体提供高维输入观测。该输入通常是视频序列中的 2D 图像帧。V 模型的作用是学习每个观测输入帧的抽象、压缩表征。




Figure 5. 变分自编码器 (VAE) 的流程示意图。

在此，我们使用简单的变分自编码器 (Kingma & Welling, 2013; Rezende et al., 2014) 作为我们的 V 模型，将每个图像帧压缩为一个小型潜在向量 z 。

2.2. MDN-RNN (M) 模型

V 模型的作用是压缩智能体在每个时间帧看到的内容，而我们同样希望压缩随时间推移发生的变化。为此，M 模型的作用是预测未来。M 模型作为 V 预期产生的未来 z 向量的预测模型。由于许多复杂环境本质上是随机的，我们训练 RNN 输出概率密度函数 $p(z)$ ，而非对 z 进行确定性预测。

在我们的方法中，我们将 $p(z)$ 近似为混合高斯分布，并训练 RNN 输出下一个潜在向量 z_{t+1} 的概率分布，给定其可获取的当前和历史信息。

更具体地说，RNN 将对 $P(z_{t+1} | a_t, z_t, h_t)$ 建模，其中 a_t 是在时间 t 执行的动作， h_t 是 RNN 在时间 t 的隐藏状态。在采样过程中，我们可以调节一个温度参数 τ 来控制模型的不确定性，如 (Ha & Eck, 2017) 中所做的那样——我们将发现调节 τ 对后续训练控制器非常有用。

这种方法被称为混合密度网络 (Bishop, 1994) 与 RNN




Figure 6. 具有混合密度网络输出层的 RNN。MDN 输出混合高斯分布的参数，用于采样预测下一个潜在向量 z 。




Figure 7. SketchRNN (Ha & Eck, 2017) 是使用 MDN-RNN 预测素描绘制中下一个笔触的示例。我们使用类似模型来预测下一个潜在向量 z_t 。

的结合 (MDN-RNN) (Graves, 2013; Ha, 2017a)，过去曾应用于序列生成问题，如生成手写 (Graves, 2013) 和素描 (Ha & Eck, 2017)。

2.3. 控制器 (C) 模型

控制器 (C) 模型负责决定行动方案，以最大化智能体在环境 rollout 过程中的预期累积奖励。在我们的实验中，我们刻意使 C 尽可能简单和小型，并与 V 和 M 分开训练，使得智能体的大部分复杂性存在于世界模型 (V 和 M) 中。

C 是一个简单的单层线性模型，在每个时间步将 z_t 和 h_t 直接映射到动作 a_t ：

$$a_t = W_c [z_t \ h_t] + b_c \quad (1)$$

在这个线性模型中， W_c 和 b_c 分别是将拼接输入向量 $[z_t \ h_t]$ 映射到输出动作向量 a_t 的权重矩阵和偏置向量。

2.4. 将 V、M 和 C 组合在一起

下面的流程示意图说明了 V、M 和 C 如何与环境交互：

以下是如何在 OpenAI Gym (Brockman et al., 2016) 环境中使用我们智能体模型的伪代码：

```
def rollout(controller):
```




Figure 8. 智能体模型的流程图。在每个时间步 t ，原始观测首先由 V 处理以生成 z_t 。C 的输入是该潜在向量 z_t 与 M 在每一时间步的隐藏状态 h_t 的拼接。然后 C 将输出一个用于电机控制的动作向量 a_t ，并影响环境。然后 M 将当前 z_t 和动作 a_t 作为输入来更新自身的隐藏状态以生成 h_{t+1} ，供时间步 $t+1$ 使用。

```
''' env, rnn, vae are '''
''' global variables '''
obs = env.reset()
h = rnn.initial_state()
done = False
cumulative_reward = 0
while not done:
    z = vae.encode(obs)
    a = controller.action([z, h])
    obs, reward, done = env.step(a)
    cumulative_reward += reward
    h = rnn.forward([a, z, h])
return cumulative_reward
```

在给定的 controller C 上运行该函数将返回一次 rollout 中的累积奖励。

C 的这种极简设计还提供了重要的实际优势。深度学习的进步为我们提供了高效训练大型复杂模型的工具，前提是我们可以定义一个良态、可微的损失函数。我们的 V 和 M 模型被设计为能够使用反向传播算法在现代 GPU 加速器上高效训练，因此我们希望模型的大部分复杂性和模型参数都位于 V 和 M 中。相比之下，线性模型 C 的参数数量极少。这种选择使我们能够探索更多非传统的方式来训练 C——例如，甚至可以使用进化策略 (ES) (Rechenberg, 1973; Schwefel, 1977) 来解决更具挑战性的 RL 任务，其中信用分配问题十分困难。

为优化 C 的参数，我们选择了协方差矩阵自适应进化策略 (CMA-ES) (Hansen, 2016; Hansen & Ostermeier, 2001) 作为优化算法，因为它已知适用于解空间达数千参数的问题。我们在具有多个 CPU 核心的单台机器上演化 C 的参数，并行运行环境的多次 rollout。

有关实验中使用的模型、训练过程和环境的具体信息，请参阅附录部分。

3. 赛车实验

在本节中，我们描述如何训练前面描述的智能体模型来解决赛车任务。据我们所知，我们的智能体是首个达到解决该任务所需分数的已知解决方案。²

3.1. 用于特征提取的世界模型

预测性世界模型可以帮助我们提取有用的空间和时间表征。通过将特征用作控制器的输入，我们可以训练一个紧凑且极简的控制器来执行连续控制任务，例如在一个称为 **CarRacing-v0** (Klimov, 2016) 的俯视赛车环境中从像素输入学习驾驶。



Figure 9. 我们的智能体在 **CarRacing-v0** 中学习导航。

在该环境中，赛道在每次试验中是随机生成的，我们的智能体因在尽可能短的时间内访问尽可能多的图块而获得奖励。智能体控制三个连续动作：向左/向右转向、加速和刹车。

为训练 V 模型，我们首先收集了 10,000 次随机 rollout 的数据集。我们首先让一个智能体随机行动来多次探索环境，并记录所执行的随机动作 a_t 以及环境产生的观测结果。我们使用此数据集训练 V 来学习每一帧观测的潜在空间。我们训练 VAE 将每一帧编码为低维潜在向量 z ，通过最小化给定帧与解码器从 z 生成的该帧重建版本之间的差异。

现在我们可以使用训练好的 V 模型将每个时间步 t 的帧预处理为 z_t ，以训练 M 模型。使用这些预处理数据以及记录的随机动作 a_t ，我们的 MDN-RNN 现在可以被训练为将 $P(z_{t+1} | a_t, z_t, h_t)$ 建模为混合高斯分布。³

²我们发现这个任务很有趣，因为虽然训练一个智能体在随机生成的赛道上摇摆并取得中等分数并不困难，但 **CarRacing-v0** 将解决定义为在 100 次连续试验中获得平均奖励 900，这意味着智能体只能容忍极少的驾驶失误。

³原则上，我们可以以端到端方式同时训练两个模型，但我们发现分别训练每个模型更具实践性，并且也能取得令人满意的结果。训练每个模型仅需要在单个 GPU 上不到一小时的计算时间。我们还可以训练各自的 VAE 和 MDN-RNN 模型而无需穷举调节超参数。

在本实验中，世界模型（V 和 M）对环境中的实际奖励信号一无所知。它的任务仅仅是压缩和预测观测到的图像帧序列。只有控制器（C）模型能够访问来自环境的奖励信息。由于线性控制器模型内部仅有 867 个参数，诸如 CMA-ES 之类的进化算法非常适合此优化任务。

我们可以使用 VAE 在每个时间步用 z_t 重建每一帧，以可视化智能体在 rollout 中实际看到的信息的质量。下图是在 **CarRacing-v0** 截图上训练的 VAE 模型。




Figure 10. 尽管在这一有损压缩过程中损失了细节，潜在向量 z 仍然捕获了每个图像帧的本质。

在本文的在线版本中，读者可以加载随机选择的截屏，将其编码为小型潜在向量 z ，再用于重建原始截屏。读者还可以使用滑块调整 z 向量的值，观察它如何影响重建结果，或随机化 z 来探索可能的截屏空间。

3.2. 流程

总结赛车实验，以下为执行步骤：

1. 从随机策略收集 10,000 次 rollout。
2. 训练 VAE (V) 将帧编码为 $z \in \mathcal{R}^{32}$ 。
3. 训练 MDN-RNN (M) 对 $P(z_{t+1} | a_t, z_t, h_t)$ 建模。
4. 定义控制器 (C) 为 $a_t = W_c [z_t h_t] + b_c$ 。
5. 使用 CMA-ES 求解最大化预期累积奖励的 W_c 和 b_c 。

模型	参数数量
VAE	4,348,547
MDN-RNN	422,368
控制器	867

3.3. 实验结果

仅使用 V 模型

如果我们有良好的观测表征，训练智能体驾驶并不是一项困难的任务。先前的工作 (Hünemann, 2017; Bling,

2015; Lau, 2016) 表明, 通过一组良好的关于观测的手工设计信息——例如 LIDAR 信息、角度、位置和速度——人们可以轻松训练一个小型前馈网络来接受这些手工输入并输出令人满意的导航策略。因此, 我们首先通过限制 C 只能访问 V 而不能访问 M 来测试我们的智能体, 即定义控制器为 $a_t = W_c z_t + b_c$ 。



Figure 11. 将控制器限制为只能看到 z_t 而不能看到 h_t , 会导致摇摆和不稳定的驾驶行为。

尽管在这种设置下智能体仍能沿赛道导航, 但我们注意到它会左右摇摆, 并在急转弯处错过赛道。这种受限智能体在 100 次随机试验中的平均得分为 632 ± 251 , 与 OpenAI Gym 排行榜上其他智能体的表现 (Klimov, 2016) 以及 A3C 等传统深度 RL 方法 (Khan & Elibol, 2016; Jang et al., 2017) 相当。为 C 的策略网络添加一个隐藏层可将结果提升至 788 ± 141 , 但仍不足以解决该环境。

完整世界模型 (V 和 M)

我们的 V 模型提供的表征 z_t 仅捕捉到某一时点的表征, 预测能力不强。相比之下, M 被训练来做一件事, 而且做得非常好, 那就是预测 z_{t+1} 。由于 M 对 z_{t+1} 的预测是由 RNN 在时间 t 的隐藏状态 h_t 生成的, 该向量是我们可以提供给智能体的学习特征集的一个良好候选。将 z_t 与 h_t 结合, 为控制器 C 提供当前观测以及未来预期的良好表征。

我们看到, 允许智能体同时访问 z_t 和 h_t 极大地提升了其驾驶能力。驾驶更加稳定, 智能体似乎能够有效地应对急转弯。此外, 我们看到在赛车中做出这些快速反射性驾驶决策时, 智能体不需要提前规划并推演假设的未来场景。由于 h_t 包含了关于未来概率分布的信息, 智能体可以仅仅本能地查询 RNN 来指导其动作决策。就像经验丰富的方程式车手或前面讨论的棒球选手一样, 智能体可以在关键时刻本能地预测何时何地如何进行导航。

我们的智能体在 100 次随机试验中达到了 906 ± 21 的得分, 有效解决了该任务并获得了新的最先进结果。之前使用深度 RL 方法的尝试 (Khan & Elibol, 2016; Jang et al., 2017) 获得的平均得分在 591–652 范围内, 而排行



Figure 12. 如果我们让控制器同时访问 z_t 和 h_t , 驾驶会更加稳定。

方法	平均得分
DQN (Prieur, 2017)	343 ± 18
A3C (连续) (Jang et al., 2017)	591 ± 45
A3C (离散) (Khan & Elibol, 2016)	652 ± 10
CEOBILLIONAIRE (Gym 排行榜)	838 ± 11
V 模型	632 ± 251
带隐藏层的 V 模型	788 ± 141
完整世界模型	906 ± 21

Table 1. 使用不同方法获得的 CarRacing-v0 得分。

榜上报告的最佳解决方案在 100 次随机试验中的平均得分为 838 ± 11 。传统深度 RL 方法通常需要对每一帧进行预处理, 例如使用边缘检测 (Jang et al., 2017), 以及将最近若干帧堆叠 (Khan & Elibol, 2016; Jang et al., 2017) 作为输入。相比之下, 我们的世界模型接收原始 RGB 像素图像流, 直接学习时空表征。据我们所知, 我们的方法是首个报告解决该任务的方案。

3.4. 赛车梦境

由于我们的世界模型能够对未来建模, 我们还可以让它自行生成假设的赛车场景。我们可以让它根据当前状态生成 z_{t+1} 的概率分布, 从该分布中采样一个 z_{t+1} , 并将该采样作为真实观测。我们可以将训练好的 C 放回 M 生成的这种幻觉环境中。以下来自本文在线版本中交互式演示的图片展示了如何利用我们的世界模型来幻觉赛车环境:

4. VizDoom 实验

4.1. 在梦境中学习

我们刚看到, 在真实环境中学到的策略似乎也能在梦境环境中部分运行。这引出一个问题——我们能否训练智能体在它自己的梦境中学习, 并将该策略迁移回真实环境?

如果我们的世界模型对于其目标而言足够准确, 并且对当前问题足够完整, 我们应该能够用这个世界模型替代真实环境。毕竟, 我们的智能体并不直接观察现实, 只看到世




Figure 13. 我们的智能体在其自身的梦境世界中驾驶。在此，我们将训练好的策略部署到由 MDN-RNN 生成的虚拟环境中，并使用 VAE 的解码器进行渲染。在该演示中，读者可以覆盖智能体的动作并调节 τ 来控制 M 所生成环境的不确定性。

界模型让它看到的内容。在本实验中，我们在由世界模型生成的幻觉中训练智能体，该世界模型被训练用于模拟 VizDoom (Kempka et al., 2016) 环境。



Figure 14. 我们最终的智能体解决 VizDoom: Take Cover。

智能体必须学习躲避房间另一侧怪物射出的火球，这些怪物的唯一目的就是杀死智能体。该环境中没有显式奖励，因此为了模拟自然选择，累积奖励可定义为智能体在一次 rollout 期间存活的步数。每次环境 rollout 最多运行 2100 个时间步（约 60 秒），若在 100 次连续 rollout 中的平均存活时间超过 750 个时间步（约 20 秒），则任务被视为已解决 (Paquette, 2016)。

4.2. 流程

VizDoom 实验的设置与赛车任务基本一致，但有以下几项关键区别。在赛车任务中，M 仅被训练来建模下一个 z_t 。由于我们希望构建一个可以在其中训练智能体的世界模型，此处的 M 模型还将预测智能体是否在下一帧死亡（作为一个二值事件 $done_t$ ，简写为 d_t ），除了预测下一帧 z_t 之外。

由于 M 模型除了预测下一个观测外还能预测 $done$ 状态，我们现在拥有了构建完整 RL 环境所需的所有要素。我们首先通过将 `gym.Env` 接口包装在我们的 M 之上——就好像它是一个真实的 Gym 环境——来构建一个 OpenAI Gym 环境接口，然后在这个虚拟环境中而非真实环境中训练我们的智能体。

在此模拟过程中，在幻觉过程中我们不需要 V 模型来编码任何真实像素帧，因此我们的智能体将完全在潜在空间中训练。正如我们将看到的，这具有许多优势。

该虚拟环境与真实环境具有相同的接口，因此在智能体在虚拟环境中学习到满意的策略后，我们可以轻松地将此策略部署回真实环境，以查看策略迁移的效果。

总结 *Take Cover* 实验，以下为执行步骤：

1. 从随机策略收集 10,000 次 rollout。
2. 训练 VAE (V) 将每一帧编码为潜在向量 $z \in \mathcal{R}^{64}$ ，并使用 V 将 (1) 中收集的图像转换为潜在空间表征。
3. 训练 MDN-RNN (M) 对 $P(z_{t+1}, d_{t+1} | a_t, z_t, h_t)$ 建模。
4. 定义控制器 (C) 为 $a_t = W_c [z_t h_t]$ 。
5. 使用 CMA-ES 求解最大化虚拟环境内预期存活时间的 W_c 。
6. 将 (5) 中学到的策略在真实环境中使用。

模型	参数数量
VAE	4,446,915
MDN-RNN	1,678,785
控制器	1,088

4.3. 在梦境中训练

经过一些训练后，我们的控制器学会了在梦境环境中导航并躲避 M 生成怪物射出的致命火球。我们的智能体在虚拟环境中达到了约 900 个时间步的分数。

在此，我们基于 RNN 的世界模型被训练来模拟由人类程序员设计的完整游戏环境。仅通过从随机 episode 中收集的原始图像数据进行学习，它学会了如何模拟游戏的关键方面——例如游戏逻辑、敌人行为、物理以及 3D 图形渲染。




Figure 15. 我们的智能体发现了一种躲避幻觉火球的策略。在本文在线版本中，读者可以与此演示中的环境进行交互。

例如，如果智能体选择向左移动，M 模型学会将智能体向左移动并相应地调整其游戏状态的内部表征。它还学会阻止智能体在任一方向上移动得过远而超出关卡两侧的墙壁。偶尔，M 模型需要跟踪多个怪物射出的多个火球，并连贯地将它们沿预期方向移动。它还必须检测智能体是否被其中一个火球杀死。

然而，与真实游戏环境不同，我们注意到可以向虚拟环境中加入额外的不确定性，从而使梦境环境中的游戏更具挑战性。我们可以通过在 z_{t+1} 的采样过程中增加温度参数 τ 来实现这一点。通过增加不确定性，我们的梦境环境相比真实环境变得更加困难。火球可能以更不可预测的路径更加随机地移动，相比真实游戏。有时智能体甚至可能因为纯粹的厄运而毫无解释地死亡。

我们发现，在较高温度设置下表现良好的智能体通常在正常设置下表现更佳。实际上，增加 τ 有助于防止我们的控制器利用世界模型的不完美之处——我们稍后将对此进行更深入的讨论。

4.4. 将策略迁移到真实环境

我们将在虚拟环境中训练的智能体取出，并在原始 VizDoom 场景中测试其性能。在 100 次随机连续试验中的得分约为 1100 个时间步，远超 750 个时间步的要求，也远高于在更困难的虚拟环境中获得的分数。

我们看到，即使 V 模型无法正确捕获每一帧的所有细节——例如，无法正确显示怪物数量——智能体仍然能够使用学到的策略在真实环境中导航。由于虚拟环境本身甚至无法跟踪怪物的确切数量，一个能够在嘈杂且不确定的虚拟噩梦环境中存活智能体，将在原始、更清晰的环境中蓬勃发展。




Figure 16. 将我们在梦境 RNN 环境中学到的策略部署回真实的 VizDoom 环境中。




Figure 17. 在线文章中 Doom 的交互式 VAE。

4.5. 欺骗世界模型

在我们的童年时期，我们可能遇到过以原始游戏设计者预期之外的方式利用电子游戏 (Wikipedia, 2017) 的方法。玩家发现了收集无限生命或生命值的方式，通过利用这些漏洞，他们可以轻松通关一个原本困难的游戏。然而，在这样做时，他们可能丧失了学习按游戏设计者预期方式掌握游戏所需技能的机会。

例如，在我们的初步实验中，我们注意到我们的智能体发现了一种对抗性策略，即在某些 rollout 中以某种方式移动，使得这个由 M 模型支配的虚拟环境中的怪物从不发射一颗火球。即使有火球形成的迹象，智能体也会以某种方式移动，神奇地熄灭火球，仿佛它在环境中拥有超能力。

因为我们的世界模型仅是环境的近似概率模型，它偶尔会生成不遵循真实环境支配规律的轨迹。正如我们之前看到的，真实环境中房间另一侧的怪物数量甚至也无法被世界模型精确再现。就像一个学会空中物体通常会落地的孩子，这个孩子也可能会想象不现实的超级英雄飞越天空。出于这个原因，我们的世界模型将被控制器利用，即使在真实环境中不存在这样的漏洞。

而且，由于我们使用 M 模型为智能体生成虚拟梦境环境，我们也让控制器能够访问 M 的所有隐藏状态。这本质上授予了智能体对游戏引擎所有内部状态和记忆的访问权，而不仅仅是玩家能看到的观测。因此，我们的智能体可以有效探索直接操控游戏引擎隐藏状态的方法，以追求最大化其预期累积奖励。这种在学习到的动力学模型内部学习策略的方法的弱点是，我们的智能体可以轻易找到能

够欺骗我们动力学模型的对抗性策略——它会找到一个在我们的动力学模型下看起来很好，但在真实环境中会失败的策略，通常是因为它访问了模型错误的状态，这些状态远离了训练分布。




Figure 18. 智能体发现了一种对抗性策略，在某些 rollout 中自动在火球发射后将其熄灭。

这一弱点可能是许多先前工作学习了 RL 环境的动力学模型却没有实际使用这些模型完全替代真实环境的原因 (Oh et al., 2015; Chiappa et al., 2017)。如同 (Schmidhuber, 1990a;b; 1991a) 中提出的 M 模型一样，如果动力学模型是确定性模型，那么在它不够完美时，就容易被智能体利用。使用贝叶斯模型，如 PILCO (Deisenroth & Rasmussen, 2011) 中那样，通过不确定性估计在一定程度上帮助解决了这一问题，然而它们并不能完全解决该问题。近期工作 (Nagabandi et al., 2017) 将基于模型的方法与传统无模型 RL 训练相结合，首先使用学习到的策略初始化策略网络，但随后必须依赖无模型方法在真实环境中对该策略进行微调。

在 *Learning to Think* (Schmidhuber, 2015a) 中，RNN M 不总是可靠的预测器是可以接受的。一个（可能基于进化的）RNN C 原则上可以学会忽略有缺陷的 M，或者利用 M 的某些有用部分用于任意计算目的，包括层次化规划等。然而，我们这里所做的并非如此——我们当前的方法仍然更接近一些早期的系统 (Schmidhuber, 1990a;b; 1991a)，其中 RNN M 被用于逐步预测和提前规划。但与这些早期工作不同，我们对 C 使用进化方法（如同 *Learning to Think* 中那样），而非将传统 RL 与 RNN 结合，这兼具简单性和普适性的优势。

为使 C 模型更难利用 M 模型的缺陷，我们选择使用 MDN-RNN 作为动力学模型，它对真实环境中可能结果的分布进行建模，而非仅仅预测确定性的未来。即使真实环境是

确定性的，MDN-RNN 实际上也会将其近似为一个随机环境。这使我们能够在任何环境的更随机版本中训练 C 模型——我们可以简单地调节温度参数 τ 来控制 M 模型中的随机性量，从而控制真实性与可利用性之间的权衡。

考虑到 VAE 模型编码的潜在空间仅为单对角高斯分布，使用混合高斯模型似乎有些过度。然而，混合密度模型中的离散模态对于具有随机离散事件的环境非常有用，例如怪物决定是发射火球还是静止不动。虽然单个对角高斯可能足以编码单个帧，但具有混合密度输出层的 RNN 更容易对具有离散随机状态的更复杂环境背后的逻辑进行建模。

例如，如果我们将温度参数设置为非常低的值 $\tau = 0.1$ ，实际上使用几乎等同于确定性 LSTM 的 M 模型来训练 C 模型，那么该梦境环境中的怪物无论智能体做什么都无法发射火球，这是由于模式坍塌。M 模型无法跳跃到混合高斯模型中形成和发射火球的另一个模态。在此梦境中学习到的任何策略大多数时候都会获得 2100 的满分，但当被释放到真实世界的严酷现实中时显然会失败，甚至不如随机策略的表现。

然而，需要再次指出的是，*Learning to Think* 中更简单且更鲁棒的方法并不坚持使用 M 进行逐步规划。相反，C 可以学会使用 M 的子程序（M 权重矩阵的部分）用于任意计算目的，但也可以学会在 M 无用且忽略 M 能产生更好性能时忽略 M。尽管如此，至少在我们当前的 C-M 变体中，M 的预测对于训练 C 至关重要，这更像一些早期的 C-M 系统 (Schmidhuber, 1990a;b; 1991a)，但与进化或黑箱优化相结合。

通过将温度 τ 设为 M 模型的一个可调参数，我们可以观察在不同不确定性水平的幻觉虚拟环境上训练 C 模型的效果，并查看它们迁移到真实环境的表现如何。我们实验了改变虚拟环境的温度，并观察在给定温度下的虚拟环境中训练智能体后，在真实环境中 100 次随机 rollout 所获得的平均得分：

温度 τ	虚拟得分	真实得分
0.10	2086 $\pm$ 140	193 $\pm$ 58
0.50	2060 $\pm$ 277	196 $\pm$ 50
1.00	1145 $\pm$ 690	868 $\pm$ 511
1.15	918 $\pm$ 546	1092 $\pm$ 556
1.30	732 $\pm$ 269	753 $\pm$ 139
随机策略	N/A	210 $\pm$ 108
Gym 排行榜第一	N/A	820 $\pm$ 58

Table 2. 不同温度设置下的 *Take Cover* 得分。

我们看到，虽然增加 M 模型的温度使得 C 模型更难找到对抗性策略，但增加过多会使虚拟环境对于智能体学习任何内容来说过于困难，因此实际上它是一个我们可以调节的超参数。温度还影响智能体发现的策略类型。例如，尽管在 $\tau = 1.15$ 下获得的最佳得分为 1092 $\pm$ 556，但将 τ 略微增加到 1.30 会导致得分较低，但与此同时是一种方差更低的较低风险策略。作为比较，OpenAI Gym 排行榜上的最佳得分 (Paquette, 2016) 为 820 $\pm$ 58。

5. 迭代训练流程

在我们的实验中，任务相对简单，因此使用从随机策略收集的数据集就可以训练出一个合理的世界模型。但是，如果环境变得更复杂呢？在任何困难的环境中，世界的某些部分只有在智能体学会如何策略性地在其世界中导航之后才能被访问到。

对于更复杂的任务，需要迭代训练流程。我们需要智能体能够探索其世界，并不断收集新的观测，以便其世界模型能够随时间推移得到改进和完善。迭代训练流程 (Schmidhuber, 2015a) 如下：

1. 用随机模型参数初始化 M 和 C 。
2. 在真实环境中 rollout N 次。保存 rollout 期间所有动作 a_t 和观测 x_t 到存储中。
3. 训练 M 对 $P(x_{t+1}, r_{t+1}, a_{t+1}, d_{t+1} | x_t, a_t, h_t)$ 建模，并训练 C 在 M 内部优化预期奖励。
4. 如果任务尚未完成，回到步骤 (2)。

我们已经证明，一次迭代的训练循环就足以解决简单任务。对于更困难的任务，我们需要步骤 2 中的控制器主动探索环境中有益于改进其世界模型的部分。一个令人兴奋的研究方向是探索将人工好奇心和内在动机 (Schmidhuber, 2010; 2006; 1991b; Pathak et al., 2017; Oudeyer et al., 2007) 以及信息探索 (Schmidhuber et al., 1994; Gottlieb et al., 2013) 能力融入智能体中，以鼓励新颖探索 (Lehman & Stanley, 2011)。特别地，我们可以基于压缩质量的改进来增强奖励函数 (Schmidhuber, 2010; 2006; 1991b; 2015a)。

在当前方法中，由于 M 是一个 MDN-RNN，它对下一帧的概率分布进行建模，如果它表现不佳，则意味着智能体遇到了它不熟悉的世界部分。因此，我们可以调整并重用 M 的训练损失函数来鼓励好奇心。通过在真实环境中翻转 M 损失函数的符号，智能体将被鼓励去探索它不熟悉的世界部分。它收集的新数据将可能改进世界模型。

迭代训练流程要求 M 模型不仅要预测下一观测 x 和 $done$ ，还要预测下一时间步的动作和奖励。这对于更困难的任务可能是必需的。例如，如果我们的智能体需要学习复杂的运动技能以在其环境中行走，世界模型将学会模仿它自己的 C 模型，该 C 模型已学会行走。在诸如行走等困难运动技能被吸收进具有大量容量的大型世界模型之后，较小的 C 模型可以依赖世界模型已经吸收的运动技能，并专注于学习更高层次的技能，利用它已经学会的运动技能进行导航。

与神经科学文献的一个有趣联系是关于海马体回放的研究，该研究考察了大脑如何在动物休息或睡眠时回放最近的经历。回放最近经历在记忆巩固中起着重要作用 (Foster, 2017)——在海马体回放过程中，依赖海马体的记忆在一段时间后变为独立于海马体。正如 (Foster, 2017) 所述，回放与其说像做梦，不如说更像思考。我们邀请读者阅读




Figure 19. 信息如何成为记忆。

Replay Comes of Age (Foster, 2017)，以获取从神经科学视角对回放的详细概述及其与理论强化学习的联系。

迭代训练可以使 $C-M$ 模型发展出一种自然的分层学习方式。近期关于 RL 中自我博弈的工作 (Sukhbaatar et al., 2017; Bansal et al., 2017; Al-Shedivat et al., 2017) 以及 PowerPlay (Schmidhuber, 2013; Srivastava et al., 2012) 也探索了导致自然课程学习 (Schmidhuber, 2002) 的方法，我们认为这是强化学习中最令人兴奋的研究领域之一。

6. 相关工作

有大量关于学习动力学模型并使用该模型训练策略的文献。1980 年代首次为前馈神经网络 (FNN) 探索的许多概念 (Werbos, 1987; Munro, 1987; Robinson & Fallside, 1989; Werbos, 1989; Nguyen & Widrow, 1989) 以及 1990 年代为 RNN 探索的概念 (Schmidhuber, 1990a;b; 1991a; 1990c) 为 *Learning to Think* (Schmidhuber, 2015a) 奠定了一些基础。更近期的 PILCO (Deisenroth & Rasmussen, 2011; Duvenaud, 2016; McAllister & Rasmussen, 2016) 是一种基于概率模型的搜索策略方法，旨在解决困难的控制问题。PILCO 使用从环境中收集的数据，利用高斯过程 (GP) 模型学习系统动力学，然后使用该模型采样多条轨迹以训练控制器执行期望任务，例如摆起倒立摆或骑独轮车。




Figure 20. 具有内部 RNN 世界模型的控制 (Schmidhuber, 1990a)。

虽然高斯过程在小规模低维数据上效果良好，但其计算复杂性使其难以扩展到对大量高维观测历史进行建模。其

他近期工作 (Gal et al., 2016; Depeweg et al., 2016) 使用贝叶斯神经网络而非 GP 来学习动力学模型。这些方法在具有挑战性的控制任务上展示了有希望的结果 (Hein et al., 2017), 其中状态已知且定义明确, 观测相对低维。在这里, 我们感兴趣的是从高维视觉数据中建模动力学, 其中输入是原始像素帧序列。

在机器人控制应用中, 仅从基于摄像头的视频输入中学习系统动力学的能力是一个具有挑战性但重要的问题。关于主动视觉 RL 的早期工作训练了一个 FNN 来接收视频序列的当前图像帧以预测下一帧 (Schmidhuber & Huber, 1991), 并使用此预测模型训练一个控制网络来移动中央凹以在视觉场景中寻找目标。为克服直接训练动力学模型从高维像素图像学习的困难, 研究者们探索了使用神经网络首先学习视频帧压缩表征的方法。沿此方向的近期工作 (Wahlström et al., 2014; 2015) 能够使用自编码器的瓶颈隐藏层作为低维特征向量来训练控制器, 以从像素输入控制倒立摆。从压缩潜在空间中学习动力学模型使 RL 算法能够更加数据高效 (Finn et al., 2015; Watter et al., 2015; Finn, 2017)。我们邀请读者观看 Finn 关于基于模型的 RL 的讲座 (Finn, 2017) 以了解更多。

视频游戏环境在基于模型的 RL 研究中也很受欢迎, 作为新思想的测试平台。(Matthew Guzdial, 2017) 使用前馈卷积神经网络 (CNN) 学习视频游戏的前向模拟模型。学习预测不同动作如何影响环境中的未来状态对于游戏智能体非常有用, 因为如果我们的智能体能够预测给定当前状态和动作的未来情况, 它就可以简单地选择最适合其目标的最佳动作。这不仅在早期工作中得到了证明 (Nguyen & Widrow, 1989; Schmidhuber & Huber, 1991) (当时计算成本比今天高出一百万倍), 也在近期针对多个竞争性 VizDoom 环境的研究中得到了证明 (Dosovitskiy & Koltun, 2016)。

上述工作使用 FNN 来预测下一个视频帧。我们可能希望使用能够捕获更长时域依赖关系的模型。RNN 是适合序列建模的强大模型 (Graves, 2013)。在一个名为 *Hallucination with RNNs* (Graves, 2015) 的讲座中, Graves 展示了 RNN 学习 Atari 游戏环境概率模型的能力。他训练 RNN 学习此类游戏的结构, 然后展示它们能够自行幻觉出类似的游戏关卡。

使用 RNN 开发内部模型以对未来进行推理, 早在 1990 年的一篇名为 *Making the World Differentiable* (Schmidhuber, 1990a) 的论文中就已进行了探索, 随后在 (Schmidhuber, 1990b; 1991a; 1990c) 中得到了进一步探索。一篇更近期的论文 *Learning to Think* (Schmidhuber, 2015a) 提出了一个统一框架, 用于构建基于 RNN 的通用问题求解器, 该求解器能够学习其环境的世界模型, 并学习使用该模型对未来进行推理。后续工作已使用基于 RNN 的模型生成多帧未来图像 (Chappa et al., 2017; Oh et al., 2015; Denton & Birodkar, 2017), 并将其作为对未来推理的内部模型 (Silver et al., 2016; Weber et al., 2017; Watters et al., 2017)。

在本工作中, 我们使用进化策略来训练控制器, 因为它

提供了许多好处。例如, 我们只需要向优化器提供最终累积奖励, 而非完整历史。ES 也易于并行化——我们可以启动多个不同解决方案的 rollout 实例到多个工作器, 并快速并行计算一组累积奖励。近期工作 (Fernando et al., 2017; Salimans et al., 2017; Ha, 2017b; Stanley & Clune, 2017) 已证实 ES 是传统深度 RL 方法在多个强基线上的可行替代方案。

在深度 RL 方法流行之前 (Mnih et al., 2013), 基于进化的算法已被证明在解决 RL 任务方面是有效的 (Stanley & Miikkulainen, 2002; Gomez et al., 2008; Gomez & Schmidhuber, 2005; Gauci & Stanley, 2010; Sehnke et al., 2010; Miikkulainen, 2013)。基于进化的算法甚至能够解决来自高维像素输入的困难 RL 任务 (Koutnik et al., 2013; Hausknecht et al., 2013; Parker & Bryant, 2012)。更近期的作品 (Alvernaz & Togelius, 2017) 将 VAE 和 ES 结合, 这与我们的方法类似。

7. 讨论




Figure 21. 1990 年绘制的基于 RNN 的控制器与环境的交互图 (Schmidhuber, 1990a)。

我们展示了在模拟潜在空间梦境世界中完全训练智能体以执行任务的可能性。这种方法提供了许多实际好处。例如, 运行计算密集型的游戏引擎需要使用大量计算资源来将游戏状态渲染为图像帧, 或计算与游戏不直接相关的物理过程。我们可能不希望浪费周期在真实环境中训练智能体, 而是可以按需在模拟环境中多次训练智能体。在真实世界中训练智能体的成本甚至更高, 因此渐进式训练以模拟现实的世界模型可能对于将策略迁移回真实世界非常有用。我们的方法可以补充 (Bousmalis et al., 2017; Higgins et al., 2017) 中所概述的 *sim2real* 方法。

此外, 我们可以利用深度学习框架在分布式环境中使用 GPU 加速世界模型模拟。将世界模型实现为完全可微的

循环计算图的好处还在于，我们可能能够直接使用反向传播算法在梦境中训练智能体，以微调其策略来最大化目标函数 (Schmidhuber, 1990a;b; 1991a)。

选择使用 VAE 作为 V 模型并将其作为独立模型进行训练也存在其局限性，因为它可能编码了与任务无关的观测部分。毕竟，无监督学习从定义上无法知道什么对当前任务有用。例如，它在 Doom 环境中再现了不重要、详细的侧墙砖块纹理图案，但未能在赛车环境中再现与任务相关的路面图块。通过与预测奖励的 M 模型一起训练，VAE 可能学会聚焦于图像中任务相关的区域，但这里的权衡是我们可能无法在不对新任务重新训练的情况下有效地重用该 VAE。

学习任务相关特征也与神经科学有关联。当获得奖励时，初级感觉神经元从抑制中释放，这表明它们通常学习任务相关的特征，而不仅仅是任何特征，至少在成年期是如此 (Pi et al., 2013)。

另一个关注点是我们世界模型的有限容量。虽然现代存储设备可以存储使用迭代训练流程生成的大量历史数据，但我们基于 LSTM (Hochreiter & Schmidhuber, 1997; Gers et al., 2000) 的世界模型可能无法在其权重连接中存储所有记录的信息。虽然人脑可以以某种分辨率持有数十年甚至数世纪的记忆 (Bartol et al., 2015)，但我们使用反向传播训练的神经网络容量更有限，并且遭受诸如灾难性遗忘 (Ratcliff, 1990; French, 1994; Kirkpatrick et al., 2016) 等问题的影响。未来的工作可以探索将小型 MDN-RNN 网络替换为更高容量的模型 (Shazeer et al., 2017; Ha et al., 2016; Suarez, 2017; van den Oord et al., 2016; Vaswani et al., 2017)，或者纳入外部记忆模块 (Gemici et al., 2017)，如果我们希望智能体学习探索更复杂的世界。

与早期基于 RNN 的 C-M 系统类似 (Schmidhuber, 1990a;b; 1991a; 1990c)，我们的系统逐时间步模拟可能的未来，而没有利用类人的层次化规划或抽象推理，后者通常忽略不相关的时空细节。然而，更通用的 *Learning To Think* (Schmidhuber, 2015a) 方法并不局限于这种较为简单的方法。相反，它允许一个循环的 C 学会寻址循环 M 的子程序，并以任意可计算的方式重用它们进行问题解决，例如通过层次化规划或其他利用 M 程序式权重矩阵部分的方式。近期的 *One Big Net* (Schmidhuber, 2018) 扩展了 C-M 方法，将 C 和 M 合并为单个网络，并使用类似 PowerPlay (Schmidhuber, 2013; Srivastava et al., 2012) 的行为回放（其中教师网络的行为被压缩进学生网络 (Schmidhuber, 1992)），以避免在学习新技能时遗忘旧的预测和控制技能。对那些更通用方法的实验留待未来工作。

致谢

我们感谢 Blake Richards、Kai Arulkumaran、Ankur Handa、Kory Mathewson、Kyle McDonald、Denny Britz、Elwin Ha 和 Natasha Jaques 对本文提供的深思熟虑的反馈，以及从各自专业领域提供的宝贵视角和见解。

本文的交互式在线版本使用 distill.pub 的网页技术构建。我们感谢 Chris Olah 和 Distill 编辑团队其他成员的宝贵反馈和慷慨编辑支持，以及支持使用其 Distill 技术。

worldmodels.github.io 上的交互式演示均由 `p5.js` 构建。在网页浏览器中部署所有这些机器学习模型得益于 `deeplearn.js`——由 Google People+AI Research Initiative (PAIR) 团队开发的浏览器端硬件加速机器学习框架。特别感谢 Nikhil Thorat 和 Daniel Smilkov 在开发过程中提供的帮助。

我们向 Alex Graves、Douglas Eck、Mike Schuster、Rajat Monga、Vincent Vanhoucke、Jeff Dean 和 Google Brain 团队表示感谢，感谢他们的有益反馈以及鼓励我们探索这一研究领域。实验在 Google Cloud Platform 提供的 Ubuntu 虚拟机上执行。本文中的任何错误均为我们自己之过，不代表审稿人和同事的观点。

A. 附录

在本节中，我们将更详细地描述本工作中使用的模型和训练方法。

A.1. 变分自编码器




Figure 22. ConvVAE 每一层的张量形状描述。

我们训练了一个卷积变分自编码器 (ConvVAE) 模型作为智能体的 V 模型。与普通自编码器不同，对潜在向量 z 施加高斯先验也限制了压缩每一帧的信息容量，但这一高斯先验也使得世界模型对 M 模型生成的不现实 z 向量更具鲁棒性。

由于环境可能为我们提供高维像素图像作为观测，我们首先将每个图像调整为 64x64 像素，并将此调整后的图像用作 V 模型的观测。每个像素以三个 0 到 1 之间的浮点数值存储，代表每个 RGB 通道。ConvVAE 接受这个 64x64x3 的输入张量，并通过 4 个卷积层将其编码为低维向量 μ 和 σ ，每个大小为 N_z 。潜在向量 z 从高斯先验

$N(\mu, \sigma I)$ 中采样得到。在赛车任务中, N_z 为 32, 而在 Doom 任务中 N_z 为 64。潜在向量 z 通过 4 个反卷积层用于解码和重建图像。

每个卷积和反卷积层使用步长 2。各层在图中以斜体标示为激活类型 输出通道数 x 滤波器大小。除输出层外, 所有卷积和反卷积层均使用 relu 激活函数, 因为我们需要的输出在 0 到 1 之间。我们在从随机策略收集的数据上训练模型 1 个 epoch, 使用输入图像与重建之间的 L^2 距离来量化我们优化的重建损失, 此外还有 KL 损失。

A.2. 循环神经网络

对于 M 模型, 我们使用 LSTM (Hochreiter & Schmidhuber, 1997) 循环神经网络结合混合密度网络 (Bishop, 1994) 作为输出层。我们使用该网络将下一个时间步中下一个 z 的概率分布建模为混合高斯分布。这种方法与 (Graves, 2013) 中无条件手写生成部分以及 SketchRNN (Ha & Eck, 2017) 中仅解码器部分非常相似。所用方法的唯一区别在于我们没有对 z 各元素之间的相关参数建模, 而是让 MDN-RNN 输出一个分解高斯分布的对角协方差矩阵。




Figure 23. 与 (Graves, 2013; Ha & Eck, 2017) 类似的 MDN-RNN 解码器

与手写和素描生成工作不同, 我们不是使用 MDN-RNN 来建模下一个笔触的概率密度函数, 而是建模下一个潜在向量 z 的概率密度函数。我们会在每个时间步从该概率密度函数中采样以生成幻觉环境。在 Doom 任务中, 我们还使用 MDN-RNN 来预测智能体在该帧死亡的概率。如果该概率超过 50%, 则我们在虚拟环境中将 *done* 设为 *true*。鉴于在每个时间步死亡是低概率事件, 我们发现基于截断的方法比从伯努利分布采样更加稳定。

MDN-RNN 在从随机策略智能体收集的数据上训练了 20 个 epoch。在赛车任务中, LSTM 使用 256 个隐藏单元, 而在 Doom 任务中使用了 512 个隐藏单元。在两个任务中, 我们使用了 5 个高斯混合分量, 并且未对相关 ρ 参数建模, 因此 z 从一个分解的混合高斯分布中采样。

在使用教师强制从记录数据训练 MDN-RNN 时, 我们存储一组预计算的 μ 和 σ 用于每一帧, 并在每次构建训练批次时从 $z \sim N(\mu, \sigma)$ 中采样输入, 以防止 MDN-RNN

过拟合于某个特定采样的 z 。

A.3. 控制器

对于两个环境, 我们都应用了 $\tanh$ 非线性来将动作空间裁剪并限制在合适的范围。例如, 在赛车任务中, 方向盘的范围为 -1 到 1, 油门踏板为 0 到 1, 刹车为 0 到 1。在 Doom 环境中, 我们将离散动作转换为 -1 到 1 之间的连续动作空间, 并将该范围分为三份, 以指示智能体是向左移动、原地不动, 还是向右移动。我们为 C 模型提供一个特征向量作为输入, 该向量由 z 和 MDN-RNN 的隐藏状态组成。在赛车任务中, 该隐藏状态是 LSTM 的输出向量 h , 而在 Doom 任务中, 它是 LSTM 的细胞向量 c 和输出向量 h 。

A.4. 进化策略

我们使用协方差矩阵自适应进化策略 (CMA-ES) (Hansen, 2016) 来演化 C 模型的权重。按照 *Evolving Stable Strategies* (Ha, 2017b) 中描述的方法, 我们使用 64 的种群大小, 并让每个智能体以不同的初始随机种子执行任务 16 次。该智能体的适应度值为 16 次随机 rollout 的平均累积奖励。下图展示了每一代中 64 个智能体种群的最佳个体、最差个体和平均适应度:




Figure 24. CarRacing-v0 的训练过程

由于该环境的要求是智能体在 100 次随机 rollout 中获得高于 900 的平均得分, 我们每 25 代结束时取表现最好的智能体, 在 1024 个随机 rollout 场景中测试该智能体, 以红线记录此平均值。经过 1800 代后, 一个智能体能够在 1024 次随机 rollout 中达到 900.46 的平均得分。我们使用 1024 次随机 rollout 而非 100 次, 是因为 64 核机器的每个进程已被配置为运行 16 次, 实际上每 25 代后使用一整代的计算资源来评估最佳智能体 1024 次。下面, 我们绘制同一智能体在 100 次 rollout 中的评估结果:

我们还试验了一种智能体, 它只能访问来自 VAE 的 z 向量, 而无法访问 RNN 的隐藏状态。我们尝试了两种变体: 在第一种变体中, C 模型将 z 直接映射到动作空间 a 。在第二种变体中, 我们尝试在 z 和 a 之间添加一个具有 40 个 $\tanh$ 激活的隐藏层, 将 C 模型的参数数量增加到 1443, 使其与原始设置更具可比性。




Figure 25. 累积奖励的直方图。得分为 906 ± 21 。




Figure 26. 当智能体只能看到 z_t 时，得分为 632 ± 251 。

A.5. DoomRNN

我们在幻觉 Doom 环境上进行了类似实验，我们将此环境称为 *DoomRNN*。请注意，我们实际上并未尝试在真实 VizDoom 环境上训练智能体，而仅使用 VizDoom 来使用随机策略收集训练数据。*DoomRNN* 比 VizDoom 更具计算效率，因为它仅在潜在空间中运行，无需在每个时间步渲染截屏，也无需运行真实的 Doom 游戏引擎。

在我们构建的虚拟 DoomRNN 环境中，我们略微提高了温度并使用 $\tau = 1.15$ ，使智能体在更具挑战性的环境中学习。最佳智能体在 1024 次随机 rollout 中获得了 959 的平均得分（图中红线的最高得分）。当部署到真实的 *DoomTakeCover-v0* (Paquette, 2016) 环境中时，同一智能体在 100 次随机 rollout 中达到了 1092 ± 556 的平均得分。

References

- Al-Shedivat, M., Bansal, T., Burda, Y., Sutskever, I., Mordatch, I., and Abbeel, P. Continuous adaptation via meta-learning in nonstationary and competitive environments. *ArXiv preprint*, October 2017. URL <https://arxiv.org/abs/1710.03641>.
- Alvernaz, S. and Togelius, J. Autoencoder-augmented neuroevolution for visual doom playing. *ArXiv*




Figure 27. 当智能体只能看到 z_t 且带有一个隐藏层时，得分为 788 ± 141 。




Figure 28. DoomRNN 的训练过程。

preprint, July 2017. URL <https://arxiv.org/abs/1707.03902>.

Arulkumaran, K., Deisenroth, M. P., Brundage, M., and Bharath, A. A. Deep reinforcement learning: A brief survey. *IEEE Signal Processing Magazine*, 34(6):26–38, Nov 2017. ISSN 1053-5888. doi: 10.1109/MSP.2017.2743240. URL <https://arxiv.org/abs/1708.05866>.

Bansal, T., Pachocki, J., Sidor, S., Sutskever, I., and Mordatch, I. Emergent complexity via multi-agent competition. *ArXiv preprint*, October 2017. URL <https://arxiv.org/abs/1710.03748>.

Bartol, Thomas M, Jr, Bromer, Cailey, Kinney, Justin, Chirillo, Michael A, Bourne, Jennifer N, Harris, Kristen M, and Sejnowski, Terrence J. Nanoconnectomic upper bound on the variability of synaptic plasticity. *eLife Sciences Publications, Ltd*, 2015. doi: 10.7554/eLife.10778. URL <https://doi.org/10.7554/eLife.10778>.

Bishop, Christopher M. Mixture density networks. *Technical Report*, 1994. URL <http://publications.aston.ac.uk/373/>.




Figure 29. 在真实 VizDoom 环境中, 100 次连续试验存活时间步的直方图。得分为 1092 ± 556 。

- Bling, Seth. Mar i/o kart, 2015. URL https://youtu.be/S9Y_I9vY8Qw.
- Bousmalis, K., Irpan, A., Wohlhart, P., Bai, Y., Kelsey, M., Kalakrishnan, M., Downs, L., Ibarz, J., Pastor, P., Konolige, K., Levine, S., and Vanhoucke, V. Using simulation and domain adaptation to improve efficiency of deep robotic grasping. *ArXiv e-prints*, September 2017. URL <https://arxiv.org/abs/1709.07857>.
- Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J., and Zaremba, W. Openai gym. *ArXiv preprint*, June 2016. URL <https://arxiv.org/abs/1606.01540>.
- Cheang, L. and Tsao, D. The code for facial identity in the primate brain. *Cell*, 2017. doi: 10.1016/j.cell.2017.05.011. URL <http://www.cell.com/cell/fulltext/S0092-8674%2817%2930538-X>.
- Chiappa, S., Racaniere, S., Wierstra, D., and Mohamed, S. Recurrent environment simulators. *ArXiv preprint*, April 2017. URL <https://arxiv.org/abs/1704.02254>.
- Deisenroth, M. and Rasmussen, C. Pilco: A model-based and data-efficient approach to policy search. 2011. URL <http://mlg.eng.cam.ac.uk/pub/pdf/DeiRas11.pdf>.
- Denton, E. and Birodkar, V. Unsupervised learning of disentangled representations from video. *ArXiv preprint*, May 2017. URL <https://arxiv.org/abs/1705.10915>.
- Depeweg, S., Hernandez-Lobato, J., Doshi-Velez, F., and Udluft, S. Learning and policy search in stochastic dynamical systems with bayesian neural networks. *ArXiv preprint*, May 2016. URL <https://arxiv.org/abs/1605.07127>.

- Dosovitskiy, A. and Koltun, V. Learning to act by predicting the future. *ArXiv preprint*, November 2016. URL <https://arxiv.org/abs/1611.01779>.
- Duvenaud, David. Lecture slides on pilco. *CSC 2541 Course at University of Toronto*, 2016. URL <https://www.cs.toronto.edu/~duvenaud/courses/csc2541/slides/pilco.pdf>.
- E, M. More thoughts from understanding comics by scott mccloud, 2012. URL <https://goo.gl/5Tndi4>.
- Fernando, C., Banarse, D., Blundell, C., Zwols, Y., Ha, D., Rusu, A., Pritzel, A., and Wierstra, D. Pathnet: Evolution channels gradient descent in super neural networks. *ArXiv preprint*, January 2017. URL <https://arxiv.org/abs/1701.08734>.
- Finn, C., Tan, X., Duan, Y., Darrell, T., Levine, S., and Abbeel, P. Deep spatial autoencoders for visuomotor learning. *ArXiv preprint*, September 2015. URL <https://arxiv.org/abs/1509.06113>.
- Finn, Chelsea. Model-based rl lecture at deep rl bootcamp 2017, 2017. URL <https://youtu.be/iC2a7M9voYU?t=44m35s>.
- Forrester, Jay Wright. Counterintuitive behavior of social systems, 1971. URL https://en.wikipedia.org/wiki/Mental_model. [Online; accessed 01-Nov-2017].
- Foster, David J. Replay comes of age. *Annual Review of Neuroscience*, 40(1):581–602, 2017. doi: 10.1146/annurev-neuro-072116-031538. URL <https://doi.org/10.1146/annurev-neuro-072116-031538>.
- French, Robert M. Catastrophic interference in connectionist networks: Can it be predicted, can it be prevented? In Cowan, J. D., Tesauero, G., and Alspector, J. (eds.), *Advances in Neural Information Processing Systems 6*, pp. 1176–1177. Morgan-Kaufmann, 1994. URL <https://goo.gl/jwpLsk>.
- Gal, Y., McAllister, R., and Rasmussen, C. Improving pilco with bayesian neural network dynamics models. April 2016. URL <http://mlg.eng.cam.ac.uk/yarin/PDFs/DeepPILCO.pdf>.
- Gauci, Jason and Stanley, Kenneth O. Autonomous evolution of topographic regularities in artificial neural networks. *Neural Computation*, 22(7): 1860–1898, July 2010. ISSN 0899-7667. doi: 10.1162/neco.2010.06-09-1042. URL http://eplex.cs.ucf.edu/papers/gauci_nc10.pdf.

- Gemici, M., Hung, C., Santoro, A., Wayne, G., Mohamed, S., Rezende, D., Amos, D., and Lillicrap, T. Generative temporal models with memory. *ArXiv preprint*, February 2017. URL <https://arxiv.org/abs/1702.04649>.
- Gerrit, M., Fischer, J., and Whitney, D. Motion-dependent representation of space in area mt+. *Neuron*, 2013. doi: 10.1016/j.neuron.2013.03.010. URL <http://dx.doi.org/10.1016/j.neuron.2013.03.010>.
- Gers, F., Schmidhuber, J., and Cummins, F. Learning to forget: Continual prediction with lstm. *Neural Computation*, 12(10):2451–2471, October 2000. ISSN 0899-7667. doi: 10.1162/089976600300015015. URL <ftp://ftp.idsia.ch/pub/juergen/FgGates-NC.pdf>.
- Gomez, F. and Schmidhuber, J. Co-evolving recurrent neurons learn deep memory pomdps. *Proceedings of the 7th Annual Conference on Genetic and Evolutionary Computation*, pp. 491–498, 2005. doi: 10.1145/1068009.1068092. URL <ftp://ftp.idsia.ch/pub/juergen/gecco05gomez.pdf>.
- Gomez, F., Schmidhuber, J., and Miikkulainen, R. Accelerated neural evolution through cooperatively coevolved synapses. *Journal of Machine Learning Research*, 9:937–965, June 2008. ISSN 1532-4435. URL <http://people.idsia.ch/~juergen/gomez08a.pdf>.
- Gottlieb, J., Oudeyer, P., Lopes, M., and Baranes, A. Information-seeking, curiosity, and attention: computational and neural mechanisms. *Cell*, September 2013. doi: 10.1016/j.tics.2013.09.001. URL <http://www.pyoudeyer.com/TICSCuriosity2013.pdf>.
- Graves, Alex. Generating sequences with recurrent neural networks. *ArXiv preprint*, 2013. URL <https://arxiv.org/abs/1308.0850>.
- Graves, Alex. Hallucination with recurrent neural networks, 2015. URL <https://www.youtube.com/watch?v=-yX1SYeDHbg&t=49m33s>.
- Ha, D. Recurrent neural network tutorial for artists. *blog.otoro.net*, 2017a. URL <http://blog.otoro.net/2017/01/01/recurrent-neural-network-artist/>.
- Ha, D. Evolving stable strategies. *blog.otoro.net*, 2017b. URL <http://blog.otoro.net/2017/11/12/evolving-stable-strategies/>.
- Ha, D. and Eck, D. A neural representation of sketch drawings. *ArXiv preprint*, April 2017. URL <https://magenta.tensorflow.org/sketch-rnn-demo>.
- Ha, D., Dai, A., and Le, Q. Hypernetworks. *ArXiv preprint*, September 2016. URL <https://arxiv.org/abs/1609.09106>.
- Hansen, N. The cma evolution strategy: A tutorial. *ArXiv preprint*, 2016. URL <https://arxiv.org/abs/1604.00772>.
- Hansen, Nikolaus and Ostermeier, Andreas. Completely derandomized self-adaptation in evolution strategies. *Evolutionary Computation*, 9(2):159–195, June 2001. ISSN 1063-6560. doi: 10.1162/106365601750190398. URL <http://www.cmap.polytechnique.fr/~nikolaus.hansen/cmaartic.pdf>.
- Hausknecht, M., Lehman, J., Miikkulainen, R., and Stone, P. A neuroevolution approach to general atari game playing. *IEEE Transactions on Computational Intelligence and AI in Games*, 2013. URL <http://www.cs.utexas.edu/~ai-lab/?atari>.
- Hein, D., Depeweg, S., Tokic, M., Udluft, S., Hentschel, A., Runkler, T., and Sterzing, V. A benchmark environment motivated by industrial control problems. *ArXiv preprint*, September 2017. URL <https://arxiv.org/abs/1709.09480>.
- Higgins, I., Pal, A., Rusu, A., Matthey, L., Burgess, C., Pritzel, A., Botvinick, M., Blundell, C., and Lerchner, A. Darla: Improving zero-shot transfer in reinforcement learning. *ArXiv e-prints*, July 2017. URL <https://arxiv.org/abs/1707.08475>.
- Hirshon, B. Tracking fastballs, 2013. URL <http://sciencenetlinks.com/science-news/science-updates/tracking-fastballs/>.
- Hochreiter, Sepp and Schmidhuber, Juergen. Long short-term memory. *Neural Computation*, 1997. URL <ftp://ftp.idsia.ch/pub/juergen/lstm.pdf>.
- Hünemann, Jan. Self-driving cars in the browser, 2017. URL <http://janhuennemann.com/projects/learning-to-drive>.
- Jang, S., Min, J., and Lee, C. Reinforcement car racing with a3c. 2017. URL <https://www.scribd.com/document/358019044/Reinforcement-Car-Racing-with-A3C>.
- Kaelbling, L. P., Littman, M. L., and Moore, A. W. Reinforcement learning: a survey. *Journal of AI research*, 4:237–285, 1996.

- Keller, Georg B., Bonhoeffer, Tobias, and Hübener, Mark. Sensorimotor mismatch signals in primary visual cortex of the behaving mouse. *Neuron*, 74(5):809 – 815, 2012. ISSN 0896-6273. doi: <https://doi.org/10.1016/j.neuron.2012.03.040>. URL <http://www.sciencedirect.com/science/article/pii/S0896627312003844>.
- Kelley, H. J. Gradient theory of optimal flight paths. *ARS Journal*, 30(10):947–954, 1960.
- Kempka, Michael, Wydmuch, Marek, Runc, Grzegorz, Toczek, Jakub, and Jaskowski, Wojciech. Vizdoom: A doom-based ai research platform for visual reinforcement learning. In *IEEE Conference on Computational Intelligence and Games*, pp. 341–348, Santorini, Greece, Sep 2016. IEEE. URL <http://arxiv.org/abs/1605.02097>. The best paper award.
- Khan, M. and Elibol, O. Car racing using reinforcement learning. 2016. URL <https://web.stanford.edu/class/cs221/2017/restricted/p-final/elibol/final.pdf>.
- Kingma, D. and Welling, M. Auto-encoding variational bayes. *ArXiv preprint*, 2013. URL <https://arxiv.org/abs/1312.6114>.
- Kirkpatrick, J., Pascanu, R., Rabinowitz, N., Veness, J., Desjardins, G., Rusu, A. and Milan, K., Quan, J., Ramalho, T., Grabska-Barwinska, A., Hassabis, D., Clopath, C., Kumaran, D., and Hadsell, R. Overcoming catastrophic forgetting in neural networks. *ArXiv preprint*, December 2016. URL <https://arxiv.org/abs/1612.00796>.
- Kitaoka, Akiyoshi. Akiyoshi’s illusion pages, 2002. URL <http://www.ritsumei.ac.jp/~akitaoka/index-e.html>.
- Klimov, Oleg. Carracing-v0, 2016. URL <https://gym.openai.com/envs/CarRacing-v0/>.
- Koutnik, J., Cuccu, G., Schmidhuber, J., and Gomez, F. Evolving large-scale neural networks for vision-based reinforcement learning. *Proceedings of the 15th Annual Conference on Genetic and Evolutionary Computation*, pp. 1061–1068, 2013. doi: 10.1145/2463372.2463509. URL <http://people.idsia.ch/~juergen/compressednetworksearch.html>.
- Lau, Ben. Using keras and deep deterministic policy gradient to play torcs, 2016. URL <https://yanpanlau.github.io/2016/10/11/Torcs-Keras.html>.
- Lehman, Joel and Stanley, Kenneth. Abandoning objectives: Evolution through the search for novelty alone. *Evolutionary Computation*, 19(2):189–223, 2011. ISSN 1063-6560. URL <http://eplex.cs.ucf.edu/noveltysearch/userspage/>.
- Leinweber, Marcus, Ward, Daniel R., Sobczak, Jan M., Attinger, Alexander, and Keller, Georg B. A sensorimotor circuit in mouse cortex for visual flow predictions. *Neuron*, 95(6):1420 – 1432.e5, 2017. ISSN 0896-6273. doi: <https://doi.org/10.1016/j.neuron.2017.08.036>. URL <http://www.sciencedirect.com/science/article/pii/S0896627317307791>.
- Linnainmaa, S. The representation of the cumulative rounding error of an algorithm as a taylor expansion of the local rounding errors. Master’s thesis, Univ. Helsinki, 1970.
- Matthew Guzdial, Boyang Li, Mark O. Riedl. Game engine learning from video. In *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, IJCAI-17*, pp. 3707–3713, 2017. doi: 10.24963/ijcai.2017/518. URL <https://doi.org/10.24963/ijcai.2017/518>.
- McAllister, R. and Rasmussen, C. Data-efficient reinforcement learning in continuous-state pomdps. *ArXiv preprint*, February 2016. URL <https://arxiv.org/abs/1602.02523>.
- McCloud, Scott. *Understanding Comics: The Invisible Art*. Tundra Publishing, 1993. URL https://en.wikipedia.org/wiki/Understanding_Comics.
- Miikkulainen, R. Evolving neural networks. *IJCNN*, August 2013. URL <http://nn.cs.utexas.edu/downloads/slides/miikkulainen.ijcnn13.pdf>.
- Mnih, V., Kavukcuoglu, K., Silver, D., Graves, A., Antonoglou, I., Wierstra, D., and Riedmiller, M. Playing atari with deep reinforcement learning. *ArXiv preprint*, December 2013. URL <https://arxiv.org/abs/1312.5602>.
- Mobbs, Dean, Hagan, Cindy C., Dalgleish, Tim, Silston, Brian, and Prévost, Charlotte. The ecology of human fear: survival optimization and the nervous system., 2015. URL <https://www.frontiersin.org/article/10.3389/fnins.2015.00055>.
- Munro, P. W. A dual back-propagation scheme for scalar reinforcement learning. *Proceedings of the Ninth Annual Conference of the Cognitive Science Society, Seattle, WA*, pp. 165–176, 1987.

- Nagabandi, A., Kahn, G., Fearing, R., and Levine, S. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. *ArXiv preprint*, August 2017. URL <https://arxiv.org/abs/1708.02596>.
- Nguyen, N. and Widrow, B. The truck backer-upper: An example of self learning in neural networks. In *Proceedings of the International Joint Conference on Neural Networks*, pp. 357–363. IEEE Press, 1989.
- Nortmann, Nora, Rekauszke, Sascha, Onat, Selim, König, Peter, and Jancke, Dirk. Primary visual cortex represents the difference between past and present. *Cerebral Cortex*, 25(6):1427–1440, 2015. doi: 10.1093/cercor/bht318. URL <http://dx.doi.org/10.1093/cercor/bht318>.
- Oh, J., Guo, X., Lee, H., Lewis, R., and Singh, S. Action-conditional video prediction using deep networks in atari games. *ArXiv preprint*, July 2015. URL <https://arxiv.org/abs/1507.08750>.
- Oudeyer, P., Kaplan, F., and Hafner, V. Intrinsic motivation systems for autonomous mental development. *Trans. Evol. Comp.*, apr 2007. doi: 10.1109/TEVC.2006.890271. URL <http://www.pyoudeyer.com/ims.pdf>.
- Paquette, Philip. Doomtakecover-v0, 2016. URL <https://gym.openai.com/envs/DoomTakeCover-v0/>.
- Parker, M. and Bryant, B. Neuro-visual control in the quake ii environment. *IEEE Transactions on Computational Intelligence and AI in Games*, 2012. URL <https://www.cse.unr.edu/~bdbryant/papers/parker-2012-tciaig.pdf>.
- Pathak, D., Agrawal, P., A., Efros, and Darrell, T. Curiosity-driven exploration by self-supervised prediction. *ArXiv preprint*, May 2017. URL <https://pathak22.github.io/noreward-rl/>.
- Pi, H., Hangya, B., Kvitsiani, D., Sanders, J., Huang, Z., and Kepecs, A. Cortical interneurons that specialize in disinhibitory control. *Nature*, November 2013. doi: 10.1038/nature12676. URL <http://dx.doi.org/10.1038/nature12676>.
- Priour, Luc. Deep-q learning for box2d racecar rl problem., 2017. URL <https://goo.gl/VpDqSw>.
- Quiroga, R., Reddy, L., Kreiman, G., Koch, C., and Fried, I. Invariant visual representation by single neurons in the human brain. *Nature*, 2005. doi: 10.1038/nature03687. URL <http://www.nature.com/nature/journal/v435/n7045/abs/nature03687.html>.
- Ratcliff, Rodney Mark. Connectionist models of recognition memory: constraints imposed by learning and forgetting functions. *Psychological review*, 97 2: 285–308, 1990.
- Rechenberg, I. *Evolutionstrategie: optimierung technischer systeme nach prinzipien der biologischen evolution*. Frommann-Holzboog, 1973. URL https://en.wikipedia.org/wiki/Ingo_Rechenberg.
- Rezende, D., Mohamed, S., and Wierstra, D. Stochastic backpropagation and approximate inference in deep generative models. *ArXiv preprint*, 2014. URL <https://arxiv.org/abs/1401.4082>.
- Robinson, T. and Fallside, F. Dynamic reinforcement driven error propagation networks with application to game playing. In *CogSci 89*, 1989.
- Salimans, T., Ho, J., Chen, X., Sidor, S., and Sutskever, I. Evolution strategies as a scalable alternative to reinforcement learning. *ArXiv preprint*, 2017. URL <https://arxiv.org/abs/1703.03864>.
- Schmidhuber, J. Making the world differentiable: On using self-supervised fully recurrent neural networks for dynamic reinforcement learning and planning in non-stationary environments. 1990a. URL [http://people.idsia.ch/~juergen/FKI-126-90_\(revised\)bw_ocr.pdf](http://people.idsia.ch/~juergen/FKI-126-90_(revised)bw_ocr.pdf).
- Schmidhuber, J. An on-line algorithm for dynamic reinforcement learning and planning in reactive environments. 1990 *IJCNN International Joint Conference on Neural Networks*, pp. 253–258 vol.2, June 1990b. doi: 10.1109/IJCNN.1990.137723. URL <ftp://ftp.idsia.ch/pub/juergen/ijcnn90.ps.gz>.
- Schmidhuber, J. A possibility for implementing curiosity and boredom in model-building neural controllers. *Proceedings of the First International Conference on Simulation of Adaptive Behavior on From Animals to Animats*, pp. 222–227, 1990c. URL <ftp://ftp.idsia.ch/pub/juergen/curiositysab.pdf>.
- Schmidhuber, J. Reinforcement learning in markovian and non-markovian environments. *Advances in Neural Information Processing Systems 3*, pp. 500–506, 1991a. URL <https://goo.gl/ij1uYQ>.
- Schmidhuber, J. Curious model-building control systems. In *Proc. International Joint Conference on Neural Networks, Singapore*, pp. 1458–1463, 1991b.

- Schmidhuber, J. Learning complex, extended sequences using the principle of history compression. *Neural Computation*, 4(2):234–242, 1992. (Based on TR FKI-148-91, TUM, 1991).
- Schmidhuber, J. Optimal ordered problem solver. *ArXiv preprint*, July 2002. URL <https://arxiv.org/abs/cs/0207097>.
- Schmidhuber, J. Developmental robotics, optimal artificial curiosity, creativity, music, and the fine arts. *Connection Science*, 18(2):173–187, 2006.
- Schmidhuber, J. Formal theory of creativity, fun, and intrinsic motivation (1990-2010). *IEEE Trans. Autonomous Mental Development*, 2010. URL <http://people.idsia.ch/~juergen/creativity.html>.
- Schmidhuber, J. Powerplay: Training an increasingly general problem solver by continually searching for the simplest still unsolvable problem. *Frontiers in Psychology*, 4:313, 2013. ISSN 1664-1078. doi: 10.3389/fpsyg.2013.00313. URL <https://www.frontiersin.org/article/10.3389/fpsyg.2013.00313>.
- Schmidhuber, J. On learning to think: Algorithmic information theory for novel combinations of reinforcement learning controllers and recurrent neural world models. *ArXiv preprint*, 2015a. URL <https://arxiv.org/abs/1511.09249>.
- Schmidhuber, J. Deep learning in neural networks: An overview. *Neural Networks*, 61:85–117, 2015b. doi: 10.1016/j.neunet.2014.09.003. Published online 2014; based on TR arXiv:1404.7828 [cs.NE].
- Schmidhuber, J. One big net for everything. *Preprint arXiv:1802.08864 [cs.AI]*, February 2018. URL <https://arxiv.org/abs/1802.08864>.
- Schmidhuber, J. and Huber, R. Learning to generate artificial fovea trajectories for target detection. *International Journal of Neural Systems*, 2(1-2):125–134, 1991. doi: 10.1142/S012906579100011X. URL <ftp://ftp.idsia.ch/pub/juergen/attention.pdf>.
- Schmidhuber, J., Storck, J., and Hochreiter, S. Reinforcement driven information acquisition in non-deterministic environments. Technical Report FKI-94, TUM Department of Informatics, 1994.
- Schwefel, H. *Numerical Optimization of Computer Models*. John Wiley and Sons, Inc., New York, NY, USA, 1977. ISBN 0471099880. URL https://en.wikipedia.org/wiki/Hans-Paul_Schwefel.
- Sehnke, F., Osendorfer, C., Ruckstieb, T., Graves, A., Peters, J., and Schmidhuber, J. Parameter-exploring policy gradients. *Neural Networks*, 23(4):551–559, 2010. doi: 10.1016/j.neunet.2009.12.004. URL <http://citeseerx.ist.psu.edu/viewdoc/download;jsessionid=A64D1AE8313A364B814998E9E245B40A?doi=10.1.1.180.7104&rep=rep1&type=pdf>.
- Shazeer, N., Mirhoseini, A., Maziarz, K., Davis, A., Le, Q., Hinton, G., and Dean, J. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *ArXiv preprint*, January 2017. URL <https://arxiv.org/abs/1701.06538>.
- Silver, D., van Hasselt, H., Hessel, M., Schaul, T., Guez, A., Harley, T., Dulac-Arnold, G., Reichert, D., Rabinowitz, N., Barreto, A., and Degris, T. The predictron: End-to-end learning and planning. *ArXiv preprint*, December 2016. URL <https://arxiv.org/abs/1612.08810>.
- Silver, David. David silver’s lecture on integrating learning and planning, 2017. URL http://www0.cs.ucl.ac.uk/staff/d.silver/web/Teaching_files/dyna.pdf.
- Srivastava, R., Steunebrink, B., and Schmidhuber, J. First experiments with powerplay. *ArXiv preprint*, October 2012. URL <https://arxiv.org/abs/1210.8385>.
- Stanley, Kenneth and Clune, Jeff. Welcoming the era of deep neuroevolution, 2017. URL <https://eng.uber.com/deep-neuroevolution/>.
- Stanley, Kenneth O. and Miikkulainen, Risto. Evolving neural networks through augmenting topologies. *Evolutionary Computation*, 10(2):99–127, 2002. URL <http://nn.cs.utexas.edu/?stanley:ec02>.
- Suarez, Joseph. Language modeling with recurrent highway hypernetworks. In Guyon, I., Luxburg, U. V., Bengio, S., Wallach, H., Fergus, R., Vishwanathan, S., and Garnett, R. (eds.), *Advances in Neural Information Processing Systems 30*, pp. 3269–3278. Curran Associates, Inc., 2017. URL <https://goo.gl/4nqHXw>.
- Sukhbaatar, S., Lin, Z., Kostrikov, I., Synnaeve, G., Szlam, A., and Fergus, R. Intrinsic motivation and automatic curricula via asymmetric self-play. *ArXiv preprint*, October 2017. URL <https://arxiv.org/abs/1703.05407>.

- Sutton, Richard S. and Barto, Andrew G. *Introduction to Reinforcement Learning*. MIT Press, Cambridge, MA, USA, 1st edition, 1998. ISBN 0262193981. URL <http://ufal.mff.cuni.cz/~straka/courses/npfl114/2016/sutton-bookdraft2016sep.pdf>.
- van den Oord, A., Dieleman, S., Zen, H., Simonyan, K., Vinyals, O., Graves, A., Kalchbrenner, N., Senior, A., and Kavukcuoglu, K. Wavenet: A generative model for raw audio. *ArXiv preprint*, September 2016. URL <https://arxiv.org/abs/1609.03499>.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A., Kaiser, L., and Polosukhin, I. Attention is all you need. *ArXiv preprint*, June 2017. URL <https://arxiv.org/abs/1706.03762>.
- Wahlström, N., Schön, T., and Deisenroth, M. Learning deep dynamical models from image pixels. *ArXiv preprint*, October 2014. URL <https://arxiv.org/abs/1410.7550>.
- Wahlström, N., Schön, T., and Deisenroth, M. From pixels to torques: Policy learning with deep dynamical models. *ArXiv preprint*, June 2015. URL <https://arxiv.org/abs/1502.02251>.
- Watanabe, Eiji, Kitaoka, Akiyoshi, Sakamoto, Kiwako, Yasugi, Masaki, and Tanaka, Kenta. Illusory motion reproduced by deep neural networks trained for prediction. *Frontiers in Psychology*, 9: 345, 2018. ISSN 1664-1078. doi: 10.3389/fpsyg.2018.00345. URL <https://www.frontiersin.org/article/10.3389/fpsyg.2018.00345>.
- Watter, M., Springenberg, J., Boedecker, J., and Riedmiller, M. Embed to control: A locally linear latent dynamics model for control from raw images. *ArXiv preprint*, June 2015. URL <https://arxiv.org/abs/1506.07365>.
- Watters, N., Tacchetti, A., Weber, T., Pascanu, R., Battaglia, P., and Zoran, D. Visual interaction networks. *ArXiv preprint*, June 2017. URL <https://arxiv.org/abs/1706.01433>.
- Weber, T., Racanière, S., Reichert, D., Buesing, L., Guez, A., Rezende, D., Badia, A., Vinyals, O., Heess, N., Li, Y., Pascanu, R., Battaglia, P., Silver, D., and Wierstra, D. Imagination-augmented agents for deep reinforcement learning. *ArXiv preprint*, July 2017. URL <https://arxiv.org/abs/1707.06203>.
- Werbos, P. J. Learning how the world works: Specifications for predictive networks in robots and brains. In *Proceedings of IEEE International Conference on Systems, Man and Cybernetics*, N.Y., 1987.
- Werbos, P. J. Neural networks for control and system identification. In *Proceedings of IEEE/CDC Tampa, Florida*, 1989.
- Werbos, Paul J. Applications of advances in nonlinear sensitivity analysis. In *System modeling and optimization*, pp. 762–770. Springer, 1982.
- Wiering, Marco and van Otterlo, Martijn. *Reinforcement Learning*. Springer, 2012.
- Wikipedia, Authors. Video game exploits, 2017. URL https://en.wikipedia.org/wiki/Video_game_exploits. [Online; accessed 01-Nov-2017].