

从像素中学习潜在动力学用于规划

Danijar Hafner^{1,2} Timothy Lillicrap³ Ian Fischer⁴ Ruben Villegas^{1,5}
David Ha¹ Honglak Lee¹ James Davidson¹

Abstract

对于具有已知环境动力学的控制任务，规划方法已取得巨大成功。为了在未知环境中利用规划，智能体需要从与世界的交互中学习动力学。然而，学习足够精确以用于规划的动力学模型一直是一个长期挑战，尤其是在基于图像的领域中。我们提出 Deep Planning Network (PlaNet)，一种纯基于模型的智能体，它从图像中学习环境动力学，并通过在潜在空间中进行快速在线规划来选择动作。为实现高性能，动力学模型必须准确预测未来多个时间步的奖励。我们使用具有确定性和随机性两种转移成分的潜在动力学模型来解决这一问题。此外，我们提出了一种名为潜在越步的多步变分推断目标。仅使用像素观测，我们的智能体就解决了具有接触动力学、部分可观测性和稀疏奖励的连续控制任务，这些任务的难度超过了之前通过学习模型进行规划所解决的任务，最终性能接近甚至有时超过强大的无模型算法。

1. 引言

规划是一种自然而强大的决策方法，适用于具有已知动力学的决策问题，如游戏对弈和模拟机器人控制 (???)。为了在未知环境中进行规划，智能体需要从经验中学习动力学。学习足够精确以用于规划的动力学模型一直是一个长期挑战。主要困难包括模型不准确、多步预测的累积误差、无法捕捉多种可能的未来，以及在训练分布之外的过度自信预测。

相比无模型强化学习，使用学习模型进行规划具有若干优势。首先，基于模型的规划可以具有更高的数据效率，因为它利用了更丰富的训练信号，且不需要通过贝尔曼备份传播奖励。此外，规划有望通过仅增加搜索行动的计算预算来提高性能，正如?所示。最后，学习到的动力学可以独立于任何特定任务，因此有潜力很好地迁移到环境中的其他任务。

¹Google Brain ²University of Toronto ³DeepMind
⁴Google Research ⁵University of Michigan. Correspondence to: Danijar Hafner <mail@danijar.com>.

最近的工作在简单低维环境的动力学学习方面展现出前景 (????)。然而，这些方法通常假设能直接访问世界的底层状态和奖励函数，而这在实践中可能不可用。在高维环境中，我们希望在紧凑的潜在空间中学习动力学，以实现快速规划。此类潜在模型此前的成功仅限于简单任务，如基于密集奖励的摆杆平衡和双连杆臂控制 (??)。

在本文中，我们提出 Deep Planning Network (PlaNet)，一种基于模型的智能体，它从像素中学习环境动力学，并通过在紧凑潜在空间中进行在线规划来选择动作。为了学习动力学，我们使用具有随机性和确定性两种成分的转移模型。此外，我们尝试了一种新颖的广义变分目标，以鼓励多步预测。


本工作的主要贡献总结如下：

- 潜在空间中的规划 我们通过学习动力学模型并高效地在其潜在空间中进行规划，解决了 DeepMind 控制套件中的多种任务（如??所示）。我们的智能体在最终性能上大幅优于无模型算法 A3C，在某些情况下也优于 D4PG 算法，同时平均使用了少 200× 的环境交互量和相似的计算时间。
- 循环状态空间模型 我们设计了一种具有确定性和随机性两种成分的潜在动力学模型 (??)。我们的实验表明，同时拥有这两种成分对实现高规划性能至关重要。
- 潜在越步 我们将标准变分推广到包含多步预测。仅使用潜在空间中的项即可得到一个快速的、能够改进长期预测的正则化器，且该正则化器与任何潜在序列模型兼容。

2. 潜在空间规划

为了通过规划解决未知环境，我们需要从经验中建模环境动力学，并在收集到的数据上训练动力学模型来实现这一点。在本节中，我们引入环境的符号表示，并描述我们基于模型的智能体的总体实现。本节假设我们已经有一个学习好的动力学模型可用。该模型的设计和训练目标将在??中详细介绍。

问题设置 由于单个图像观测通常无法揭示环境的完整状态，我们考虑一个部分可观测马尔可夫决策过程 (POMDP)。我们定义离散时间步 t 、隐藏状态 s_t 、图像观测 o_t 、连续动作向量 a_t 和标量奖励 r_t ，它们遵循以



(a) Cartpole (b) Reacher (c) Cheetah (d) Finger (e) Cup (f) Walker

Figure 1: 实验中使用的基于图像的控制领域。图像显示的是降采样到 $64 \times 64 \times 3$ 像素之前的智能体观测。(a) cartpole 摆起任务使用固定相机，因此推车可能移出视野范围。(b) reacher 任务仅有稀疏奖励。(c) cheetah 奔跑任务包含接触和更多的关节。(d) finger 旋转任务包含手指与物体之间的接触。(e) cup 任务具有稀疏奖励，仅在球被接住时给出。(f) walker 任务需要平衡，并在机器人躺倒时预测与地面的困难交互。

Algorithm 1: Deep Planning Network (PlaNet)

输入:

R 动作重复次数	$p(s_t s_{t-1}, a_{t-1})$ 转移模型
S 种子 episode 数	$p(o_t s_t)$ 观测模型
C 收集间隔	$p(r_t s_t)$ 奖励模型
B 批次大小	$q(s_t o_{\leq t}, a_{< t})$ 编码器
L 片段长度	$p(\epsilon)$ 探索噪声
α 学习率	

```

1 用  $S$  个随机种子 episode 初始化数据集  $\mathcal{D}$ 。
2 随机初始化模型参数  $\theta$ 。
3 while 未收敛 do
    // 模型拟合
4   for 更新步  $s = 1..C$  do
5       从数据集中均匀随机抽取序列片段
6        $\{(o_t, a_t, r_t)_{t=k}^{L+k}\}_{i=1}^B \sim \mathcal{D}$ 。
7       根据??计算损失  $\mathcal{L}(\theta)$ 。
7       更新模型参数  $\theta \leftarrow \theta - \alpha \nabla_{\theta} \mathcal{L}(\theta)$ 。

    // 数据收集
8    $o_1 \leftarrow \text{env.reset}()$ 
9   for 训练步  $t = 1..\lceil \frac{T}{R} \rceil$  do
10      从历史中推断当前状态信念  $q(s_t | o_{\leq t}, a_{< t})$ 。
11       $a_t \leftarrow \text{planner}(q(s_t | o_{\leq t}, a_{< t}), p)$ , 详见附录中的??。
12      向动作添加探索噪声  $\epsilon \sim p(\epsilon)$ 。
13      for 动作重复  $k = 1..R$  do
14           $r_t^k, o_{t+1}^k \leftarrow \text{env.step}(a_t)$ 
15           $r_t, o_{t+1} \leftarrow \sum_{k=1}^R r_t^k, o_{t+1}^k$ 
16       $\mathcal{D} \leftarrow \mathcal{D} \cup \{(o_t, a_t, r_t)_{t=1}^T\}$ 

```

下随机动力学

转移函数:	$s_t \sim p(s_t s_{t-1}, a_{t-1})$
观测函数:	$o_t \sim p(o_t s_t)$
奖励函数:	$r_t \sim p(r_t s_t)$
策略:	$a_t \sim p(a_t o_{\leq t}, a_{< t})$

其中我们不失一般性地假设一个固定的初始状态 s_0 。目标是实现一个策略 $p(a_t | o_{\leq t}, a_{< t})$ ，以最大化期望奖励和 $E_p[\sum_{t=1}^T r_t]$ ，其中期望是在环境和策略的分布上取的。

基于模型的规划 $p(s_t | s_{t-1}, a_{t-1})$ 、观测模型 $p(o_t | s_t)$ 和奖励模型 $p(r_t | s_t)$ (注意模型用斜体字母表示，而真实动力学用正体字母表示)。观测模型提供了丰富的训练信号，但不用于规划。我们还学习一个编码器 $q(s_t | o_{\leq t}, a_{< t})$ ，通过滤波从历史中推断当前隐藏状态的近似信念。给定这些组件，我们将策略实现为一个规划算法，该算法搜索最优的未来动作序列。我们使用模型预测控制 (MPC; ?)，使智能体能够基于新的观测调整其规划，即我们在每一步都重新规划。与无模型和混合强化学习算法不同，我们不使用策略或价值网络。

经验收集 由于智能体最初可能不会访问环境的所有部分，我们需要迭代地收集新经验并完善动力学模型。我们通过使用部分训练的模型进行规划来实现这一点，如??所示。从少量 S 个随机动作下的种子 episode 开始，我们训练模型，并每 C 个更新步向数据集中添加一个额外的 episode。在为数据集收集 episode 时，我们对动作添加小的 Gaussian 探索噪声。为了缩短规划视野并为模型提供更清晰的学习信号，我们每个动作重复 R 次，这在强化学习中很常见 (??)。

规划算法 我们使用交叉熵方法 (CEM; ??) 在模型下搜索最优动作序列，如??所述。我们选择该算法是因为其鲁棒性，且当给定真实动力学进行规划时，它能够解决所有考虑的任务。CEM 是一种基于种群的优化算法，它推断出最大化目标的动作序列上的分布。如附录中的??所述，我们初始化一个与时间相关的对角 Gaussian 信念分布，用于描述最优动作序列 $a_{t:t+H} \sim \text{Normal}(\mu_{t:t+H}, \sigma_{t:t+H}^2 \mathbb{I})$ ，其中 t 是智能体的当前时间步， H 是规划视野长度。从零均值和单位方差开始，我们反复采样 J 个候选动作序列，在模型下评估它们，并将信念重新拟合到前 K 个动作序列。经过 I 次迭代后，规划器返回当前时间步的信念均值 μ_t 。重要的是，在接收到下一个观测后，动作序列的信念再次从零均值和单位方差开始，以避免局部最优。

为了在学习模型下评估候选动作序列，我们从当前状态信念出发采样一条状态轨迹，并将沿序列预测的均值奖励相

加。由于我们使用基于种群的优化器，我们发现每个动作序列仅考虑一条轨迹就足够了，从而将计算预算集中在评估更多不同的序列上。由于奖励被建模为潜在状态的函数，规划器可以完全在潜在空间中操作而无需生成图像，这允许快速评估大批量动作序列。下一节将介绍规划器所使用的潜在动力学模型。

3. 循环状态空间模型

为了进行规划，我们需要在智能体的每个时间步评估数千个动作序列。因此，我们使用循环状态空间模型（RSSM），它可以完全在潜在空间中进行前向预测，类似于最近提出的模型（???）。该模型可以被视为一个非线性 Kalman 滤波器或序列 VAE。我们不进行与先前架构的广泛比较，而是强调两个可以指导未来动力学模型设计的发现：我们的实验表明，转移模型中同时具有随机性和确定性路径对成功规划至关重要。在本节中，我们首先回顾潜在状态空间模型，然后描述我们的动力学模型。

潜在动力学 我们考虑序列 $\{o_t, a_t, r_t\}_{t=1}^T$ ，其中包含离散时间步 t 、图像观测 o_t 、连续动作向量 a_t 和标量奖励 r_t 。一个典型的潜在状态空间模型如??所示，其结构与部分可观马尔可夫决策过程相似。它使用隐藏状态序列 $\{s_t\}_{t=1}^T$ 定义了图像和奖励的生成过程，

$$\begin{aligned} \text{转移模型:} & s_t \sim p(s_t | s_{t-1}, a_{t-1}) \\ \text{观测模型:} & o_t \sim p(o_t | s_t) \\ \text{奖励模型:} & r_t \sim p(r_t | s_t), \end{aligned} \quad (2)$$

其中我们不失一般性地假设一个固定的初始状态 s_0 。转移模型是 Gaussian 分布，其均值和方差由前馈神经网络参数化；观测模型是 Gaussian 分布，均值由反卷积神经网络参数化，协方差为单位矩阵；奖励模型是标量 Gaussian 分布，均值由前馈神经网络参数化，方差为单位方差。注意，在单位方差 Gaussian 分布下的对数似然等于均方误差，仅相差一个常数。

变分编码器 由于模型是非线性的，我们无法直接计算参数学习所需的状态后验。相反，我们使用编码器 $q(s_{1:T} | o_{1:T}, a_{1:T}) = \prod_{t=1}^T q(s_t | s_{t-1}, a_{t-1}, o_t)$ 从过去的观测和动作中推断近似的状态后验，其中 $q(s_t | s_{t-1}, a_{t-1}, o_t)$ 是一个对角 Gaussian 分布，其均值和方差由卷积神经网络后接前馈神经网络参数化。我们使用以过去观测为条件的滤波后验，因为我们最终关注于使用模型进行规划，但在训练过程中也可以使用完整的平滑后验（??）。

训练目标 使用编码器，我们构建了数据对数似然的变分界。为简单起见，我们仅写出预测观测的损失——奖励损失的推导类似。使用 Jensen 不等式得到的变分界为

$$\ln p(o_{1:T} | a_{1:T}) \triangleq \ln \int \prod_t p(s_t | s_{t-1}, a_{t-1}) p(o_t | s_t)_{1:T}$$

$$\geq \sum_{t=1}^T \left(\underbrace{\mathbb{E}_{q(s_t | o_{\leq t}, a_{< t})} [\ln p(o_t | s_t)]}_{\text{重建}} - \underbrace{\mathbb{E} [\text{KL}[q(s_t | o_{\leq t}, a_{< t}) \parallel p(s_t | s_{t-1}, a_{t-1})]]}_{\text{复杂度}} \right). \quad (3)$$

推导过程请参见附录中的??。使用单个重参数化采样估计外部期望，可得到一个用于非线性潜在变量模型推断和学习的有效目标，该目标可以通过梯度上升进行优化（???）。

确定性路径 尽管具有一般性，纯随机性的转移使得转移模型难以在多个时间步中可靠地记住信息。理论上，该模型可以学习将某些状态分量的方差设为零，但优化过程可能找不到该解。这促使我们引入一个确定性激活向量序列 $\{h_t\}_{t=1}^T$ ，使模型不仅能够访问最近的状态，还能确定性地访问所有先前的状态（??）。我们使用这样的模型，如??所示，并将其命名为循环状态空间模型（RSSM），

$$\begin{aligned} \text{确定性状态模型:} & h_t = f(h_{t-1}, s_{t-1}, a_{t-1}) \\ \text{随机性状态模型:} & s_t \sim p(s_t | h_t) \\ \text{观测模型:} & o_t \sim p(o_t | h_t, s_t) \\ \text{奖励模型:} & r_t \sim p(r_t | h_t, s_t), \end{aligned} \quad (4)$$

其中 $f(h_{t-1}, s_{t-1}, a_{t-1})$ 通过循环神经网络（RNN）实现。直观地，我们可以将该模型理解为将状态分解为随机部分 s_t 和确定性部分 h_t ，这两部分通过 RNN 依赖于前一时间步的随机和确定性部分。我们使用编码器 $q(s_{1:T} | o_{1:T}, a_{1:T}) = \prod_{t=1}^T q(s_t | h_t, o_t)$ 来参数化近似状态后验。重要的是，所有关于观测的信息都必须通过编码器的采样步骤，以避免从输入到重建的确定性捷径。

在下一节中，我们将指出潜在序列模型标准目标的一个局限性，并提出一种对其的推广以改进长期预测。

4. 潜在越步

在上一节中，我们推导了潜在序列模型学习和推断的典型变分界（??）。如??所示，该目标函数包含观测的重建项和近似后验的 KL 散度正则化项。该目标的一个局限性是，转移函数 $p(s_t | s_{t-1}, a_{t-1})$ 的随机路径仅通过单步预测的 KL 散度正则化项进行训练：梯度通过 $p(s_t | s_{t-1}, a_{t-1})$ 直接流入 $q(s_{t-1})$ ，但从未穿过多个 $p(s_t | s_{t-1}, a_{t-1})$ 的链条。在本节中，我们将此变分界推广为**潜在越步**，它训练潜在空间中所有距离的多步预测。我们发现多个动力学模型都受益于潜在越步，尽管我们最终使用 RSSM 模型的智能体并不需要它（见??）。

容量有限 如果我们能够训练模型做出完美的单步预测，那么它也会做出完美的多步预测，因此这不会成为问题。然而，当使用容量有限且分布族受限的模型时，仅在单步预测上训练直到收敛，通常并不会得到在多步预测上最优的模型。为了成功进行规划，我们需要精确的多步预测。因此，我们受?及更早的相关思想（???）的启发，在所有距离的多步预测上训练模型。我们为潜在序列模型发展了这一思想，表明多步预测可以通过潜在空间中的损失来改进，而无需生成额外的图像。




Figure 2: 潜在动力学模型设计。在本例中，模型观测前两个时间步并预测第三个时间步。圆形表示随机变量，方形表示确定性变量。实线表示生成过程，虚线表示推断模型。(a) 循环神经网络中的转移是纯确定性的。这阻止了模型捕捉多种未来，并使规划器容易利用不准确性。(b) 状态空间模型中的转移是纯随机性的。这使得在多个时间步中记住信息变得困难。(c) 我们将状态分解为随机和确定性部分，使模型能够鲁棒地学习预测多种未来。




Figure 3: 展开方案。标签 $s_{i|j}$ 是时间 i 处、以时间 j 之前的观测为条件的状态的简写。指向灰色圆的箭头表示对数似然损失项。波浪箭头表示 KL 散度损失项。(a) 标准变分目标在每一步解码后验以计算重建损失。它还在每一步对先验和后验施加 KL 散度，这训练了单步预测的转移函数。(b) 观测越步 (?) 解码所有多步预测以施加额外的重建损失。这在图像领域通常计算代价过高。(c) 潜在越步预测所有多步先验。这些状态信念在潜在空间中被训练朝向其对应的后验，以鼓励精确的多步预测。

多步预测 我们首先将标准变分界 (??) 从训练单步预测推广到训练固定距离 d 的多步预测。为简化符号，此处我们省略条件集合中的动作；每个关于 s_t 的分布都以 $a_{<t}$ 为条件。我们首先定义多步预测，它通过重复应用转移模型并积分掉中间状态来计算，

$$p(s_t | s_{t-d}) \triangleq \int \prod_{\tau=t-d+1}^t p(s_\tau | s_{\tau-1})_{t-d+1:t-1} \quad (5)$$

$$= \mathbb{E}_{p(s_{t-1} | s_{t-d})} [p(s_t | s_{t-1})].$$

$d = 1$ 的情况还原了原始模型中使用的单步转移。基于此多步预测定义，我们将 ?? 推广为多步预测分布 p_d 上的变

分界，

$$\begin{aligned} \ln p_d(o_{1:T}) &\triangleq \ln \int \prod_{t=1}^T p(s_t | s_{t-d}) p(o_t | s_t)_{1:T} \\ &\geq \sum_{t=1}^T \left(\underbrace{\mathbb{E}_{q(s_t | o_{\leq t})} [\ln p(o_t | s_t)]}_{\text{重建}} \leftarrow \right. \\ &\quad \left. - \underbrace{\mathbb{E} [\text{KL}[q(s_t | o_{\leq t}) \parallel p(s_t | s_{t-1})]]}_{\text{多步预测}} \right). \end{aligned} \quad (6)$$

推导过程请参见附录中的 ??。最大化此目标可以训练多步预测分布。这反映了在规划过程中，模型在没有访问所有先前观测的情况下进行预测的事实。

我们推测 ?? 也是 $\ln p(o_{1:T})$ 的一个下界，基于数据处理不等式。由于潜在状态序列是 Markov 的，对于 $d \geq 1$ 我们有 $I(s_t; s_{t-d}) \leq I(s_t; s_{t-1})$ ，因此 $\mathbb{E}[\ln p_d(o_{1:T})] \leq \mathbb{E}[\ln p(o_{1:T})]$ 。因此，在数据集上取期望后，多步预测分布的每一个界同时也是单步预测分布的界。详细信息请参见附录中的 ??。在下一段中，我们将解决某个特定 p_d 仅训练单一距离预测的局限性，并得到我们的最终目标。

潜在越步 我们引入了给定距离 d 的预测界。然而，对于规划而言，我们需要的不仅是固定距离的精确预测，而是直到规划视野的所有距离的精确预测。为此我们引入潜在越步，这是潜在序列模型的一个目标函数，它推广了标准变分界 (??)，在所有距离 $1 \leq d \leq D$ 的多步预测上训练模型，

$$\frac{1}{D} \sum_{d=1}^D \ln p_d(o_{1:T}) \geq \sum_{t=1}^T \left(\underbrace{\mathbb{E}_{q(s_t | o_{\leq t})} [\ln p(o_t | s_t)]}_{\text{重建}} - \underbrace{\frac{1}{D} \sum_{d=1}^D \beta_d \mathbb{E} [\text{KL}[q(s_t | o_{\leq t}) \parallel p(s_t | s_{t-1})]]}_{\text{潜在越步}} \right). \quad (7)$$

潜在越步可以理解为潜在空间中的一个正则化器，它鼓励单步预测和多步预测之间的一致性，而我们知道在数据集上取期望后这两者应该是等价的。我们包含权重因子 $\{\beta_d\}_{d=1}^D$ ，类似于 β -VAE (??)。虽然为简单起见我们将所有 $\beta_{>1}$ 设为相同的值，但它们可以被选择为让模型更多地关注长期或短期预测。在实践中，我们对越步距离 $d > 1$ 的后验分布停止梯度，使得多步预测被训练朝向信息更丰富的后验，而不是相反。

5. 实验

我们在六个基于像素的连续控制任务上评估 PlaNet。我们从智能体的多个设计维度进行探索：动力学模型中的随机性和确定性路径、迭代规划以及在线经验收集。有关超参数 (??) 和额外实验 (??????)，请参见附录。除了动作重复次数外，我们对所有任务使用相同的超参数。在不到百分之一的 episode 数内，3C (??)，并达到了与顶级无模型算法 D4PG (??) 相似的性能。在单块 Nvidia V100 GPU 上 10 到 20 小时的训练时间（取决于任务）与 A3C 和 D4PG 相比具有优势。我们的实现使用了 TensorFlow Probability (??)。请访问 <https://danijar.com/planet> 获取代码和训练智能体的视频。

在我们的评估中，我们考虑了 DeepMind 控制套件中的六个基于图像的连续控制任务 (??)，如??所示。这些环境提供了性质上各异的挑战。cartpole 摆起任务需要较长的规划视野，并且需要在推车移出视野时记住其位置；reacher 任务具有稀疏奖励，当手和目标区域重叠时才给予奖励；finger 旋转任务包含手指与物体之间的接触动力学；cheetah 具有更大的状态和动作空间；cup 任务仅在球被接住时才有稀疏奖励；walker 任务具有挑战性，因为机器人首先需要站立起来然后行走，导致与地面发生难以预测的碰撞。在所有任务中，仅有的观测是大小为 $64 \times 64 \times 3$ 像素的第三人称相机图像。

与无模型方法的比较 ??将?报告的无模型算法进行了比较。在 100 个 episode 内，100,000 个 episode 的策略梯度方法 A3C。在 500 个 episode 后，除 finger 任务外，其性能与从图像训练了 100,000 个 episode 的 D4PG 相似。26% 的相对提升超越了 D4PG 的最终性能。数值结果请参见??，其中还包含了使用模拟器真实动力学进行 CEM 规划的性能。

模型设计 ??还比较了动力学模型的设计选择。我们使用循环状态空间模型 (RSSM) 以及纯确定性的 GRU (??) 和纯随机性的状态空间模型 (SSM) 版本训练 PlaNet。我们观察到，在所有任务上转移函数中同时具有随机性和确定性元素的重要性。确定性部分使模型能够在多个时间步中记住信息。随机性成分更加重要——没有它，智能体根本无法学习。这可能是因为由于初始状态的部分可观测性，这些任务从智能体的角度来看是随机的。噪声还可能为规划目标增加安全边际，从而产生更鲁棒的动作序列。

智能体设计 ??比较了 PlaNet、一个在随机动作下收集 episode 而非通过规划收集的版本，以及一个在每个环境步从 1000 个序列中选择最优动作而不通过 CEM 迭代优化规划的版本（随机射击）。我们观察到，在线数据收集对所有任务都有帮助，并且对 cartpole、finger 和 walker 任务是必需的。使用 CEM 迭代搜索动作序列在所有任务上都提升了性能。

单智能体多任务 附录中的??展示了在全部六个任务上训练的单个智能体的性能。智能体不会被告知它面临哪个任务；它需要从图像观测中推断。我们对齐动作空间（用未使用的元素填充）以使其兼容，并修改??，每 C 个更新步收集每个任务的一个 episode。我们使用与上述主要实验相同的超参数。该智能体解决了所有任务，尽管与单独训练的智能体相比学习速度较慢。这表明模型可以学习预测多个领域，无论它们在视觉概念上有什么不同。

6. 相关工作

基于模型强化学习的先前工作集中于在低维状态空间中进行规划 (????)，结合基于模型和无模型方法的优势 (????????)，以及不涉及规划的纯视频预测 (????????)。??更详细地回顾了这些正交的研究方向。

相对较少的工作展示了使用学习到的动力学模型从像素中成功进行规划。机器人学社区专注于用于规划的视频预测模型 (????)，这些模型处理真实世界的视觉复杂性并使用简单的夹具解决任务，如抓取或推动物体。相比之下，我们专注于模拟环境，利用潜在规划扩展到更大的状态和动作空间、更长的规划视野以及稀疏奖励任务。E2C (??) 和 RCE (??) 将图像嵌入到潜在空间中，在潜在空间中学习局部线性的潜在转移，并使用 LQR 规划动作。这些方法可以平衡模拟摆杆并从图像控制双连杆臂，但一直难以扩展。我们解除了这些模型的 Markov 假设，使我们的方法在部分可观测情况下仍然适用，并在更具挑战性的环境中展示了结果，包括更长的规划视野、接触动力学和稀疏奖励。

7. 讨论

我们提出了 PlaNet，这是一种基于模型的智能体，它从图像观测中学习潜在动力学模型，并通过在潜在空间中进




Figure 4: 图中显示测试性能随所收集 episode 数量的变化。我们将使用 RSSM (??) 的 (GRU) 和纯随机性模型 (SSM) 进行比较。RNN 不使用潜在越步，因为它没有随机潜在变量。线条表示中位数，区域表示 5 个种子和 10 条轨迹上的第 5 到第 95 百分位数。由于稀疏奖励，其中两个任务的阴影区域较大。

Table 1: ?报告的无模型算法 A3C 和 D4PG 的比较。这些算法的训练曲线在其论文的图 4 中以橙色线显示，在图 6 中以实心绿色线显示。我们据此估计 D4PG 达到，以估算数据效率增益。我们还包含了使用真实模拟器替代学习动力学的 CEM 规划 ($H = 12, I = 10, J = 1000, K = 100$)，作为性能的估计上界。数值表示 5 个种子和 10 条轨迹上的平均最终性能。

方法	模态	Episodes	Cartpole Swing Up	Reacher Easy	Cheetah Run	Finger Spin	Cup Catch	Walker Walk
A3C	本体感知	100,000	558	285	214	129	105	311
D4PG	像素	100,000	862	967	524	985	980	968
PlaNet (本文)	像素	1,000	821	832	662	700	930	951
CEM + 真实模拟器	模拟器状态	0	850	964	656	825	993	994
PlaNet 相对 D4PG 的数据效率增益 (倍数)			250	40	500+	300	100	90

行快速规划来选择动作。为了实现精确的长期预测，我们设计了一个同时具有随机性和确定性路径的模型。我们证明，我们的智能体在多个基于图像观测的连续控制任务上取得了成功，达到了与最佳无模型算法相当的性能，同时使用的 episode 数减少了 $200\times$ ，且计算时间相似或更少。结果表明，在图像领域中学习用于规划的潜在动力学模型是一种有前景的方法。

未来工作的方向包括学习时间抽象而非使用固定的动作重复，可能通过分层模型来实现。为了进一步提高最终性能，可以学习一个价值函数来近似规划视野之外的奖励和。此外，基于梯度的规划可以提高智能体的计算效率，

而无需重建的学习表示可以帮助解决具有更高视觉多样性的任务。我们的工作为通过共享动力学模型实现多任务控制提供了一个起点。

致谢 我们感谢 Jacob Buckman、Nicolas Heess、John Schulman、Rishabh Agarwal、Silviu Pitis、Mohammad Norouzi、George Tucker、David Duvenaud、Shane Gu、Chelsea Finn、Steven Bohez、Jimmy Ba、Stephanie Chan 和 Jenny Liu 的有益讨论。




Figure 5: 智能体设计比较。图中显示测试性能随所收集 episode 数量的变化。我们比较了 PlaNet、一个在随机动作下收集数据的版本（随机收集），以及一个在每个环境步从 1000 个序列中选择最优动作而不通过 CEM 迭代优化规划的版本（随机射击）。线条表示中位数，区域表示 5 个种子和 10 条轨迹上的第 5 到第 95 百分位数。

References

- Agrawal, P., Nair, A. V., Abbeel, P., Malik, J., and Levine, S. Learning to poke by poking: Experiential learning of intuitive physics. In *Advances in Neural Information Processing Systems*, pp. 5074–5082, 2016.
- Amos, B., Dinh, L., Cabi, S., Rothörl, T., Muldal, A., Erez, T., Tassa, Y., de Freitas, N., and Denil, M. Learning awareness models. In *International Conference on Learning Representations*, 2018.
- Babaeizadeh, M., Finn, C., Erhan, D., Campbell, R. H., and Levine, S. Stochastic variational video prediction. *arXiv preprint arXiv:1710.11252*, 2017.
- Banijamali, E., Shu, R., Ghavamzadeh, M., Bui, H., and Ghodsi, A. Robust locally-linear controllable embedding. *arXiv preprint arXiv:1710.05373*, 2017.
- Barth-Maron, G., Hoffman, M. W., Budden, D., Dabney, W., Horgan, D., Muldal, A., Heess, N., and Lillicrap, T. Distributed distributional deterministic policy gradients. *arXiv preprint arXiv:1804.08617*, 2018.
- Bengio, S., Vinyals, O., Jaitly, N., and Shazeer, N. Scheduled sampling for sequence prediction with recurrent neural networks. In *Advances in Neural Information Processing Systems*, pp. 1171–1179, 2015.
- Buckman, J., Hafner, D., Tucker, G., Brevdo, E., and Lee, H. Sample-efficient reinforcement learning with stochastic ensemble value expansion. *arXiv preprint arXiv:1807.01675*, 2018.
- Buesing, L., Weber, T., Racaniere, S., Eslami, S., Rezende, D., Reichert, D. P., Viola, F., Besse, F., Gregor, K., Hassabis, D., et al. Learning and querying fast generative models for reinforcement learning. *arXiv preprint arXiv:1802.03006*, 2018.
- Chiappa, S., Racaniere, S., Wierstra, D., and Mohamed, S. Recurrent environment simulators. *arXiv preprint arXiv:1704.02254*, 2017.
- Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., and Bengio, Y. Learning phrase representations using rnn encoder-decoder for statistical machine translation. *arXiv preprint arXiv:1406.1078*, 2014.
- Chua, K., Calandra, R., McAllister, R., and Levine, S. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. *arXiv preprint arXiv:1805.12114*, 2018.
- Chung, J., Kastner, K., Dinh, L., Goel, K., Courville, A. C., and Bengio, Y. A recurrent latent variable model for sequential data. In *Advances in neural information processing systems*, pp. 2980–2988, 2015.
- Clevert, D.-A., Unterthiner, T., and Hochreiter, S. Fast and accurate deep network learning by exponential linear units (elus). *arXiv preprint arXiv:1511.07289*, 2015.
- Deisenroth, M. and Rasmussen, C. E. Pilco: A model-based and data-efficient approach to policy search. In *Proceedings of the 28th International Conference on machine learning (ICML-11)*, pp. 465–472, 2011.
- Denton, E. and Fergus, R. Stochastic video generation with a learned prior. *arXiv preprint arXiv:1802.07687*, 2018.
- Dillon, J. V., Langmore, I., Tran, D., Brevdo, E., Vasudevan, S., Moore, D., Patton, B., Alemi, A., Hoffman, M., and Saurous, R. A. Tensorflow distributions. *arXiv preprint arXiv:1711.10604*, 2017.

- Doerr, A., Daniel, C., Schiegg, M., Nguyen-Tuong, D., Schaal, S., Toussaint, M., and Trimpe, S. Probabilistic recurrent state-space models. *arXiv preprint arXiv:1801.10395*, 2018.
- Ebert, F., Finn, C., Dasari, S., Xie, A., Lee, A., and Levine, S. Visual foresight: Model-based deep reinforcement learning for vision-based robotic control. *arXiv preprint arXiv:1812.00568*, 2018.
- Finn, C. and Levine, S. Deep visual foresight for planning robot motion. In *Robotics and Automation (ICRA), 2017 IEEE International Conference on*, pp. 2786–2793. IEEE, 2017.
- Gal, Y., McAllister, R., and Rasmussen, C. E. Improving pilco with bayesian neural network dynamics models. In *Data-Efficient Machine Learning workshop, ICML*, 2016.
- Gemici, M., Hung, C.-C., Santoro, A., Wayne, G., Mohamed, S., Rezende, D. J., Amos, D., and Lillicrap, T. Generative temporal models with memory. *arXiv preprint arXiv:1702.04649*, 2017.
- Gregor, K. and Besse, F. Temporal difference variational auto-encoder. *arXiv preprint arXiv:1806.03107*, 2018.
- Ha, D. and Schmidhuber, J. World models. *arXiv preprint arXiv:1803.10122*, 2018.
- Henaff, M., Whitney, W. F., and LeCun, Y. Model-based planning with discrete and continuous actions. *arXiv preprint arXiv:1705.07177*, 2018.
- Higgins, I., Matthey, L., Pal, A., Burgess, C., Glorot, X., Botvinick, M., Mohamed, S., and Lerchner, A. beta-vae: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations*, 2016.
- Higuera, J. C. G., Meger, D., and Dudek, G. Synthesizing neural network controllers with probabilistic model based reinforcement learning. *arXiv preprint arXiv:1803.02291*, 2018.
- Igl, M., Zintgraf, L., Le, T. A., Wood, F., and Whiteson, S. Deep variational reinforcement learning for pomdps. *arXiv preprint arXiv:1806.02426*, 2018.
- Kalchbrenner, N., Oord, A. v. d., Simonyan, K., Danihelka, I., Vinyals, O., Graves, A., and Kavukcuoglu, K. Video pixel networks. *arXiv preprint arXiv:1610.00527*, 2016.
- Kalweit, G. and Boedecker, J. Uncertainty-driven imagination for continuous deep reinforcement learning. In *Conference on Robot Learning*, pp. 195–206, 2017.
- Karl, M., Soelch, M., Bayer, J., and van der Smagt, P. Deep variational bayes filters: Unsupervised learning of state space models from raw data. *arXiv preprint arXiv:1605.06432*, 2016.
- Kingma, D. P. and Ba, J. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- Kingma, D. P. and Dhariwal, P. Glow: Generative flow with invertible 1x1 convolutions. *arXiv preprint arXiv:1807.03039*, 2018.
- Kingma, D. P. and Welling, M. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- Krishnan, R. G., Shalit, U., and Sontag, D. Deep kalman filters. *arXiv preprint arXiv:1511.05121*, 2015.
- Krishnan, R. G., Shalit, U., and Sontag, D. Structured inference networks for nonlinear state space models. In *AAAI*, pp. 2101–2109, 2017.
- Kurutach, T., Clavera, I., Duan, Y., Tamar, A., and Abbeel, P. Model-ensemble trust-region policy optimization. *arXiv preprint arXiv:1802.10592*, 2018.
- Lamb, A. M., GOYAL, A. G. A. P., Zhang, Y., Zhang, S., Courville, A. C., and Bengio, Y. Professor forcing: A new algorithm for training recurrent networks. In *Advances In Neural Information Processing Systems*, pp. 4601–4609, 2016.
- Mathieu, M., Couprie, C., and LeCun, Y. Deep multi-scale video prediction beyond mean square error. *arXiv preprint arXiv:1511.05440*, 2015.
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529, 2015.
- Mnih, V., Badia, A. P., Mirza, M., Graves, A., Lillicrap, T., Harley, T., Silver, D., and Kavukcuoglu, K. Asynchronous methods for deep reinforcement learning. In *International Conference on Machine Learning*, pp. 1928–1937, 2016.

- Moerland, T. M., Broekens, J., and Jonker, C. M. Learning multimodal transition dynamics for model-based reinforcement learning. *arXiv preprint arXiv:1705.00470*, 2017.
- Moravčík, M., Schmid, M., Burch, N., Lisý, V., Morrill, D., Bard, N., Davis, T., Waugh, K., Johanson, M., and Bowling, M. Deepstack: Expert-level artificial intelligence in heads-up no-limit poker. *Science*, 356(6337):508–513, 2017.
- Nagabandi, A., Kahn, G., Fearing, R. S., and Levine, S. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. *arXiv preprint arXiv:1708.02596*, 2017.
- Nair, V. and Hinton, G. E. Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th international conference on machine learning (ICML-10)*, pp. 807–814, 2010.
- Oh, J., Guo, X., Lee, H., Lewis, R. L., and Singh, S. Action-conditional video prediction using deep networks in atari games. In *Advances in Neural Information Processing Systems*, pp. 2863–2871, 2015.
- Rezende, D. J., Mohamed, S., and Wierstra, D. Stochastic backpropagation and approximate inference in deep generative models. *arXiv preprint arXiv:1401.4082*, 2014.
- Richards, A. G. *Robust constrained model predictive control*. PhD thesis, Massachusetts Institute of Technology, 2005.
- Rubinstein, R. Y. Optimization of computer simulation models with rare events. *European Journal of Operational Research*, 99(1):89–112, 1997.
- Silver, D., Schrittwieser, J., Simonyan, K., Antonoglou, I., Huang, A., Guez, A., Hubert, T., Baker, L., Lai, M., Bolton, A., et al. Mastering the game of go without human knowledge. *Nature*, 550(7676):354, 2017.
- Srinivas, A., Jabri, A., Abbeel, P., Levine, S., and Finn, C. Universal planning networks. *arXiv preprint arXiv:1804.00645*, 2018.
- Talvitie, E. Model regularization for stable sample rollouts. In *UAI*, pp. 780–789, 2014.
- Tassa, Y., Erez, T., and Todorov, E. Synthesis and stabilization of complex behaviors through online trajectory optimization. In *Intelligent Robots and Systems (IROS), 2012 IEEE/RSJ International Conference on*, pp. 4906–4913. IEEE, 2012.
- Tassa, Y., Doron, Y., Muldal, A., Erez, T., Li, Y., Casas, D. d. L., Budden, D., Abdolmaleki, A., Merel, J., Lefrancq, A., et al. Deepmind control suite. *arXiv preprint arXiv:1801.00690*, 2018.
- van den Oord, A., Vinyals, O., et al. Neural discrete representation learning. In *Advances in Neural Information Processing Systems*, pp. 6309–6318, 2017.
- Venkatraman, A., Hebert, M., and Bagnell, J. A. Improving multi-step prediction of learned time series models. In *AAAI*, pp. 3024–3030, 2015.
- Vondrick, C., Pirsiavash, H., and Torralba, A. Generating videos with scene dynamics. In *Advances In Neural Information Processing Systems*, 2016.
- Watter, M., Springenberg, J., Boedecker, J., and Riedmiller, M. Embed to control: A locally linear latent dynamics model for control from raw images. In *Advances in neural information processing systems*, pp. 2746–2754, 2015.
- Wayne, G., Hung, C.-C., Amos, D., Mirza, M., Ahuja, A., Grabska-Barwinska, A., Rae, J., Mirowski, P., Leibo, J. Z., Santoro, A., et al. Unsupervised predictive memory in a goal-directed agent. *arXiv preprint arXiv:1803.10760*, 2018.
- Weber, T., Racanière, S., Reichert, D. P., Buesing, L., Guez, A., Rezende, D. J., Badia, A. P., Vinyals, O., Heess, N., Li, Y., et al. Imagination-augmented agents for deep reinforcement learning. *arXiv preprint arXiv:1707.06203*, 2017.
- Zhang, M., Vikram, S., Smith, L., Abbeel, P., Johnson, M., and Levine, S. SOLAR: deep structured representations for model-based reinforcement learning. *arXiv preprint arXiv:1808.09105*, 2018.

A. 超参数

我们使用来自?的卷积和反卷积网络, 使用具有 200 个单元的 GRU (?) 作为动力学模型中的确定性路径, 并将所有其他函数实现为两个大小为 200 的全连接层, 使用 ReLU 激活 (?). 潜在空间中的分布是 30 维对角 Gaussian 分布, 其均值和标准差由模型预测。

我们对图像进行预处理, 将位深度降低到 5 位, 如?所述。模型使用 Adam 优化器 (?) 训练, 学习率为 10^{-3} , $\epsilon = 10^{-4}$, 梯度裁剪范数为 1000, 批次为 $B = 50$ 个长度为 $L = 50$ 的序列片段。我们不相对于重建项缩放 KL 散度项, 但通过将散度损失裁剪到低于 3 个自由 nats 的值来给予模型 3 个自由 nats。在智能体的先前版本中, 我们使用潜在越步和一个额外的固定全局先验, 但我们发现这是不必要的。

对于规划, 我们使用 CEM, 规划视野长度 $H = 12$, 优化迭代次数 $I = 10$, 候选采样数 $J = 1000$, 重新拟合到最佳的 $K = 100$ 个候选。我们从 $S = 5$ 个随机动作的种子 episode 开始, 每 $C = 100$ 个更新步在 $\epsilon \sim \text{Normal}(0, 0.3)$ 的动作噪声下收集另一个 episode。动作重复在不同领域之间有所不同: cartpole ($R = 8$)、reacher ($R = 4$)、cheetah ($R = 4$)、finger ($R = 2$)、cup ($R = 4$)、walker ($R = 2$)。我们发现重要的超参数包括动作重复次数、KL 散度缩放系数 β 和学习率。

B. 规划算法

Algorithm 2: 使用 CEM 的潜在规划

输入: H 规划视野距离 $q(s_t \mid o_{\leq t}, a_{< t})$ 当前状态信念
 I 优化迭代次数 $p(s_t \mid s_{t-1}, a_{t-1})$ 转移模型
 J 每轮候选数 $p(r_t \mid s_t)$ 奖励模型
 K 用于拟合的顶级候选数

```

1 初始化动作序列上的分解信念  $q(a_{t:t+H}) \leftarrow \text{Normal}(0, \mathbb{I})$ 。
2 for 优化迭代  $i = 1..I$  do
    // 从当前信念中评估  $J$  个动作序列。
3   for 候选动作序列  $j = 1..J$  do
4        $a_{t:t+H}^{(j)} \sim q(a_{t:t+H})$ 
5        $s_{t:t+H+1}^{(j)} \sim q(s_t \mid o_{1:t}, a_{1:t-1}) \prod_{\tau=t+1}^{t+H+1} p(s_\tau \mid s_{\tau-1}, a_{\tau-1}^{(j)})$ 
6        $R^{(j)} = \sum_{\tau=t+1}^{t+H+1} \mathbb{E}[p(r_\tau \mid s_\tau^{(j)})]$ 
    // 将信念重新拟合到  $K$  个最优动作序列。
7    $\mathcal{K} \leftarrow \text{argsort}(\{R^{(j)}\}_{j=1}^J)_{1:K}$ 
8    $\mu_{t:t+H} = \frac{1}{K} \sum_{k \in \mathcal{K}} a_{t:t+H}^{(k)}$ ,  $\sigma_{t:t+H} = \frac{1}{K-1} \sum_{k \in \mathcal{K}} |a_{t:t+H}^{(k)} - \mu_{t:t+H}|$ .
9    $q(a_{t:t+H}) \leftarrow \text{Normal}(\mu_{t:t+H}, \sigma_{t:t+H}^2 \mathbb{I})$ 
10 return 第一个动作均值  $\mu_t$ 。

```

C. 多任务学习




Figure 6: 我们比较在所有任务上训练的单个。图中显示测试性能随每任务收集的 episode 数量的变化。单个智能体学会了解决所有任务，但与单独训练的智能体相比学习速度较慢。线条表示 6 个任务、5 个种子和 10 条轨迹上的均值和 1 个标准差。




Figure 7: 在六个任务上训练的单个 PlaNet 智能体的逐任务性能。图中显示测试性能随每任务收集的 episode 数量的变化。智能体不会被告知它正在解决哪个任务，需要从图像观测中推断。智能体学会了区分这些任务并解决它们，学习速度仅有适度放缓。线条表示中位数，区域表示 4 个种子和 10 条轨迹上的第 5 到第 95 百分位数。

D. 潜在越步




Figure 8: 我们在提出的 RSSM 和另一种称为 DRNN 的模型（使用两个 RNN 作为编码器和解码器，中间有随机状态序列）上，比较标准变分目标与潜在越步。潜在越步可以显著提升 DRNN 和我们实验过的其他模型（未显示）的性能，但会略微降低我们 RSSM 的性能。线条表示中位数，区域表示 5 个种子和 10 条轨迹上的第 5 到第 95 百分位数。

E. 激活函数




Figure 9: 硬 ReLU (?) 与平滑 ELU (?) 激活函数的比较。我们发现平滑激活有助于提升纯随机模型（以及纯确定性模型；未显示）的性能，而我们提出的 RSSM 对激活函数的选择具有鲁棒性。线条表示中位数，区域表示 5 个种子和 10 条轨迹上的第 5 到第 95 百分位数。

F. 界的推导

单步预测分布 潜在动力学模型 $p(o_{1:T}, s_{1:T} | a_{1:T}) = \prod_t p(s_t | s_{t-1}, a_{t-1})p(o_t | s_t)$ 和变分后验 $q(s_{1:T} | o_{1:T}, a_{1:T}) = \prod_t q(s_t | o_{\leq t}, a_{< t})$ 的变分界通过重要性加权 and Jensen 不等式得到，如下所示：

$$\begin{aligned}
 \ln p(o_{1:T} | a_{1:T}) &\triangleq \ln \mathbb{E}_{p(s_{1:T}|a_{1:T})} \left[\prod_{t=1}^T p(o_t | s_t) \right] \\
 &= \ln \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\prod_{t=1}^T p(o_t | s_t) p(s_t | s_{t-1}, a_{t-1}) / q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &\geq \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\sum_{t=1}^T \ln p(o_t | s_t) + \ln p(s_t | s_{t-1}, a_{t-1}) - \ln q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &= \sum_{t=1}^T \left(\underbrace{\mathbb{E}_{q(s_t|o_{\leq t}, a_{< t})} [\ln p(o_t | s_t)]}_{\text{重建}} - \underbrace{\mathbb{E}_{q(s_{t-1}|o_{\leq t-1}, a_{< t-1})} [\text{KL}[q(s_t | o_{\leq t}, a_{< t}) \| p(s_t | s_{t-1}, a_{t-1})]]}_{\text{复杂度}} \right).
 \end{aligned} \tag{8}$$

多步预测分布 d 步预测分布 $p_d(o_{1:T}, s_{1:T} | a_{1:T}) = \prod_t p(s_t | s_{t-d}, a_{t-d-1:t-2})p(o_t | s_t)$ 和变分后验 $q(s_{1:T} | o_{1:T}, a_{1:T}) = \prod_t q(s_t | o_{\leq t}, a_{< t})$ 的变分界类似可得。第二个界来自将对数移入多步先验内部，这些先验满足递推关系 $p(s_t | s_{t-d}, a_{t-d-1:t-1}) = \mathbb{E}_{p(s_{t-1}|s_{t-d}, a_{t-d-1:t-2})}[p(s_t | s_{t-1}, a_{t-1})]$ 。

$$\begin{aligned}
 \ln p_d(o_{1:T} | a_{1:T}) &\triangleq \ln \mathbb{E}_{p_d(s_{1:T}|a_{1:T})} \left[\prod_{t=1}^T p(o_t | s_t) \right] \\
 &= \ln \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\prod_{t=1}^T p(o_t | s_t) p(s_t | s_{t-d}, a_{t-d-1:t-1}) / q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &\geq \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\sum_{t=1}^T \ln p(o_t | s_t) + \ln p(s_t | s_{t-d}, a_{t-d-1:t-1}) - \ln q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &\geq \mathbb{E}_{q(s_{1:T}|o_{1:T}, a_{1:T})} \left[\sum_{t=1}^T \ln p(o_t | s_t) + \underbrace{\mathbb{E}_{p(s_{t-1}|s_{t-d}, a_{t-d-1:t-2})} [\ln p(s_t | s_{t-1}, a_{t-1})]}_{\text{多步预测}} - \ln q(s_t | o_{\leq t}, a_{< t}) \right] \\
 &= \sum_{t=1}^T \left(\underbrace{\mathbb{E}_{q(s_t|o_{\leq t}, a_{< t})} [\ln p(o_t | s_t)]}_{\text{重建}} - \underbrace{\mathbb{E}_{p(s_{t-1}|s_{t-d}, a_{t-d-1:t-2})q(s_{t-d}|o_{\leq t-d}, a_{< t-d})} [\text{KL}[q(s_t | o_{\leq t}, a_{< t}) \| p(s_t | s_{t-1}, a_{t-1})]]}_{\text{多步预测}} \right).
 \end{aligned} \tag{9}$$

由于所有期望都在目标的外部，我们可以通过将期望替换为样本平均来轻松获得此界的无偏估计量。

单步预测分布与多步预测分布之间的关系 我们推测多步预测分布 $p_d(o_{1:T})$ 在数据集上取期望后是同一潜在序列模型的单步预测分布 $p(o_{1:T})$ 的下界。由于潜在状态序列是 Markov 的，对于 $d \geq 1$ 我们有数据处理不等式

$$\begin{aligned}
 I(s_t; s_{t-d}) &\leq I(s_t; s_{t-1}) \\
 s_t - s_t | s_{t-d} &\leq s_t - s_t | s_{t-1} \\
 \mathbb{E}[\ln p(s_t | s_{t-d})] &\leq \mathbb{E}[\ln p(s_t | s_{t-1})] \\
 \mathbb{E}[\ln p_d(o_{1:T})] &\leq \mathbb{E}[\ln p(o_{1:T})].
 \end{aligned} \tag{10}$$

因此，多步预测分布的任何界，包括??和??，也是单步预测分布的界。

G. 额外相关工作

状态空间中的规划 当环境的低维状态对智能体可用时，可以直接在状态空间中学习动力学。在只有少量状态变量的控制任务中（如 cart pole 和 mountain car 任务），PILCO (?) 使用 Gaussian 过程建模动力学，实现了显著的采样效率。使用神经网络动力学模型的类似方法能够解决双连杆平衡问题 (??) 并通过梯度实现规划 (?)。?使用神经网络集成，扩展到 cheetah 奔跑任务。这些方法的局限在于它们需要访问底层系统的低维 Markov 状态，有时还需要奖励函数。?使用观测空间中的越步训练确定性模型，用于机器人手的主动探索。我们超越了低维状态表示，使用潜在动力学模型从图像中解决控制任务。

混合智能体 基于模型 RL 的挑战激励研究社区开发混合智能体，通过基于想象的训练经验来加速策略学习 (?????), 改进特征表示 (??), 或直接利用模型的信息内容 (?)。?使用强化学习且无需预测损失来学习具有集成规划计算的策略网络，但训练需要专家演示。

多步预测 在序列模型上训练多步预测已经被探索了多年。计划采样 (?) 在训练过程中改变序列模型的展开距离。幻觉回放 (?) 将预测混入数据集以间接训练多步预测。?采用模仿学习方法。最近，?同时在所有多步预测上训练动力学模型。我们将这一思想推广到通过变分推断训练的潜在序列模型。

潜在序列模型 经典工作已经探索了用于非 Markov 观测序列的模型，包括具有确定性隐藏状态的循环神经网络 (RNN) 和概率性状态空间模型 (SSM)。变分自编码器 (??) 背后的思想使通过变分推断训练的非线性 SSM 成为可能 (?)。VRNN (?) 结合了 RNN 和 SSM，并通过变分推断进行训练。与我们的 RSSM 不同，它将生成的观测反馈回模型，使得前向预测代价高昂。?通过限制转移函数来解决模式坍缩到单一未来的问题，?关注多模态转移，?稳定纯随机模型的训练。?提出了一个与我们的模型相似的模型，但用于混合智能体而非显式规划。

视频预测 视频预测是深度学习中的一个活跃研究领域。?和?使用确定性模型在 Atari 游戏上实现了视觉上合理的预测。?引入了一种使用门控 CNN 和 LSTM 的自回归视频预测模型。最近的方法将随机性引入模型以捕捉多种未来 (??)。为了获得真实的预测，?和?使用对抗损失。在模拟环境中，?通过外部记忆增强动力学模型以记住长期上下文。?提出了一种避免采样的变分模型，使用最近邻查找，产生高保真度的图像预测。这些模型与我们的方法是互补的。

H. 视频预测




Figure 10: 测试 episode 的开环视频预测。第 1-5 列显示重建的上下文帧，其余图像以开环方式生成。我们的 RSSM 在 cheetah 环境中实现了对未来 50 步的像素级精确预测。我们从使用动作噪声与训练 episode 并行收集的测试 episode 中随机选择了动作序列。

I. 状态诊断




Figure 11: 开环状态诊断。我们冻结一个，并学习小型神经网络来预测模拟器的真实位置、速度和奖励。这些量的开环预测表明，学习到的潜在空间中存在关于底层系统的大部分信息，并且可以精确地向前预测到比本工作中使用的规划视野更远的距离。

J. 规划参数




Figure 12: 使用真实模拟器在 cheetah 奔跑任务上的规划性能，采用不同的规划器设置。性能范围从 132（蓝色）到 837（黄色）。评估更多动作序列、优化更多迭代以及重新拟合到更少的最优候选倾向于提高性能。规划视野长度为 6 不够充分，导致性能较差。过长的规划视野由于搜索空间增大而损害性能。对于此环境，最优规划视野长度接近 8 步。