

DREAM TO CONTROL: 通过潜在想象学习行为

Danijar Hafner*
University of Toronto
Google Brain

Timothy Lillicrap
DeepMind

Jimmy Ba
University of Toronto

Mohammad Norouzi
Google Brain

Abstract

学习到的世界模型总结了智能体的经验，以便于学习复杂行为。虽然通过深度学习从高维感官输入学习世界模型正变得可行，但从中推导行为的方式有很多种。我们提出 Dreamer，一种仅通过潜在想象从图像中解决长时程任务的强化学习智能体。我们通过学习到的世界模型的紧凑状态空间中想象出的轨迹，反向传播学习到的状态值的解析梯度，从而高效地学习行为。在 20 个具有挑战性的视觉控制任务上，Dreamer 在数据效率、计算时间和最终性能方面均超越了现有方法。

1 引言

智能体可以在复杂环境中实现目标，即使它们从未两次遇到完全相同的情况。这种能力需要从过去的经验中构建世界表征，从而能够推广到新情境。世界模型提供了一种显式的方式，将智能体关于世界的知识表示为一个参数化模型，该模型可以对未来做出预测。

当感官输入是高维图像时，潜在动力学模型可以抽象观测结果，在紧凑的状态空间中进行前向预测 (Watter et al., 2015; Oh et al., 2017; Gregor et al., 2019)。与图像空间中的预测相比，潜在状态具有较小的内存占用，能够并行想象数千条轨迹。通过深度学习和潜变量模型的进展，学习有效的潜在动力学模型正变得可行 (Krishnan et al., 2015; Karl et al., 2016; Doerr et al., 2018; Buesing et al., 2018)。

从动力学模型中推导行为的方式有很多种。通常，想象奖励通过参数化策略 (Sutton, 1991; Ha and Schmidhuber, 2018; Zhang et al., 2019) 或在线规划 (Chua et al., 2018; Hafner et al., 2018) 来最大化。然而，仅考虑固定想象视野内的奖励会导致短视行为 (Wang et al., 2019)。此外，先前的工作通常采用无导数优化来应对模型误差 (Ebert et al., 2017; Chua et al., 2018; Parmas et al., 2019)，而不是利用神经网络动力学提供的解析梯度 (Henaff et al., 2019; Srinivas et al., 2018)。

我们提出 Dreamer，一种仅通过潜在想象从图像中学习长时程行为的智能体。一种新颖的 Actor-Critic 算法能够考虑超出想象视野的奖励，同时高效利用神经网络动力学。为此，我们在学习到的潜在空间中预测状态值和动作，如 Figure 1 所示。值函数优化想象奖励的贝尔曼一致性，策略通过将解析梯度反向传播通过动力学来最大化值函数。

与通过在线学习或经验回放学习的 Actor-Critic 算法 (Lillicrap et al., 2015; Mnih et al., 2016; Schulman et al., 2017; Haarnoja et al., 2018; Lee et al., 2019) 相比，世界模型可以插值过去的经验，并提供多步回报的解析梯度以实现高效的策略优化。

*Correspondence to: Danijar Hafner <mail@danijar.com>.




Figure 1: Dreamer from past experience learns world model, and through backward propagation of value estimates along imagined trajectories, learns to act efficiently in its latent space.




Figure 2: 我们实验中使用的 20 个视觉控制任务中的 5 个的图像观测。这些任务提出了各种挑战，包括接触动力学、稀疏奖励、多自由度和 3D 环境。其中几个任务以前无法通过世界模型解决。

本文的主要贡献总结如下：

- 通过潜在想象学习长时程行为 基于模型的智能体如果使用有限的想象视野可能是短视的。我们通过同时预测动作和状态值来解决这一局限性。完全在潜在空间中通过想象进行训练，使我们能够通过将解析值梯度反向传播通过潜在动力学来高效地学习策略。
- 视觉控制的经验性能 我们将 Dreamer 与现有的表征学习方法结合，并在 DeepMind 控制套件上以图像输入进行评估，如 Figure 2 所示。在所有任务上使用相同的超参数，Dreamer 在数据效率、计算时间和最终性能方面均超越了之前的基于模型和无模型智能体。

2 使用世界模型进行控制

强化学习 我们将视觉控制形式化为一个部分可观测马尔可夫决策过程 (POMDP)，具有离散时间步 $t \in [1; T]$ ，由智能体生成的连续向量值动作 $a_t \sim p(a_t | o_{\leq t}, a_{< t})$ ，以及由未知环境生成的高维观测和标量奖励 $o_t, r_t \sim p(o_t, r_t | o_{\leq t}, a_{< t})$ 。目标是开发一个最大化期望奖励总和 $E_p(\sum_{t=1}^T r_t)$ 的智能体。Figure 2 展示了我们任务的一个子集。

智能体组件 在想象中学习的智能体的经典组件是动力学学习、行为学习和环境交互 (Sutton, 1991)。在 Dreamer 的情况下，行为是通过在世界模型的紧凑潜在空间中预测假设轨迹来学习的。如 Figure 3 概述和 Algorithm 1 详细描述，Dreamer 在智能体的整个生命周期中执行以下操作，可以交替进行或并行执行：

- 从过去经验的数据集中学习潜在动力学模型，以从动作和过去的观测中预测未来奖励。任何世界模型的学习目标都可以与 Dreamer 结合使用。我们在 Section 4 中回顾了现有的潜在动力学学习方法。
- 从预测的潜在轨迹中学习动作和值模型，如 Section 3 所述。值模型优化想象奖励的贝尔曼一致性，动作模型通过将值估计的梯度反向传播通过神经网络动力学来更新。
- 在真实世界中执行学习到的动作模型，以收集新的经验来扩充数据集。

潜在动力学 Dreamer 使用由三个组件组成的潜在动力学模型。表征模型编码观测和动作以创建具有马尔可夫转移的连续向量值模型状态 s_t (Watter et al., 2015; Zhang et al., 2019; Hafner et al., 2018)。转移模型预测未来的模型状态，而不需要看到随后将导致这些状态的相应观测。奖励模型根据模型状态预测奖励，

$$\begin{aligned}
 \text{表征模型:} & \quad p(s_t | s_{t-1}, a_{t-1}, o_t) \\
 \text{转移模型:} & \quad q(s_t | s_{t-1}, a_{t-1}) \\
 \text{奖励模型:} & \quad q(r_t | s_t).
 \end{aligned} \tag{1}$$

我们使用 p 表示在真实环境中生成样本的分布，使用 q 表示其近似分布，以实现潜在想象。具体而言，转移模型使我们能够在紧凑的潜在空间中进行前向预测，而无需观察或想象相应的图像。这导致了低内存占用和数千条想象轨迹的快速并行预测。

该模型类似于非线性卡尔曼滤波器 (Kalman, 1960)、潜在状态空间模型或具有实值状态的 HMM。然而，它以动作为条件并预测奖励，使智能体能够在不在环境中执行的情况下，想象潜在动作序列的结果。




Figure 3: Dreamer 的组件。(a) 从过去经验的数据集中，智能体学习将观测和动作编码为紧凑的潜在状态 (●)，例如通过重建，并预测环境奖励 (●)。 (b) 在紧凑的潜在空间中，Dreamer 预测状态值 (●) 和动作 (●)，通过将梯度反向传播通过想象轨迹来最大化未来的值预测。(c) 智能体编码回合的历史以计算当前模型状态，并预测要在环境中执行的下一个动作。智能体的伪代码见 Algorithm 1。

3 通过潜在想象学习行为

Dreamer 通过学习到的世界模型的紧凑潜在空间中学习长时程行为，高效地利用神经网络潜在动力学。为此，我们使用重参数化技术，将多步回报的随机梯度通过动作、状态、奖励和值的神经网络预测进行反向传播。本节描述了我们论文的主要贡献。

想象环境 潜在动力学定义了一个马尔可夫决策过程 (MDP; Sutton, 1991)，由于紧凑的模型状态 s_t 是马尔可夫的，因此该过程是完全可观测的。我们用 τ 作为时间索引表示想象量。想象轨迹从智能体过去经验中抽取的观测序列的真实模型状态 s_t 出发。它们遵循转移模型 $s_\tau \sim q(s_\tau | s_{\tau-1}, a_{\tau-1})$ 、奖励模型 $r_\tau \sim q(r_\tau | s_\tau)$ 和策略 $a_\tau \sim q(a_\tau | s_\tau)$ 的预测。目标是针对策略最大化期望想象奖励 $E_q(\sum_{\tau=t}^{\infty} \gamma^{\tau-t} r_\tau)$ 。

Algorithm 1: Dreamer 算法

用 S 个随机种子回合初始化数据集 $\mathcal{D}$ 。

随机初始化神经网络参数 θ, ϕ, ψ 。

while 未收敛 **do**

for 更新步 $c = 1..C$ **do**

 // 动力学学习

 抽取 B 个数据序列 $\{(a_t, o_t, r_t)\}_{t=k}^{k+L} \sim \mathcal{D}$ 。

 计算模型状态 $s_t \sim p_\theta(s_t | s_{t-1}, a_{t-1}, o_t)$ 。

 使用表征学习更新 θ 。

 // 行为学习

 从每个 s_t 想象轨迹 $\{(s_\tau, a_\tau)\}_{\tau=t}^{t+H}$ 。

 预测奖励 $E(q_\theta(r_\tau | s_\tau))$ 和值 $v_\psi(s_\tau)$ 。

 通过 Equation 6 计算值估计 $V_\lambda(s_\tau)$ 。

 更新 $\phi \leftarrow \phi + \alpha \nabla_\phi \sum_{\tau=t}^{t+H} V_\lambda(s_\tau)$ 。

 更新 $\psi \leftarrow \psi - \alpha \nabla_\psi \sum_{\tau=t}^{t+H} \frac{1}{2} \|v_\psi(s_\tau) - V_\lambda(s_\tau)\|^2$ 。

 // 环境交互

$o_1 \leftarrow \text{env.reset}()$

for 步 $t = 1..T$ **do**

 从历史计算 $s_t \sim p_\theta(s_t | s_{t-1}, a_{t-1}, o_t)$ 。

 用动作模型计算 $a_t \sim q_\phi(a_t | s_t)$ 。

 向动作添加探索噪声。

$r_t, o_{t+1} \leftarrow \text{env.step}(a_t)$ 。

 将经验添加到数据集 $\mathcal{D} \leftarrow \mathcal{D} \cup \{(o_t, a_t, r_t)\}_{t=1}^T$ 。

模型组件

表征 $p_\theta(s_t | s_{t-1}, a_{t-1}, o_t)$

转移 $q_\theta(s_t | s_{t-1}, a_{t-1})$

奖励 $q_\theta(r_t | s_t)$

动作 $q_\phi(a_t | s_t)$

值 $v_\psi(s_t)$

超参数

种子回合数 S

收集间隔 C

批次大小 B

序列长度 L

想象视野 H

学习率 α




Figure 4: 想象视野。我们比较了 Dreamer、学习无值预测的动作模型以及使用 PlaNet 进行在线规划的最终性能。学习状态值模型来估计超出想象视野的奖励使 Dreamer 对视野长度更具鲁棒性。智能体使用像素重建进行表征学习，动作重复为 $R = 2$ 。

动作和值模型 考虑具有有限视野 H 的想象轨迹。Dreamer 使用 Actor-Critic 方法来学习考虑视野之外奖励的行为。为此，我们在世界模型的潜在空间中学习动作模型和值模型。动作模型实现策略，旨在预测解决想象环境的动作。值模型估计动作模型从每个状态 s_τ 所能达到的期望想象奖励，

$$\begin{aligned} \text{动作模型:} \quad & a_\tau \sim q_\phi(a_\tau | s_\tau) \\ \text{值模型:} \quad & v_\psi(s_\tau) \approx \mathbb{E}_{q(\cdot|s_\tau)} \left(\sum_{\tau=t}^{t+H} \gamma^{\tau-t} r_\tau \right). \end{aligned} \quad (2)$$

动作模型和值模型以策略迭代的典型方式进行协同训练：动作模型旨在最大化值的估计，而值模型旨在匹配随动作模型变化而变化的值的估计。

我们使用具有参数 ϕ 和 ψ 的密集神经网络分别实现动作模型和值模型。动作模型输出一个经过 $\tanh$ 变换的高斯分布 (Haarnoja et al., 2018)，其充分统计量由神经网络预测。这允许重参数化采样 (Kingma and Welling, 2013; Rezende et al., 2014)，将采样的动作视为对神经网络输出的确定性依赖，使我们能够通过采样操作反向传播解析梯度，

$$a_\tau = \tanh(\mu_\phi(s_\tau) + \sigma_\phi(s_\tau) \epsilon), \quad \epsilon \sim \text{Normal}(0, \mathbb{I}). \quad (3)$$

值估计 为了学习动作和值模型，我们需要估计想象轨迹 $\{s_\tau, a_\tau, r_\tau\}_{\tau=t}^{t+H}$ 的状态值。这些轨迹从智能体经验数据集中抽取的序列批次的模型状态 s_t 分支出来，并使用从动作模型中采样的动作前向预测想象视野 H 。状态值可以通过多种方式进行估计，这些方式在偏差和方差之间进行权衡 (Sutton and Barto, 2018)，

$$V_R(s_\tau) \doteq \mathbb{E}_{q_\theta, q_\phi} \left(\sum_{n=\tau}^{t+H} r_n \right), \quad (4)$$

$$V_N^k(s_\tau) \doteq \mathbb{E}_{q_\theta, q_\phi} \left(\sum_{n=\tau}^{h-1} \gamma^{n-\tau} r_n + \gamma^{h-\tau} v_\psi(s_h) \right) \quad \text{其中} \quad h = \min(\tau + k, t + H), \quad (5)$$

$$V_\lambda(s_\tau) \doteq (1 - \lambda) \sum_{n=1}^{H-1} \lambda^{n-1} V_N^n(s_\tau) + \lambda^{H-1} V_N^H(s_\tau), \quad (6)$$

其中期望是在想象轨迹下估计的。 V_R 简单地将从 τ 到视野结束的奖励求和，并忽略视野之外的奖励。这允许在没有值模型的情况下学习动作模型，我们在实验中与此消融进行了比较。 V_N^k 使用学习到的值模型估计超过 k 步的奖励。Dreamer 使用 V_λ ，即对不同 k 的估计进行指数加权平均，以平衡偏差和方差。Figure 4 显示，在想象中学习值模型使 Dreamer 能够解决长时程任务，同时对想象视野具有鲁棒性。所有任务的实验细节和结果在 Section 6 中描述。




Figure 5: 长期预测的重建。我们将表征模型应用于两条保留轨迹的前 5 张图像，并仅给定动作，使用潜在动力学前向预测 45 步。循环状态空间模型 (RSSM; Hafner et al., 2018) 执行准确的长期预测，使 Dreamer 能够在紧凑的潜在空间中学习成功的行为。

学习目标 为了更新动作和值模型，我们首先计算想象轨迹上所有状态 s_τ 的值估计 $V_\lambda(s_\tau)$ 。动作模型 $q_\phi(a_\tau | s_\tau)$ 的目标是预测导致具有高值估计的状态轨迹的动作。值模型 $v_\psi(s_\tau)$ 的目标则是回归这些值估计，

$$\max_{\phi} \mathbb{E}_{q_{\theta}, q_{\phi}} \left(\sum_{\tau=t}^{t+H} V_{\lambda}(s_{\tau}) \right), \quad (7) \quad \min_{\psi} \mathbb{E}_{q_{\theta}, q_{\phi}} \left(\sum_{\tau=t}^{t+H} \frac{1}{2} \|v_{\psi}(s_{\tau}) - V_{\lambda}(s_{\tau})\|^2 \right). \quad (8)$$

值模型通过回归目标进行更新，我们对目标停止梯度传播，一如通常做法 (Sutton and Barto, 2018)。动作模型使用通过学习到的动力学的解析梯度来最大化值估计。为了理解这一点，我们注意到值估计依赖于奖励和值预测，后者依赖于想象状态，而想象状态又依赖于想象动作。由于所有步骤都通过神经网络实现，我们通过随机反向传播 (Kingma and Welling, 2013; Rezende et al., 2014) 解析地计算 $\nabla_{\phi} \mathbb{E}_{q_{\theta}, q_{\phi}} \left(\sum_{\tau=t}^{t+H} V_{\lambda}(s_{\tau}) \right)$ 。我们对连续动作和潜在状态使用重参数化，对离散动作使用直通梯度 (Bengio et al., 2013)。在学习行为时世界模型保持固定。

在具有提前终止的任务中，世界模型还从每个潜在状态预测折扣因子，以通过预测折扣因子的累积乘积来加权 Equations 7 and 8 中的时间步，从而根据想象轨迹可能已经结束的可能性对各项进行降权。

与 Actor-Critic 方法的比较 使用 Reinforce 梯度的智能体 (Williams, 1992)，如 A3C 和 PPO (Mnih et al., 2016; Schulman et al., 2017)，采用值基线来减少梯度方差，而 Dreamer 通过值模型进行反向传播。这类似于确定性或重参数化的 Actor-Critic 方法 (Silver et al., 2014)，如 DDPG 和 SAC (Lillicrap et al., 2015; Haarnoja et al., 2018)。然而，这些方法没有利用通过转移的梯度，仅最大化即时 Q 值。MVE 和 STEVE (Feinberg et al., 2018; Buckman et al., 2018) 将它们扩展到使用学习到的动力学的多步 Q 学习，以提供更准确的 Q 值目标。我们预测状态值，这足以进行策略优化，因为我们通过动力学进行反向传播。更详细的比较参见 Section 5。

4 学习潜在动力学

在想象中学习行为需要一个泛化良好的世界模型。我们专注于在紧凑潜在空间中进行前向预测的潜在动力学模型，这有助于长期预测，并使智能体能够并行想象数千条轨迹。已有多用于控制任务的表征学习目标被提出 (Watter et al., 2015; Jaderberg et al., 2016; Oord et al., 2018;




Figure 6: 与现有方法的性能比较。Dreamer 继承了 PlaNet 的数据效率，同时超越了最佳无模型智能体的渐近性能。在 5×10^6 环境步后，Dreamer 跨任务平均性能达到 823，相比之下 PlaNet 为 332，而顶级无模型 D4PG 智能体在 10^8 步后为 786。结果为 5 个随机种子的平均值。




Figure 7: Dreamer 在需要长时程信用分配的视觉控制任务上取得成功，例如 acrobot 和 hopper 任务。仅通过动作模型或在线规划在视野内优化想象奖励会产生短视行为，只能在反应性任务中成功，例如 walker 领域。所有 20 个任务的性能总结在 Figure 6 中，训练曲线显示在 Section D 中。D4PG 和 A3C 的性能曲线见 Tassa et al. (2018)。

Eslami et al., 2018)。我们回顾了三种用于 Dreamer 的表征学习方法：奖励预测、图像重建和对比估计。

奖励预测 潜在想象需要一个表征模型 $p(s_t | s_{t-1}, a_{t-1}, o_t)$ 、转移模型 $q(s_t | s_{t-1}, a_{t-1}, o_t)$ 和奖励模型 $q(r_t | s_t)$ ，如 Section 2 所述。原则上，这可以通过简单地学习从给定动作和过去观测中预测未来奖励来实现 (Oh et al., 2017; Gelada et al., 2019; Schrittwieser et al., 2019)。如果数据集足够大且多样化，这样的表征应该足以解决控制任务。然而，在有限数据集下，尤其是奖励稀疏时，学习与奖励相关的观测信息可能会改善世界模型 (Jaderberg et al., 2016; Gregor et al., 2019)。

重建 我们首先描述 PlaNet (Hafner et al., 2018) 使用的世界模型，它通过重建图像来学习潜在动力学，如 Figure 3a 所示。世界模型由以下组件组成，其中观测模型仅用于提供学习信号，

$$\begin{aligned}
 \text{表征模型:} & p_{\theta}(s_t | s_{t-1}, a_{t-1}, o_t) \\
 \text{观测模型:} & q_{\theta}(o_t | s_t) \\
 \text{奖励模型:} & q_{\theta}(r_t | s_t) \\
 \text{转移模型:} & q_{\theta}(s_t | s_{t-1}, a_{t-1}).
 \end{aligned} \tag{9}$$

这些组件被联合优化以增加变分下界 (ELBO; Jordan et al., 1999)，或更一般地说，变分信息瓶颈 (VIB; Tishby et al., 2000; Alemi et al., 2016)。如 Section B 中所推导，该下界包括观测和奖励的重建项以及一个 KL 正则化项。期望在数据集和表征模型下取值，

$$\begin{aligned}
 \mathcal{J}_{\text{REC}} & \doteq \mathbb{E}_p \left(\sum_t \left(\mathcal{J}_O^t + \mathcal{J}_R^t + \mathcal{J}_D^t \right) \right) + \text{const} & \mathcal{J}_O^t & \doteq -\ln q(o_t | s_t) \\
 \mathcal{J}_R^t & \doteq \ln q(r_t | s_t) & \mathcal{J}_D^t & \doteq -\beta \text{KL} \left(p(s_t | s_{t-1}, a_{t-1}, o_t) \parallel q(s_t | s_{t-1}, a_{t-1}) \right).
 \end{aligned} \tag{10}$$

我们将转移模型实现为循环状态空间模型 (RSSM; Hafner et al., 2018)，表征模型通过将 RSSM 与应用于图像观测的卷积神经网络 (CNN; LeCun et al., 1989) 相结合来实现，观测模型实现为转置 CNN，奖励模型实现为密集网络。联合参数向量 θ 通过随机反向传播 (Kingma and Welling, 2013; Rezende et al., 2014) 进行更新。Figure 5 展示了该模型的视频预测。模型细节参见 Section A 和 Hafner et al. (2018)。

对比估计 预测像素可能需要很高的模型容量。我们也可以通过从图像中预测状态来鼓励模型状态与观测之间的互信息 (Guo et al., 2018)。这用状态模型替代了观测模型，

$$\text{状态模型:} \quad q_{\theta}(s_t | o_t). \tag{11}$$

虽然重建目标利用了观测边缘分布是常数这一事实，但现在我们面对的是状态边缘分布。如 Section B 所示，这可以通过噪声对比估计 (NCE; Gutmann and Hyvärinen, 2010; Oord et al., 2018) 来估计，即对当前序列批次中的观测 o' 平均状态模型。直观上， $q(s_t | o_t)$ 使状态可以从当前图像中预测，而 $\ln \sum_{o'} q(s_t | o')$ 保持其多样性以防止坍塌，

$$\mathcal{J}_{\text{NCE}} \doteq \mathbb{E} \left(\sum_t \left(\mathcal{J}_S^t + \mathcal{J}_R^t + \mathcal{J}_D^t \right) \right) \quad \mathcal{J}_S^t \doteq \ln q(s_t | o_t) - \ln \left(\sum_{o'} q(s_t | o') \right). \tag{12}$$

我们将状态模型实现为 CNN，并再次使用随机反向传播针对联合参数向量 θ 优化该下界。虽然避免了像素预测，但该下界可以有效提取的信息量是有限的 (McAllester and Statos, 2018)。我们在 Figure 8 的实验中奖励、重建和对比目标进行了经验比较。

5 相关工作

先前的工作通过无导数策略学习或在线规划学习潜在动力学以进行视觉控制，用多步预测增强无模型智能体，或使用 Q 值或多步奖励的解析梯度，通常用于低维任务。相比之下，Dreamer 使用解析梯度高效地仅通过潜在想象为视觉控制学习长时程行为。

使用潜在动力学的控制 E2C (Watter et al., 2015) 和 RCE (Banijamali et al., 2017) 将图像嵌入到紧凑空间中，以进行前向预测并解决简单任务。World Models (Ha and Schmidhuber, 2018) 以两阶段过程学习潜在动力学，在想象中演化线性控制器。PlaNet (Hafner et al., 2018) 联合学习它们，并通过潜在在线规划解决视觉运动任务。SOLAR (Zhang et al., 2019) 通过潜在空间中的引导策略搜索解决机器人任务。I2A (Weber et al., 2017) 将想象轨迹交给无模型策略，而 Lee et al. (2019) 和 Gregor et al. (2019) 学习信念表征以加速无模型智能体。

想象的多步回报 VPN (Oh et al., 2017)、MVE (Feinberg et al., 2018) 和 STEVE (Buckman et al., 2018) 学习动力学以从经验回放缓冲区进行多步 Q 学习。AlphaGo (Silver et al., 2017) 将动作预测和状态值与规划相结合，假设可以访问真实动力学。同样假设可以访问动力学的 POLO (Lowrey et al., 2018) 通过学习值集成来规划探索。MuZero (Schrittwieser et al., 2019) 学习任务特定的奖励和值模型来解决具有挑战性的任务，但需要大量经验。PETS (Chua et al., 2018)、VisualMPC (Ebert et al., 2017) 和 PlaNet (Hafner et al., 2018) 使用无导数优化进行在线规划。POPLIN (Wang and Ba, 2019) 通过自模仿改善了在线规划。Piergiovanni et al. (2018) 通过潜在动力学模型进行想象来学习机器人策略。使用神经网络梯度进行规划在小问题上已得到展示 (Schmidhuber, 1990; Henaff et al., 2018)，但一直难以扩展到更大规模 (Parmas et al., 2019)。

解析值梯度 DPG (Silver et al., 2014)、DDPG (Lillicrap et al., 2015) 和 SAC (Haarnoja et al., 2018) 利用学习到的即时动作值的梯度, 通过经验回放来学习策略。SVG (Heess et al., 2015) 通过单步模型预测的解析值梯度来降低无模型在线策略算法的方差。Byravan et al. (2019) 的同期工作使用确定性模型的潜在想象进行导航和操控任务。ME-TRPO (Kurutach et al., 2018) 通过本体感觉输入的预测奖励梯度来加速原本是无模型的智能体。DistGBP (Henaff et al., 2017; 2019) 在简单任务中使用模型梯度进行在线规划。




Figure 8: 用于 Dreamer 的表征学习目标的比较。像素重建在大多数任务上表现最佳。对比目标解决了约一半的任务，而在我们的实验中仅预测奖励是不够的。结果表明，未来表征学习的发展很可能转化为 Dreamer 任务性能的提升。所有任务的性能曲线包含在 Section E 中。

6 实验

我们在各种控制任务上对 Dreamer 进行了实验评估。我们设计了实验以比较 Dreamer 与文献中当前最佳方法，并评估其解决长时程、连续动作、离散动作和提前终止任务的能力。我们进一步比较了世界模型学习目标的正交选择。我们所有实验的源代码和 Dreamer 视频可在 <https://danijar.com/dreamer> 获取。

控制任务 我们在 DeepMind 控制套件 (Tassa et al., 2018) 的 20 个视觉控制任务上评估了 Dreamer，如 Figure 2 所示。这些任务提出了各种挑战，包括稀疏奖励、接触动力学和 3D 场景。我们选择了 Tassa et al. (2018) 报告的从图像输入中获得非零性能的任务。智能体的观测是形状为 $64 \times 64 \times 3$ 的图像，动作维度从 1 到 12，奖励范围从 0 到 1，回合持续 1000 步并具有随机的初始状态。我们跨任务使用固定的动作重复 $R = 2$ 。我们进一步在 Atari 游戏 (Bellemare et al., 2013) 和 DeepMind Lab 关卡 (Beattie et al., 2016) 的子集上评估了 Dreamer 对离散动作和提前终止的适用性，详见 Section C。

实现 我们的实现使用 TensorFlow Probability (Dillon et al., 2017)。每个训练运行使用单块 Nvidia V100 GPU 和 10 个 CPU 核心。我们的 Dreamer 实现在控制套件上每 10^6 环境步的训练时间约为 3 小时，相比之下，使用 PlaNet 进行在线规划需要 11 小时，D4PG 达到类似性能需要 24 小时。我们在所有连续任务上使用相同的超参数，在所有离散任务上也类似，详见 Section A。除非特别说明，世界模型通过重建学习。

基线方法 在连续任务上报告的最高性能由 D4PG (Barth-Maron et al., 2018) 实现，它是 DDPG (Lillicrap et al., 2015) 的改进变体，使用了分布式收集、分布 Q 学习、多步回报和优先经验回放。我们包括来自 Tassa et al. (2018) 的像素输入 D4PG 和状态输入 A3C (Mnih et al., 2016) 的分数。PlaNet (Hafner et al., 2018) 学习与 Dreamer 相同的世界模型，并通过在线规划选择动作（无动作模型），在数据效率上大幅超越 D4PG 和 A3C。我们以 $R = 2$ 重新运行 PlaNet 以统一实验设置。对于 Atari，我们展示了 Castro et al. (2018) 报告的 SimPLe (Kaiser et al., 2019)、DQN (Mnih et al., 2015) 和 Rainbow (Hessel et al., 2018) 的最终性能，对于 DeepMind Lab 则展示 IMPALA (Espeholt et al., 2018) 的性能作为参考。

性能 为了评估 Dreamer 的性能，我们将其与最先进的强化学习智能体进行比较。结果总结在 Figure 6 中。在 5×10^6 环境步后，Dreamer 跨任务平均分数为 823，超过了强大的无模型 D4PG 智能体在 10^8 环境步内达到的 786 平均分数。同时，Dreamer 继承了 PlaNet 的数据效率，证实了学习到的世界模型有助于从少量经验中进行泛化。Dreamer 的经验成功表明，通过世界模型的潜在想象学习行为可以超越基于经验回放的顶级方法。

长时程 为了研究其学习长时程行为的能力，我们在各种视野长度下比较了 Dreamer 与从世界模型推导行为的替代方案。为此，我们学习了一个动作模型以在没有值模型的情况下最大化想象奖励，并与使用 PlaNet 的在线规划进行比较。Figure 4 显示了不同想象视野下的最终性能，证实了值模型使 Dreamer 对视野更具鲁棒性，即使在短视野下也表现良好。视野为 20 时所有 19 个任务的性能曲线显示在 Section D 中，其中 Dreamer 在 20 个任务中的 16 个上优于替代方案，4 个平局。

表征学习 Dreamer 可以与任何给定动作和过去观测预测未来奖励的可微动力学模型一起使用。由于表征学习目标与我们的算法是正交的，我们比较了 Section 4 中描述的三种自然选择：像素重建、对比估计和纯奖励预测。Figure 8 显示了不同表征学习方法在任务性能上的明显差异，像素重建在大多数任务上优于对比估计。这表明，未来在表征学习方面的改进很可能转化为 Dreamer 更高的任务性能。在我们的实验中，仅使用奖励预测是不足够的。更多消融实验包含在论文附录中。

7 结论

我们提出 Dreamer，一种仅通过潜在想象学习长时程行为的智能体。为此，我们提出了一种 Actor-Critic 方法，通过将多步值的解析梯度反向传播通过学习到的潜在动力学来优化参数化策略。Dreamer 在多种具有挑战性的图像输入连续控制任务上，在数据效率、计算时间和最终性能方面均优于先前的方法。我们进一步表明 Dreamer 适用于具有离散动作和提前回合终止的任务。未来的表征学习研究有望将潜在想象扩展到视觉复杂度更高的环境中。

致谢 我们感谢 Simon Kornblith、Benjamin Eysenbach、Ian Fischer、Amy Zhang、Geoffrey Hinton、Shane Gu、Adam Kosiorek、Brandon Amos、Jacob Buckman、Calvin Luo、Rishabh Agarwal 以及匿名审稿人的反馈和讨论。我们感谢 Yuval Tassa 为控制套件添加了四足环境。

REFERENCES

- A. A. Alemi, I. Fischer, J. V. Dillon, and K. Murphy. Deep variational information bottleneck. *arXiv preprint arXiv:1612.00410*, 2016.
- E. Banijamali, R. Shu, M. Ghavamzadeh, H. Bui, and A. Ghodsi. Robust locally-linear controllable embedding. *arXiv preprint arXiv:1710.05373*, 2017.
- G. Barth-Maron, M. W. Hoffman, D. Budden, W. Dabney, D. Horgan, A. Muldal, N. Heess, and T. Lillicrap. Distributed distributional deterministic policy gradients. *arXiv preprint arXiv:1804.08617*, 2018.
- C. Beattie, J. Z. Leibo, D. Teplyaev, T. Ward, M. Wainwright, H. Küttler, A. Lefrancq, S. Green, V. Valdés, A. Sadik, et al. Deepmind lab. *arXiv preprint arXiv:1612.03801*, 2016.
- M. G. Bellemare, Y. Naddaf, J. Veness, and M. Bowling. The arcade learning environment: An evaluation platform for general agents. *Journal of Artificial Intelligence Research*, 47: 253–279, 2013.
- Y. Bengio, N. Léonard, and A. Courville. Estimating or propagating gradients through stochastic neurons for conditional computation. *arXiv preprint arXiv:1308.3432*, 2013.
- J. Buckman, D. Hafner, G. Tucker, E. Brevdo, and H. Lee. Sample-efficient reinforcement learning with stochastic ensemble value expansion. In *Advances in Neural Information Processing Systems*, pages 8224–8234, 2018.
- L. Buesing, T. Weber, S. Racaniere, S. Eslami, D. Rezende, D. P. Reichert, F. Viola, F. Besse, K. Gregor, D. Hassabis, et al. Learning and querying fast generative models for reinforcement learning. *arXiv preprint arXiv:1802.03006*, 2018.
- A. Byravan, J. T. Springenberg, A. Abdolmaleki, R. Hafner, M. Neunert, T. Lampe, N. Siegel, N. Heess, and M. Riedmiller. Imagined value gradients: Model-based policy optimization with transferable latent dynamics models. *arXiv preprint arXiv:1910.04142*, 2019.
- P. S. Castro, S. Moitra, C. Gelada, S. Kumar, and M. G. Bellemare. Dopamine: A research framework for deep reinforcement learning. *arXiv preprint arXiv:1812.06110*, 2018.
- K. Chua, R. Calandra, R. McAllister, and S. Levine. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. In *Advances in Neural Information Processing Systems*, pages 4754–4765, 2018.
- D.-A. Clevert, T. Unterthiner, and S. Hochreiter. Fast and accurate deep network learning by exponential linear units (elus). *arXiv preprint arXiv:1511.07289*, 2015.
- J. V. Dillon, I. Langmore, D. Tran, E. Brevdo, S. Vasudevan, D. Moore, B. Patton, A. Alemi, M. Hoffman, and R. A. Saurous. Tensorflow distributions. *arXiv preprint arXiv:1711.10604*, 2017.
- A. Doerr, C. Daniel, M. Schiegg, D. Nguyen-Tuong, S. Schaal, M. Toussaint, and S. Trimpe. Probabilistic recurrent state-space models. *arXiv preprint arXiv:1801.10395*, 2018.
- F. Ebert, C. Finn, A. X. Lee, and S. Levine. Self-supervised visual planning with temporal skip connections. *arXiv preprint arXiv:1710.05268*, 2017.
- S. A. Eslami, D. J. Rezende, F. Besse, F. Viola, A. S. Morcos, M. Garnelo, A. Ruderman, A. A. Rusu, I. Danihelka, K. Gregor, et al. Neural scene representation and rendering. *Science*, 360(6394):1204–1210, 2018.
- L. Espeholt, H. Soyer, R. Munos, K. Simonyan, V. Mnih, T. Ward, Y. Doron, V. Firoiu, T. Harley, I. Dunning, et al. Impala: Scalable distributed deep-rl with importance weighted actor-learner architectures. *arXiv preprint arXiv:1802.01561*, 2018.

- V. Feinberg, A. Wan, I. Stoica, M. I. Jordan, J. E. Gonzalez, and S. Levine. Model-based value estimation for efficient model-free reinforcement learning. *arXiv preprint arXiv:1803.00101*, 2018.
- C. Gelada, S. Kumar, J. Buckman, O. Nachum, and M. G. Bellemare. Deepmdp: Learning continuous latent space models for representation learning. *arXiv preprint arXiv:1906.02736*, 2019.
- K. Gregor, D. J. Rezende, F. Besse, Y. Wu, H. Merzic, and A. v. d. Oord. Shaping belief states with generative environment models for rl. *arXiv preprint arXiv:1906.09237*, 2019.
- Z. D. Guo, M. G. Azar, B. Piot, B. A. Pires, T. Pohlen, and R. Munos. Neural predictive belief representations. *arXiv preprint arXiv:1811.06407*, 2018.
- M. Gutmann and A. Hyvärinen. Noise-contrastive estimation: A new estimation principle for unnormalized statistical models. In *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*, pages 297–304, 2010.
- D. Ha and J. Schmidhuber. World models. *arXiv preprint arXiv:1803.10122*, 2018.
- T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. *arXiv preprint arXiv:1801.01290*, 2018.
- D. Hafner, T. Lillicrap, I. Fischer, R. Villegas, D. Ha, H. Lee, and J. Davidson. Learning latent dynamics for planning from pixels. *arXiv preprint arXiv:1811.04551*, 2018.
- N. Heess, G. Wayne, D. Silver, T. Lillicrap, T. Erez, and Y. Tassa. Learning continuous control policies by stochastic value gradients. In *Advances in Neural Information Processing Systems*, pages 2944–2952, 2015.
- M. Henaff, W. F. Whitney, and Y. LeCun. Model-based planning in discrete action spaces. *CoRR*, abs/1705.07177, 2017.
- M. Henaff, W. F. Whitney, and Y. LeCun. Model-based planning with discrete and continuous actions. *arXiv preprint arXiv:1705.07177*, 2018.
- M. Henaff, A. Canziani, and Y. LeCun. Model-predictive policy learning with uncertainty regularization for driving in dense traffic. *arXiv preprint arXiv:1901.02705*, 2019.
- M. Hessel, J. Modayil, H. Van Hasselt, T. Schaul, G. Ostrovski, W. Dabney, D. Horgan, B. Piot, M. Azar, and D. Silver. Rainbow: Combining improvements in deep reinforcement learning. In *Thirty-Second AAAI Conference on Artificial Intelligence*, 2018.
- M. Jaderberg, V. Mnih, W. M. Czarnecki, T. Schaul, J. Z. Leibo, D. Silver, and K. Kavukcuoglu. Reinforcement learning with unsupervised auxiliary tasks. *arXiv preprint arXiv:1611.05397*, 2016.
- M. I. Jordan, Z. Ghahramani, T. S. Jaakkola, and L. K. Saul. An introduction to variational methods for graphical models. *Machine learning*, 37(2):183–233, 1999.
- L. Kaiser, M. Babaeizadeh, P. Milos, B. Osinski, R. H. Campbell, K. Czechowski, D. Erhan, C. Finn, P. Kozakowski, S. Levine, et al. Model-based reinforcement learning for atari. *arXiv preprint arXiv:1903.00374*, 2019.
- R. E. Kalman. A new approach to linear filtering and prediction problems. *Journal of basic Engineering*, 82(1):35–45, 1960.
- M. Karl, M. Soelch, J. Bayer, and P. van der Smagt. Deep variational bayes filters: Unsupervised learning of state space models from raw data. *arXiv preprint arXiv:1605.06432*, 2016.
- D. P. Kingma and J. Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

- D. P. Kingma and M. Welling. Auto-encoding variational bayes. *arXiv preprint arXiv:1312.6114*, 2013.
- R. G. Krishnan, U. Shalit, and D. Sontag. Deep kalman filters. *arXiv preprint arXiv:1511.05121*, 2015.
- T. Kurutach, I. Clavera, Y. Duan, A. Tamar, and P. Abbeel. Model-ensemble trust-region policy optimization. *arXiv preprint arXiv:1802.10592*, 2018.
- Y. LeCun, B. Boser, J. S. Denker, D. Henderson, R. E. Howard, W. Hubbard, and L. D. Jackel. Backpropagation applied to handwritten zip code recognition. *Neural computation*, 1(4):541–551, 1989.
- A. X. Lee, A. Nagabandi, P. Abbeel, and S. Levine. Stochastic latent actor-critic: Deep reinforcement learning with a latent variable model. *arXiv preprint arXiv:1907.00953*, 2019.
- T. P. Lillicrap, J. J. Hunt, A. Pritzel, N. Heess, T. Erez, Y. Tassa, D. Silver, and D. Wierstra. Continuous control with deep reinforcement learning. *arXiv preprint arXiv:1509.02971*, 2015.
- K. Lowrey, A. Rajeswaran, S. Kakade, E. Todorov, and I. Mordatch. Plan online, learn offline: Efficient learning and exploration via model-based control. *arXiv preprint arXiv:1811.01848*, 2018.
- M. C. Machado, M. G. Bellemare, E. Talvitie, J. Veness, M. Hausknecht, and M. Bowling. Revisiting the arcade learning environment: Evaluation protocols and open problems for general agents. *Journal of Artificial Intelligence Research*, 61:523–562, 2018.
- D. McAllester and K. Statos. Formal limitations on the measurement of mutual information. *arXiv preprint arXiv:1811.04251*, 2018.
- V. Mnih, K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, et al. Human-level control through deep reinforcement learning. *Nature*, 518(7540):529, 2015.
- V. Mnih, A. P. Badia, M. Mirza, A. Graves, T. Lillicrap, T. Harley, D. Silver, and K. Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *International Conference on Machine Learning*, pages 1928–1937, 2016.
- J. Oh, S. Singh, and H. Lee. Value prediction network. In *Advances in Neural Information Processing Systems*, pages 6118–6128, 2017.
- A. v. d. Oord, Y. Li, and O. Vinyals. Representation learning with contrastive predictive coding. *arXiv preprint arXiv:1807.03748*, 2018.
- P. Parmas, C. E. Rasmussen, J. Peters, and K. Doya. PIPPS: Flexible model-based policy search robust to the curse of chaos. *arXiv preprint arXiv:1902.01240*, 2019.
- A. Piergiovanni, A. Wu, and M. S. Ryoo. Learning real-world robot policies by dreaming. *arXiv preprint arXiv:1805.07813*, 2018.
- B. Poole, S. Ozair, A. v. d. Oord, A. A. Alemi, and G. Tucker. On variational bounds of mutual information. *arXiv preprint arXiv:1905.06922*, 2019.
- D. J. Rezende, S. Mohamed, and D. Wierstra. Stochastic backpropagation and approximate inference in deep generative models. *arXiv preprint arXiv:1401.4082*, 2014.
- J. Schmidhuber. Making the world differentiable: On using self-supervised fully recurrent neural networks for dynamic reinforcement learning and planning in non-stationary environments. 1990.
- J. Schrittwieser, I. Antonoglou, T. Hubert, K. Simonyan, L. Sifre, S. Schmitt, A. Guez, E. Lockhart, D. Hassabis, T. Graepel, et al. Mastering atari, go, chess and shogi by planning with a learned model. *arXiv preprint arXiv:1911.08265*, 2019.

- J. Schulman, F. Wolski, P. Dhariwal, A. Radford, and O. Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- D. Silver, G. Lever, N. Heess, T. Degris, D. Wierstra, and M. Riedmiller. Deterministic policy gradient algorithms. In *Proceedings of the 31st International Conference on Machine Learning*, 2014.
- D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez, T. Hubert, L. Baker, M. Lai, A. Bolton, et al. Mastering the game of go without human knowledge. *Nature*, 550(7676):354, 2017.
- A. Srinivas, A. Jabri, P. Abbeel, S. Levine, and C. Finn. Universal planning networks. *arXiv preprint arXiv:1804.00645*, 2018.
- R. S. Sutton. Dyna, an integrated architecture for learning, planning, and reacting. *ACM SIGART Bulletin*, 2(4):160–163, 1991.
- R. S. Sutton and A. G. Barto. *Reinforcement learning: An introduction*. MIT press, 2018.
- Y. Tassa, Y. Doron, A. Muldal, T. Erez, Y. Li, D. d. L. Casas, D. Budden, A. Abdolmaleki, J. Merel, A. Lefrancq, et al. Deepmind control suite. *arXiv preprint arXiv:1801.00690*, 2018.
- N. Tishby, F. C. Pereira, and W. Bialek. The information bottleneck method. *arXiv preprint physics/0004057*, 2000.
- T. Wang and J. Ba. Exploring model-based planning with policy networks. *arXiv preprint arXiv:1906.08649*, 2019.
- T. Wang, X. Bao, I. Clavera, J. Hoang, Y. Wen, E. Langlois, S. Zhang, G. Zhang, P. Abbeel, and J. Ba. Benchmarking model-based reinforcement learning. *CoRR*, abs/1907.02057, 2019.
- M. Watter, J. Springenberg, J. Boedecker, and M. Riedmiller. Embed to control: A locally linear latent dynamics model for control from raw images. In *Advances in neural information processing systems*, pages 2746–2754, 2015.
- T. Weber, S. Racanière, D. P. Reichert, L. Buesing, A. Guez, D. J. Rezende, A. P. Badia, O. Vinyals, N. Heess, Y. Li, et al. Imagination-augmented agents for deep reinforcement learning. *arXiv preprint arXiv:1707.06203*, 2017.
- R. J. Williams. Simple statistical gradient-following algorithms for connectionist reinforcement learning. *Machine learning*, 8(3-4):229–256, 1992.
- M. Zhang, S. Vikram, L. Smith, P. Abbeel, M. Johnson, and S. Levine. Solar: deep structured representations for model-based reinforcement learning. In *International Conference on Machine Learning*, 2019.

A 超参数

模型组件 我们使用 Ha and Schmidhuber (2018) 的卷积编码器和解码器网络, Hafner et al. (2018) 的 RSSM, 并将所有其他函数实现为三个大小为 300 的密集层, 使用 ELU 激活函数 (Clevert et al., 2015)。潜在空间中的分布是 30 维对角高斯分布。动作模型输出一个按因子 5 缩放的 tanh 均值和一个 softplus 标准差的正态分布, 然后使用 tanh 进行变换 (Haarnoja et al., 2018)。缩放因子允许智能体饱和动作分布。

学习更新 我们抽取 50 个长度为 50 的序列批次来训练世界模型、值模型和动作模型, 使用 Adam 优化器 (Kingma and Ba, 2014), 学习率分别为 6×10^{-4} 、 8×10^{-5} 、 8×10^{-5} , 并缩小超过 100 的梯度范数。我们不缩放 KL 正则化项 ($\beta = 1$), 但将其裁剪到 3 个自由 nat 以下, 与 PlaNet 一致。想象视野为 $H = 15$, 同一条轨迹用于更新动作模型和值模型。我们使用 $\gamma = 0.99$ 和 $\lambda = 0.95$ 计算 V_λ 目标。我们发现不需要潜在过度预测来学习模型, 不需要动作模型的熵奖励, 也不需要值模型的目标网络。

环境交互 数据集用 $S = 5$ 个使用随机动作收集的回合初始化。我们迭代进行 100 个训练步和通过执行预测的众数动作并添加 $\text{Normal}(0, 0.3)$ 探索噪声收集 1 个回合。我们没有像 Hafner et al. (2018) 和 Lee et al. (2019) 那样为每个环境手动选择动作重复, 而是对所有环境固定为 2。关于不同动作重复值的鲁棒性评估见 Figure 12。

离散控制 对于 Atari 游戏和 DeepMind Lab 关卡的实验, 动作模型预测分类分布的 logits。我们在潜在想象过程中对采样步骤使用直通梯度。动作噪声为 epsilon 贪心, 其中 ϵ 在前 200,000 个梯度步中从 0.4 线性衰减到 0.1。为了应对这些任务更高的复杂度, 我们使用想象视野 $H = 10$, 将 KL 正则化项缩放为 $\beta = 0.1$, 并使用 tanh 限制奖励。我们从潜在状态用一个二分类器预测折扣因子, 该分类器以 0 和 γ 的软标签进行训练。

B 推导

我们定义潜在动力学模型的信息瓶颈目标 (Tishby et al., 2000),

$$\max \mathbb{I}(s_{1:T}; (o_{1:T}, r_{1:T}) \mid a_{1:T}) - \beta \mathbb{I}(s_{1:T}, i_{1:T} \mid a_{1:T}), \quad (13)$$

其中 β 是标量, i_t 是数据集索引, 决定了观测 $p(o_t \mid i_t) \doteq \delta(o_t - \bar{o}_t)$, 如 Alemi et al. (2016) 所示。

最大化该目标得到的模型状态能够预测观测和奖励的序列, 同时限制每个时间步提取的信息量。这鼓励模型尽可能依赖前序时间步提取的信息来重建每张图像, 仅在必要时才从当前图像中获取额外信息。因此, 信息正则化项鼓励模型学习长期依赖关系。

对于生成目标, 我们利用 KL 散度的非负性对第一项进行下界估计, 并丢弃边缘数据概率, 因为它不依赖于表征模型,

$$\begin{aligned} & \mathbb{I}(s_{1:T}; (o_{1:T}, r_{1:T}) \mid a_{1:T}) \\ &= \mathbb{E}_{p(o_{1:T}, r_{1:T}, s_{1:T}, a_{1:T})} \left(\sum_t \ln p(o_{1:T}, r_{1:T} \mid s_{1:T}, a_{1:T}) - \underbrace{\ln p(o_{1:T}, r_{1:T} \mid a_{1:T})}_{\text{const}} \right) \\ &\stackrel{\pm}{=} \mathbb{E} \left(\sum_t \ln p(o_{1:T}, r_{1:T} \mid s_{1:T}, a_{1:T}) \right) \\ &\geq \mathbb{E} \left(\sum_t \ln p(o_{1:T}, r_{1:T} \mid s_{1:T}, a_{1:T}) \right) - \text{KL} \left(p(o_{1:T}, r_{1:T} \mid s_{1:T}, a_{1:T}) \parallel \prod_t q(o_t \mid s_t) q(r_t \mid s_t) \right) \\ &= \mathbb{E} \left(\sum_t \ln q(o_t \mid s_t) + \ln q(r_t \mid s_t) \right). \end{aligned} \quad (14)$$

对于对比目标, 我们减去变分编码器下数据的常数边缘概率, 应用贝叶斯规则, 并使用 InfoNCE 小批次下界 (Poole et al., 2019),

$$\begin{aligned} & \mathbb{E}(\ln q(o_t \mid s_t) + \ln q(r_t \mid s_t)) \\ &\stackrel{\pm}{=} \mathbb{E}(\ln q(o_t \mid s_t) - \ln q(o_t) + \ln q(r_t \mid s_t)) \\ &= \mathbb{E}(\ln q(s_t \mid o_t) - \ln q(s_t) + \ln q(r_t \mid s_t)) \\ &\geq \mathbb{E} \left(\ln q(s_t \mid o_t) - \ln \sum_{o'} q(s_t \mid o') + \ln q(r_t \mid s_t) \right). \end{aligned} \quad (15)$$

对于第二项, 我们利用 KL 散度的非负性得到一个上界,

$$\begin{aligned} & \mathbb{I}(s_{1:T}; i_{1:T} \mid a_{1:T}) \\ &= \mathbb{E}_{p(o_{1:T}, r_{1:T}, s_{1:T}, a_{1:T}, i_{1:T})} \left(\sum_t \ln p(s_t \mid s_{t-1}, a_{t-1}, i_t) - \ln p(s_t \mid s_{t-1}, a_{t-1}) \right) \\ &= \mathbb{E} \left(\sum_t \ln p(s_t \mid s_{t-1}, a_{t-1}, o_t) - \ln p(s_t \mid s_{t-1}, a_{t-1}) \right) \\ &\leq \mathbb{E} \left(\sum_t \ln p(s_t \mid s_{t-1}, a_{t-1}, o_t) - \ln q(s_t \mid s_{t-1}, a_{t-1}) \right) \\ &= \mathbb{E} \left(\sum_t \text{KL} (p(s_t \mid s_{t-1}, a_{t-1}, o_t) \parallel q(s_t \mid s_{t-1}, a_{t-1})) \right). \end{aligned} \quad (16)$$

这构成了目标的下界。

C 离散控制

我们在具有离散动作的 Atari 套件 (Bellemare et al., 2013) 和 DeepMind Lab (Beattie et al., 2016) 的任务子集上评估了 Dreamer。虽然纯通过世界模型学习的智能体在这些领域中尚不具备竞争力 (Kaiser et al., 2019)，但这些任务提供了具有视觉复杂度、稀疏奖励和提前终止的多样化测试平台。智能体观测 $64 \times 64 \times 3$ 的图像，并选择 3 到 18 个动作中的一个。对于 Atari，我们遵循 Machado et al. (2018) 的评估协议，使用粘性动作。这些实验参见 Figure 9。




Figure 9: Dreamer 在具有离散动作和提前终止的环境中的性能。Dreamer 在这个 Atari 游戏子集和 DMLab 的物体收集关卡上学习到了成功的行为。我们强调这些环境的表征学习是未来工作的方向，可能使 Dreamer 在所有 Atari 游戏和 DMLab 关卡上实现有竞争力的性能。

D 行为学习




Figure 10: 在 DeepMind 控制套件的连续控制任务上，基于像素输入的动作选择方案的比较。线条显示环境步数上的平均分数，阴影区域显示 5 个种子下的标准差。我们比较了在想象中同时学习动作和值的 Dreamer，到仅在想象中学习动作，以及通过在线规划而不是学习策略来选择动作的 PlaNet。基线包括顶级无模型算法 D4PG、知名的 A3C 智能体以及混合型 SLAC 智能体。

E 表征学习




Figure 11: Dreamer 的表征学习方法比较。线条显示平均分数，阴影区域显示 5 个种子下的标准差。我们比较了生成图像和奖励、生成奖励并使用对比损失来学习图像信息以及仅预测奖励。图像重建在大多数任务上提供了最佳的学习信号，其次是对比目标。在我们的实验中，仅从奖励中学习是不够的，可能需要更大的经验量。

F 动作重复




Figure 12: Dreamer 对不同控制频率的鲁棒性。强化学习方法可能对此超参数敏感，当以环境的控制频率学习动力学模型时可能被放大。在本实验中，我们以不同的动作重复量训练 Dreamer。区域显示 2 个种子下的一个标准差。我们在此实验中使用了之前的超参数设置。我们发现 $R = 2$ 的值在跨任务上效果最好。

G 连续控制分数

	A3C	D4PG	PlaNet ¹	Dreamer
输入模态	本体感觉	像素	像素	像素
环境步数	10^8	10^8	5×10^6	5×10^6
Acrobot Swingup	41.90	91.70	3.21	365.26
Cartpole Balance	951.60	992.80	452.56	979.56
Cartpole Balance Sparse	857.40	1000.00	164.74	941.84
Cartpole Swingup	558.40	862.00	312.56	833.66
Cartpole Swingup Sparse	179.80	482.00	0.64	812.22
Cheetah Run	213.90	523.80	496.12	894.56
Cup Catch	104.70	980.50	455.98	962.48
Finger Spin	129.40	985.70	495.25	498.88
Finger Turn Easy	167.30	971.40	451.22	825.86
Finger Turn Hard	88.70	966.00	312.55	891.38
Hopper Hop	0.50	242.00	0.37	368.97
Hopper Stand	27.90	929.90	5.96	923.72
Pendulum Swingup	48.60	680.90	3.27	833.00
Quadruped Run	—	—	280.45	888.39
Quadruped Walk	—	—	238.90	931.61
Reacher Easy	95.60	967.40	468.50	935.08
Reacher Hard	39.70	957.10	187.02	817.05
Walker Run	191.80	567.20	626.25	824.67
Walker Stand	378.40	985.20	759.19	977.99
Walker Walk	311.00	968.30	944.70	961.67
平均	243.70	786.32	332.97	823.39

¹我们以固定的动作重复 $R = 2$ 重新运行 PlaNet，以避免为 20 个任务中的每一个调整此值。因此，分数与 Hafner et al. (2018) 不同。